

CHƯƠNG 1: TỔNG QUAN CÔNG NGHỆ TRÍ TUỆ NHÂN TẠO VÀ ỨNG DỤNG TRONG PHÁT HIỆN HƯ HỎNG HỆ THỐNG PIN NĂNG LƯỢNG MẶT TRỜI

- Nghiên cứu tổng quan về công nghệ Trí tuệ nhân tạo (AI), Học máy (Machine Learning), Học sâu (Deep Learning), các nghiên cứu áp dụng vào công tác phát hiện và phân loại hư hỏng trong hệ thống pin năng lượng mặt trời.

1. Giới thiệu

Trong bối cảnh nhu cầu sử dụng năng lượng tái tạo ngày càng tăng, hệ thống pin năng lượng mặt trời (PV – Photovoltaic) đang trở thành một trong những giải pháp hàng đầu. Tuy nhiên, trong quá trình vận hành, các tấm pin có thể gặp nhiều sự cố như nứt vỡ mô, bụi bẩn, hư đi-ốt, điểm nóng (hotspot), gây suy giảm hiệu suất và thiệt hại kinh tế đáng kể.

Trước đây, việc phát hiện các lỗi này thường được thực hiện thủ công hoặc bán tự động, tốn nhiều thời gian và nhân lực. Gần đây, sự phát triển mạnh mẽ của các công nghệ Trí tuệ nhân tạo (AI), Học máy (Machine Learning – ML) và đặc biệt là Học sâu (Deep Learning – DL) đã mở ra hướng tiếp cận mới, hiện đại và hiệu quả hơn trong việc tự động hóa quá trình giám sát, phát hiện và phân loại lỗi trong hệ thống PV.

Trí tuệ nhân tạo (AI), Học máy (ML) và Học sâu (DL) là các lĩnh vực công nghệ cao, đang ngày càng thể hiện vai trò quan trọng trong nhiều ngành công nghiệp, trong đó có lĩnh vực năng lượng tái tạo nói chung và năng lượng mặt trời nói riêng. AI cung cấp nền tảng cho các hệ thống thông minh có khả năng tự động hóa, học hỏi từ dữ liệu và ra quyết định mà không cần sự can thiệp trực tiếp của con người. ML là một nhánh của AI, tập trung vào việc xây dựng các mô hình cho phép máy tính học tập từ dữ liệu và dự đoán kết quả. DL là một phần mở rộng của ML, với các mô hình mạng nơ-ron sâu, giúp giải quyết hiệu quả các bài toán phức tạp như nhận diện hình ảnh, phân tích tín hiệu, dự báo hiệu suất, và đặc biệt là phát hiện, phân loại hư hỏng thông qua dữ liệu hình ảnh hoặc tín hiệu từ hệ thống pin mặt trời.

Chương này trình bày tổng quan về các công nghệ AI, ML và DL, đồng thời tổng hợp các nghiên cứu và ứng dụng nổi bật liên quan đến phát hiện hư hỏng trong hệ thống pin năng lượng mặt trời.

1. Trí tuệ nhân tạo (AI)

1.1. Định nghĩa và lịch sử phát triển AI

Trí tuệ nhân tạo (AI) là một chuyên ngành trong khoa học máy tính liên quan đến việc tạo ra các hệ thống có thể sao chép trí thông minh và khả năng giải quyết vấn đề của con người. Các hệ thống này tiếp nhận vô số dữ liệu, xử lý và học hỏi từ quá khứ để hợp lý hóa và cải thiện trong tương lai. Lịch sử của AI có thể được nhìn nhận từ hàng ngàn năm trước, với các nhà triết học cổ đại xem xét các câu hỏi về sự sống và cái chết, và các nhà phát minh tạo ra "automatons" – những cỗ máy cơ khí di chuyển độc lập.[1] Tuy nhiên, nền tảng cho AI hiện đại bắt đầu được hình thành vào đầu những năm 1900, với những bước tiến lớn diễn ra từ những năm 1950.[1] Giai đoạn "Khai sinh AI" (1950-1956) chứng kiến sự ra đời của thuật ngữ "trí tuệ nhân tạo" và công trình của Alan Turing về "Máy tính và Trí thông minh", tiền đề cho Thử nghiệm Turing.[1] Tiếp theo là giai đoạn "Trưởng thành của AI" (1957-1979) với sự phát triển nhanh chóng và cả những khó khăn trong nghiên cứu AI, bao gồm việc tạo ra ngôn ngữ lập trình LISP và robot công nghiệp đầu tiên. "Sự bùng nổ AI" (1980-1987) mang lại sự tăng trưởng và quan tâm mạnh mẽ, với các kỹ thuật Học sâu và Hệ thống chuyên gia trở nên phổ biến. Sau đó là "Mùa đông AI" (1987-1993) khi sự quan tâm và tài trợ giảm sút. Giai đoạn "Tác nhân AI" (1993-2011) chứng kiến những bước tiến ấn tượng bất chấp thiếu hụt tài trợ, bao gồm việc AI đánh bại nhà vô địch cờ vua thế giới và sự ra đời của các trợ lý ảo như Siri. Từ năm 2012 đến nay, chúng ta đang ở trong kỷ nguyên "Trí tuệ nhân tạo tổng quát (AGI)", với sự gia tăng của các công cụ AI phổ biến và sự phổ biến của Học sâu cũng như Dữ liệu lớn.

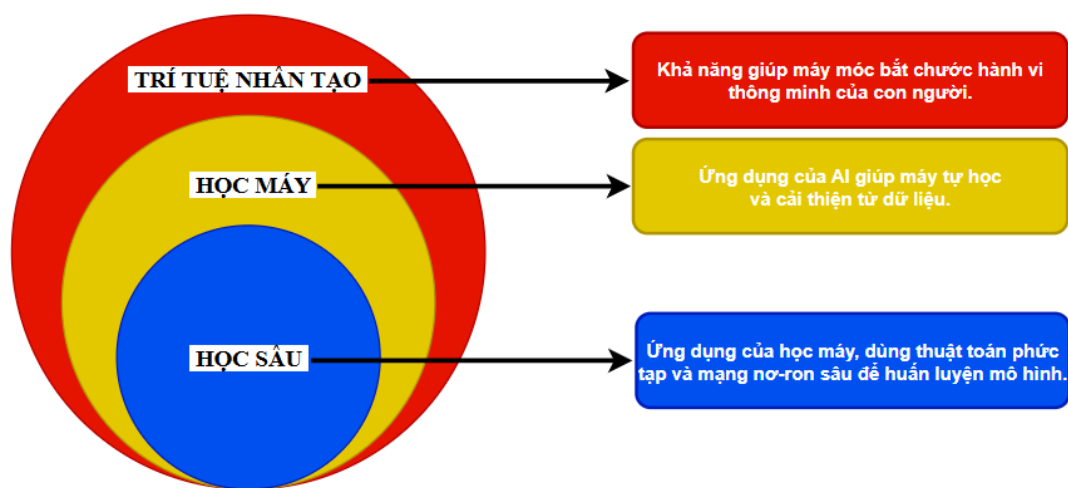
1.2. Các lĩnh vực chính của AI

Trí tuệ nhân tạo (AI) là một lĩnh vực rộng lớn, bao gồm nhiều nhánh và hướng nghiên cứu khác nhau nhằm mục tiêu xây dựng các hệ thống có khả năng mô phỏng, thực hiện các chức năng trí tuệ của con người. Để đạt được điều này, AI phát triển dựa trên sự kết hợp của nhiều lĩnh vực chuyên môn, từ khoa học máy tính, toán học, cho đến các ngành như thần kinh học, tâm lý học và triết học. Trong quá trình phát triển, AI đã hình thành nên một số lĩnh vực chính, mỗi lĩnh vực tập trung giải quyết một nhóm

vấn đề cụ thể, góp phần bổ sung và hoàn thiện năng lực của các hệ thống thông minh. Dưới đây là một số lĩnh vực tiêu biểu trong AI:

- Học máy (Machine Learning - ML): Đây là lĩnh vực nghiên cứu các thuật toán máy tính cho phép hệ thống tự động cải thiện thông qua kinh nghiệm và dữ liệu.[1] Các ứng dụng của ML bao gồm nhận dạng hình ảnh và giọng nói, phân tích dự đoán và hệ thống đề xuất.[1] ML có các nhánh phụ như Học có giám sát, Học không giám sát và Học tăng cường, sử dụng các thuật toán chính như Cây quyết định, Máy vector hỗ trợ (SVM), Mạng nơ-ron và k-Láng giềng gần nhất.[1]

- Học sâu (Deep Learning): Học sâu là một tập hợp con của Học máy, sử dụng các mạng nơ-ron đa lớp lấy cảm hứng từ mạng nơ-ron sinh học của não động vật để giải quyết các vấn đề phức tạp.[1] Các ứng dụng bao gồm nhận dạng hình ảnh và giọng nói, xử lý ngôn ngữ tự nhiên và chơi game.[1] Các khái niệm chính bao gồm lan truyền ngược, mạng tích chập và mạng hồi quy, với các công nghệ phổ biến như TensorFlow, PyTorch và Keras.[1]



[https://www.researchgate.net/figure/The-connections-between-AI-ML-and-DL_fig2_374840830]

3. Học máy (Machine Learning)

3.1 Tổng quan về học máy

Học máy (ML) là một lĩnh vực nghiên cứu trong trí tuệ nhân tạo, tập trung vào việc phát triển và nghiên cứu các thuật toán thống kê có khả năng học hỏi từ dữ liệu và tổng quát hóa cho dữ liệu chưa thấy, từ đó thực hiện các tác vụ mà không cần hướng dẫn rõ ràng.[1] Nền tảng của học máy bao gồm các phương pháp thống kê và tối ưu

hóa toán học.[1] Các phương pháp học máy truyền thống được chia thành ba loại chính: học có giám sát, học không giám sát và học tăng cường.[1] Học máy có nhiều ứng dụng trong các lĩnh vực như xử lý ngôn ngữ tự nhiên, thị giác máy tính, nhận dạng giọng nói, và y học.

[Sources help Machine learning – Wikipedia]

3.2 Ứng dụng học máy cho nhận diện lỗi

Các thuật toán học máy (ML) và các phương pháp nhận dạng mẫu khác đã được ứng dụng rộng rãi để tự động hóa việc phân loại các hình ảnh pin/mô-đun PV bình thường và bị lỗi. Trong số này, máy vector hỗ trợ (SVM) là một thuật toán nổi bật. Chẳng hạn, Demant và cộng sự [91] đã sử dụng SVM để phân loại các hình ảnh quang phát quang (PL) bị nứt và bình thường, trong khi các mẫu vết nứt cũng được xác định bằng cách sử dụng biểu đồ vị trí và hướng gradient (GLOH), mặc dù phương pháp này nhạy cảm với lỗi vùng và việc sửa lỗi có thể tốn thời gian [92]. Kato [93] đã sử dụng bộ phân loại SVM trên các đặc trưng hình ảnh được trích xuất từ ảnh RGB, bao gồm các đặc trưng như Histogram of Oriented Gradients (HOG) [94] và Speeded Up Robust Features (SURF) [95], để tự động phân loại các chế độ hỏng hóc của pin PV. Tương tự, Demant và cộng sự [96] đã thực hiện phát hiện vết nứt tự động trong ảnh PL và ảnh hồng ngoại (IR) của mô-đun PV bằng cách sử dụng nhận dạng mẫu dựa trên các bộ mô tả cục bộ và thuật toán SVM với hạt nhân hàm cơ sở xuyên tâm. Các bộ phân loại SVM, đôi khi kết hợp với các kỹ thuật trích xuất đặc trưng như đặc trưng Haralick hoặc các đặc trưng dựa trên mô hình (ví dụ, từ EfficientNetB0) và lựa chọn đặc trưng (ví dụ, Network Component Analysis - NCA), đã cho thấy độ chính xác cao, chẳng hạn như 98,95% trong việc phát hiện các lỗi như vết nứt và ăn mòn thanh cái [160], và các điểm F1 cụ thể cho các lỗi khác nhau như vết nứt (91,40%) [161]. Các mô hình kết hợp (ensemble) bao gồm SVM cũng đã đạt được độ chính xác lên đến 98,34% [178].

Các thuật toán học máy (ML) và các phương pháp nhận dạng mẫu khác đã được ứng dụng rộng rãi để tự động hóa việc phân loại các hình ảnh pin/mô-đun PV bình thường và bị lỗi. Trong số này, máy vector hỗ trợ (SVM) là một thuật toán nổi bật. Chẳng hạn, Demant và cộng sự [91] đã sử dụng SVM để phân loại các hình ảnh quang phát quang (PL) bị nứt và bình thường, trong khi các mẫu vết nứt cũng được xác định bằng cách sử dụng biểu đồ vị trí và hướng gradient (GLOH), mặc dù phương pháp này nhạy cảm với lỗi vùng và việc sửa lỗi có thể tốn thời gian [92]. Kato [93] đã sử dụng bộ phân loại SVM trên các đặc trưng hình ảnh được trích xuất từ ảnh RGB, bao gồm các đặc trưng như Histogram of Oriented Gradients (HOG) [94] và Speeded Up

Robust Features (SURF) [95], để tự động phân loại các chế độ hỏng hóc của pin PV. Tương tự, Demant và cộng sự [96] đã thực hiện phát hiện vết nứt tự động trong ảnh PL và ảnh hồng ngoại (IR) của mô-đun PV bằng cách sử dụng nhận dạng mẫu dựa trên các bộ mô tả cục bộ và thuật toán SVM với hạt nhân hàm cơ sở xuyên tâm. Các bộ phân loại SVM, đôi khi kết hợp với các kỹ thuật trích xuất đặc trưng như đặc trưng Haralick hoặc các đặc trưng dựa trên mô hình (ví dụ, từ EfficientNetB0) và lựa chọn đặc trưng (ví dụ, Network Component Analysis - NCA), đã cho thấy độ chính xác cao, chẳng hạn như 98,95% trong việc phát hiện các lỗi như vết nứt và ăn mòn thanh cái [160], và các điểm F1 cụ thể cho các lỗi khác nhau như vết nứt (91,40%) [161]. Các mô hình kết hợp (ensemble) bao gồm SVM cũng đã đạt được độ chính xác lên đến 98,34% [178].

[Nguồn báo]

4. Học sâu (Deep Learning)

4.1. Tổng quan học sâu

Học sâu là một tập hợp con của học máy, tập trung vào việc sử dụng các mạng nơ-ron đa lớp để thực hiện các tác vụ như phân loại, hồi quy và học biểu diễn.[1] Lĩnh vực này lấy cảm hứng từ khoa học thần kinh sinh học và tập trung vào việc xếp chồng các nơ-ron nhân tạo thành các lớp và "huấn luyện" chúng để xử lý dữ liệu.[1] Tính từ "sâu" đề cập đến việc sử dụng nhiều lớp (từ ba đến vài trăm hoặc hàng nghìn) trong mạng.[1] Các phương pháp được sử dụng có thể là có giám sát, bán giám sát hoặc không giám sát.[1] Hầu hết các mô hình học sâu hiện đại dựa trên các mạng nơ-ron đa lớp như mạng nơ-ron tích chập và transformer, mặc dù chúng cũng có thể bao gồm các công thức mệnh đề hoặc các biến tiềm ẩn được tổ chức theo lớp trong các mô hình sinh sâu như các nút trong mạng niềm tin sâu và máy Boltzmann sâu.[1] Về cơ bản, học sâu đề cập đến một lớp các thuật toán học máy trong đó một hệ thống phân cấp các lớp được sử dụng để biến đổi dữ liệu đầu vào thành một biểu diễn ngày càng trừu tượng và tổng hợp hơn.[1] Ví dụ, trong một mô hình nhận dạng hình ảnh, đầu vào thô có thể là một hình ảnh (được biểu diễn dưới dạng một tensor pixel).[1] Lớp biểu diễn đầu tiên có thể cố gắng xác định các hình dạng cơ bản như đường thẳng và hình tròn, lớp thứ hai có thể soạn và mã hóa các sắp xếp của các cạnh, lớp thứ ba có thể mã hóa mũi và mắt, và lớp thứ tư có thể nhận ra rằng hình ảnh chứa một khuôn mặt.[1] Quan trọng là, một quy trình học sâu có thể tự học những đặc trưng nào cần đặt ở cấp độ nào một cách tối ưu.[1] Các kiến trúc học sâu có thể được xây dựng bằng phương pháp tham lam theo từng lớp.[1] Học sâu giúp tách rời các trừu tượng này và chọn ra những đặc trưng nào cải thiện hiệu suất.[1] Các thuật toán học sâu có

thể được áp dụng cho các tác vụ học không giám sát.[1] Đây là một lợi ích quan trọng vì dữ liệu không được gán nhãn phong phú hơn dữ liệu được gán nhãn.[1] Ví dụ về các cấu trúc sâu có thể được huấn luyện theo cách không giám sát là mạng niềm tin sâu.

[Sources help Deep learning – Wikipedia]

4.2. Các thuật toán học sâu

Các thuật toán học sâu đã được ứng dụng rộng rãi trong việc phát hiện lỗi của hệ thống quang điện (PV). Các nghiên cứu ban đầu [109-112] đã sử dụng học sâu để phát hiện các lỗi có thể nhìn thấy được bằng mắt thường. Một nghiên cứu khác [113] đã sử dụng Mạng Nơ-ron Tích chập (CNN) để kiểm soát chất lượng và giám sát quy trình trong quá trình sản xuất pin mặt trời, mặc dù bị hạn chế bởi độ phân giải thấp của camera sử dụng. Mạng Mask FCNN đã được sử dụng trong nghiên cứu [114] để dự đoán loại ô nhiễm và khoanh vùng vị trí trong các mô-đun năng lượng mặt trời, đồng thời cũng dự đoán tổn thất điện năng. Các nghiên cứu gần đây cũng đã áp dụng học sâu cho ảnh điện quang (EL) và ảnh hồng ngoại (IR). Ví dụ, Mehta và Azad đã sử dụng phương pháp học sâu để phân loại lỗi tự động trong ảnh EL, đồng thời so sánh với thuật toán SVM kết hợp các kỹ thuật trích xuất đặc trưng như KAZE, SIFT, HOG và SURF, tuy nhiên kết quả tốt nhất thu được khi sử dụng CNN với học chuyển giao [114]. Các phương pháp CNN, sử dụng bộ dữ liệu ảnh EL công khai và kỹ thuật học chuyển giao với mạng VGG, cũng đã được đề xuất [115,116], mặc dù lỗi trong bộ dữ liệu được gán nhãn, đặc biệt là ở các cạnh vết nứt, dường như ảnh hưởng lớn đến hiệu suất của mô hình phát hiện. Một kiến trúc CNN nhẹ cũng được sử dụng để phát hiện lỗi trong ảnh EL của các tấm pin PV, với các chiến lược tổng quát hóa được áp dụng để đạt hiệu suất tốt bằng cách sử dụng tài nguyên phần cứng thông thường và duy trì tốc độ dự đoán thời gian thực [11].

Cả học sâu độc lập và học sâu chuyển giao đều có thể phát hiện thành công các lỗi trong ảnh IR của mô-đun PV. Nghiên cứu của Akram và cộng sự [49] đã thu thập một bộ dữ liệu ảnh IR từ các mô-đun bình thường và bị lỗi, sau đó áp dụng CNN nhẹ huấn luyện từ đầu và học chuyển giao, cho thấy học chuyển giao với phát triển mô hình mang lại hiệu quả tốt hơn. Mạng ResNet-50 cũng được sử dụng để phân loại lỗi trên ảnh IR [152]. Mạng YOLO là một chủ đề nóng trong nghiên cứu gần đây về phát hiện lỗi trong mô-đun PV. Cụ thể, các tác giả trong [117] đã sử dụng YOLO để phát hiện các điểm nóng trong ảnh IR của mô-đun PV, cho thấy tính mạnh mẽ và tốc độ thời gian thực của phương pháp. Các biến thể của YOLO như YOLOv3 [154, 156], GBH-YOLOv5 [157], YOLOv7 [171], YOLO-ICBAM [175] và YOLOv8 [176, 179]

cũng đã được áp dụng thành công trong việc phát hiện nhiều loại lỗi khác nhau từ ảnh IR, RGB và EL. Mạng VGG và MobileNet cũng được sử dụng để phát hiện và phân loại lỗi trong ảnh IR của mô-đun PV [118,119]. Faster R-CNN được dùng để phát hiện điểm nóng trong ảnh IR nhiệt [12]. Buratti và cộng sự [120] đã sử dụng học chuyển giao với các kiến trúc như AlexNet, ResNet, SqueezeNet và VGGNet để trích xuất đặc trưng từ ảnh EL của pin PV và phân loại các pin bị lỗi với độ chính xác khoảng 96%. Nhiều kiến trúc khác như MSI CNN [109], DeepLabv3 kết hợp ResNet-50 [159], Efficientb0 [161], BAFPN trong Faster RCNN+FPN [162], Vision Transformer (ViT) [172], Mạng đối nghịch tạo sinh (GAN) [173, 181] và Mask R-CNN [180] cũng cho thấy tiềm năng trong việc phát hiện và phân loại lỗi trong các hệ thống PV. Nhìn chung, các phương pháp và ứng dụng này nhấn mạnh tiềm năng của học sâu trong việc phát hiện và phân loại lỗi trong hệ thống PV, đồng thời nhấn mạnh tính hiệu quả và tầm quan trọng của chúng trong lĩnh vực này. Tuy nhiên, các hạn chế của thuật toán học sâu, như đã đề cập trong các phần trước, bao gồm yêu cầu lượng lớn dữ liệu đầu vào đa dạng và được gán nhãn. Quá trình thu thập và chú thích dữ liệu có thể tốn nhiều công sức. Hơn nữa, các mô hình sâu đòi hỏi GPU mạnh mẽ, đặc biệt cho các ứng dụng thời gian thực. Tính giải thích được của các mô hình sâu là một thách thức bổ sung, liên quan chặt chẽ đến sự tin cậy vào kết quả đầu ra của chúng, đặc biệt đối với các bên liên quan muốn đầu tư vào công nghệ này.

[Nguồn báo]

6. Phân tích, so sánh các phương pháp hiện tại

- [17]. Yagi, Y., et al., *Diagnostic technology and an expert system for photovoltaic systems using the learning method*. Solar Energy Materials and Solar Cells, 2003. 75(3-4): p. 655-663.
- [18]. Karatepe, E. and T. Hiyama. *Controlling of artificial neural network for fault diagnosis of photovoltaic array*. in *2011 16th International Conference on Intelligent System Applications to Power Systems*. 2011. IEEE.
- [19]. Jufri, F.H., S. Oh, and J. Jung, *Development of Photovoltaic abnormal condition detection system using combined regression and Support Vector Machine*. Energy, 2019. 176: p. 457-467.
- [20]. Harrou, F., B. Taghezouit, and Y. Sun, *Improved k NN-based monitoring schemes for detecting faults in PV systems*. IEEE Journal of Photovoltaics, 2019. 9(3): p. 811-821.
- [21]. Rawat, W. and Z. Wang, *Deep convolutional neural networks for image classification: A comprehensive review*. Neural computation, 2017. 29(9): p. 2352-2449.
- [22]. Creswell, A., et al., *Generative adversarial networks: An overview*. IEEE signal processing magazine, 2018. 35(1): p. 53-65.

- [23]. Li, X., et al., *Deep learning based module defect analysis for large-scale photovoltaic farms*. IEEE Transactions on Energy Conversion, 2018. 34(1): p. 520-529.
- [24]. Pierdicca, R., et al., *Deep convolutional neural network for automatic detection of damaged photovoltaic cells*. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 2018. 42: p. 893-900.
- [25]. Chen, Z., et al., *Deep residual network based fault detection and diagnosis of photovoltaic arrays using current-voltage curves and ambient conditions*. Energy Conversion and Management, 2019. 198: p. 111793.
- [26]. Jiang, P., et al., *A Review of Yolo algorithm developments*. Procedia Computer Science, 2022. **199**: p. 1066-1073.
- [27]. Ronneberger, O., P. Fischer, and T. Brox. *U-net: Convolutional networks for biomedical image segmentation*. in *Medical Image Computing and Computer-Assisted Intervention -MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III* 18. 2015. Springer.