




Danh sách nội dung có sẵn tại [ScienceDirect](#)

Hệ thống và máy tính mềm

trang chủ tạp chí: www.journals.elsevier.com/soft-computing-letters



Một tập dữ liệu chuẩn để phát hiện và phân loại lỗi trong hình ảnh phát quang điện của các mô-đun PV bằng cách sử dụng phân đoạn ngữ nghĩa

Lawrence Pratt ^{a,b,*}, Jana Mattheus ^a, Richard Klein ^b

^a CSIR, Đờng Meiring Naude, Pretoria, Nam Phi
^b Khoa Khoa học Máy tính và Toán ứng dụng, Đại học Witwatersrand, Johannesburg, Nam Phi

THÔNG TIN BÀI VIẾT

Từ khóa:
Phát quang điện

PV
Phân đoạn ngữ nghĩa
Học máy

TÓM TẮT

Hình ảnh phát quang điện (EL) cho phép phát hiện khuyết tật trong các mô-đun quang điện mặt trời (PV) vốn vô hình với mắt thường, tương tự như cách chụp X-quang giúp bác sĩ phát hiện các vết nứt và gãy xương. Bài báo này trình bày một tập dữ liệu chuẩn và kết quả để phát hiện và phân loại tự động bằng các mô hình học sâu được đào tạo trên 24 khuyết tật và đặc điểm trong hình ảnh EL của pin mặt trời silicon tinh thể. Tập dữ liệu bao gồm 593 hình ảnh tế bào với mật độ sự thật cơ bản tương ứng với nhãn cấp độ pixel cho từng đặc điểm và khuyết tật. Bốn mô hình học sâu (U-Net₁₂, U-Net₂₅, PSPNet và DeepLabv3+) đã được đào tạo bằng cách sử dụng các trọng số lớp bằng nhau, trọng số lớp nghịch đảo và trọng số lớp tùy chỉnh cho tổng cộng mười hai bộ dự đoán cho mỗi 50 hình ảnh thử nghiệm. Hiệu suất của mô hình được định lượng dựa trên giao điểm trung bình trên hợp nhất (mIoU) và thu hồi trung bình (mRc1) cho một tập hợp con các khuyết tật phổ biến nhất (vết nứt, vùng không hoạt động và khuyết tật đờng lưới) và các đặc điểm (các kết nối ruy băng và khoảng cách giữa các ô) trong tập dữ liệu. mIoU được đo cao hơn đối với hai đặc điểm so với ba khuyết tật trên tất cả các mô hình, tương quan với kích thước của các đặc điểm lớn so với các khuyết tật nhỏ mà mỗi lớp chiếm giữ trong hình ảnh. DeepLabv3+ với trọng số lớp tùy chỉnh đạt điểm cao nhất về mIoU cho các khuyết tật được chọn trong tập dữ liệu này. Trong khi mIoU cho vết nứt thấp (25%) ngay cả đối với DeepLabv3+, thì khả năng thu hồi lại cao (86%) và mật độ dự đoán kết quả định vị đáng tin cậy các khuyết tật trong các hình ảnh phức tạp với cả vật thể lớn và nhỏ. Do đó, mô hình tỏ ra hữu ích trong bối cảnh phát hiện vết nứt và các khuyết tật khác trong hình ảnh EL. Những đóng góp độc đáo từ công trình này bao gồm tập dữ liệu chuẩn với mật độ sự thật cơ bản tương ứng để phân đoạn ngữ nghĩa đa lớp trong hình ảnh EL của tế bào quang điện mặt trời và số liệu hiệu suất từ bốn mô hình phân đoạn ngữ nghĩa được đào tạo bằng ba bộ trọng số lớp.

1. Giới thiệu

Hình ảnh phát quang điện (EL) cho phép phát hiện khuyết tật trong các mô-đun quang điện mặt trời (PV) mà mắt thường không nhìn thấy được, giống như cách chụp X-quang giúp bác sĩ phát hiện các vết nứt và gãy xương. Hàng triệu hình ảnh EL được chụp mỗi ngày tại các nhà máy, phòng thí nghiệm và nhà máy PV trên toàn cầu. Hình ảnh EL rất cần thiết để xác định các vết nứt và khuyết tật khác trong sản phẩm hoàn thiện trước khi mô-đun được đưa ra thị trường. Hình ảnh EL cũng thường xuyên được chụp trong quá trình kiểm tra chất lượng và xử lý sự cố trong suốt 25 năm tuổi thọ thông thường của một mô-đun PV.

Mục đích của công trình này là trình bày một tập dữ liệu độc đáo và đánh giá một số mô hình học sâu để phân đoạn ngữ nghĩa được áp dụng để phát hiện các khuyết tật và đặc điểm trong hình ảnh EL của pin mặt trời. Hai U-Net, một PSPNet và một mô hình DeepLabv3+ đã được đào tạo để phát hiện 12 đặc điểm

và 12 khiếm khuyết cùng lúc. Mục tiêu của phân tích là xác định mô hình triển vọng nhất phù hợp với nhiệm vụ, sau đó sẽ được tối ưu hóa trong công việc trong tương lai. Những đóng góp độc đáo từ công việc này bao gồm tập dữ liệu chuẩn với các mật độ thực tế tương ứng để phát hiện khiếm khuyết đa lớp trong hình ảnh EL của tế bào quang điện mặt trời. Tập dữ liệu mới này cung cấp nhãn cấp pixel chi tiết đầu tiên cho hình ảnh EL của tế bào quang điện.

2. Bối cảnh

Phát hiện và phân loại khuyết tật tự động trong pin mặt trời là chủ đề của nhiều ấn phẩm kể từ khi hình ảnh EL của pin mặt trời silicon lần đầu tiên được giới thiệu bởi Fuyuki et al. [1] để phát hiện các khu vực bị hư hỏng trong pin mặt trời vào năm 2005. Kể từ thời điểm đó, đã có những tiến bộ hướng tới hình ảnh EL tại chỗ [2-5], cải thiện chất lượng hình ảnh [6,7], hình ảnh dự đoán

* Tác giả liên hệ tại: CSIR, Đờng Meiring Naude, Pretoria, Nam Phi.
Địa chỉ email: lpratt@csir.co.za (L. Pratt).

điều kiện đầy thách thức [8] và tương quan các khiếm khuyết với công suất đầu ra của các mô-đun PV [9-16]. Đánh giá về công nghệ camera EL và ứng dụng thực địa

cation đã được công bố trong Tài liệu tham khảo [17].

Phân tích tự động và phát hiện lỗi của mô-đun PV cấp EL im tuổi tác rất quan trọng để có được thông tin hữu ích từ các lô mô-đun PV được mua và bán trong suốt chuỗi giá trị PV. Các kỹ thuật đã được phát triển để trích xuất và nâng cao hình ảnh của các tế bào năng lượng mặt trời từ hình ảnh cấp mô-đun PV [18-21] như một bước tiền xử lý để tự động hóa việc phát hiện và phân loại lỗi thường được thực hiện trên hình ảnh cấp tế bào. Các mô hình học sâu đã được đào tạo trên hình ảnh EL để phân loại

phân loại các ô và mô-đun thành các loại khuyết tật hoặc các mức độ nghiêm trọng khuyết tật khác nhau [19,20,22-28]. Các phương pháp phát hiện đối tượng và định vị nhiều khuyết tật trong ảnh EL đã được trình bày [29-31]. Các phương pháp phân đoạn nhị phân đã được sử dụng để phát hiện và định vị các vết nứt và khuyết tật đường lưới ở cấp độ pixel [32-36]. Fioresi et al. [36] đã trình bày kết quả sử dụng phân đoạn ngưỡng nghĩa để phát hiện và định vị ba lớp đồng thời trên ảnh EL từ một tập dữ liệu riêng với 14 lớp được gán nhãn. Tuy nhiên, các nhãn cho vết nứt và khuyết tật đường lưới trong Tài liệu tham khảo [36] đã được gán cho các vùng lớn của ảnh tế bào, như đã thảo luận trong Phần 3.2.

Bài báo này dựa trên công trình trước đó trong đó kết quả của mô hình U-Net được đào tạo trên 24 khuyết tật và tính năng đã được trình bày [37]. Trong công trình đó, phân đoạn ngữ nghĩa đã được giới thiệu như một phương pháp tiếp cận đầy hứa hẹn để phát hiện và định lượng nhiều lớp khuyết tật trong hình ảnh EL của mô-đun PV. Đồng góp chính từ phân đoạn ngữ nghĩa nằm ở phân loại hình ảnh ở cấp độ pixel [38,39] cho phép dịch từ hình ảnh không có cấu trúc sang tập dữ liệu có cấu trúc.

Phân loại cấp độ pixel cho phép mô hình phát hiện và định lượng nhiều loại lỗi trên một tế bào quang điện duy nhất thay vì chỉ phân loại từng hình ảnh tế bào có lỗi cụ thể hay không. Bộ dữ liệu có cấu trúc được sử dụng để định lượng mức độ của từng lỗi ở cấp độ mô-đun bằng cách tổng hợp số lượng pixel liên quan đến từng lỗi được quan sát thấy trong các hình ảnh EL cấp độ tế bào được chụp ở nhiều giai đoạn trong một chuỗi các thử nghiệm ứng suất tăng tốc. Hiệu suất điện của mô-đun PV sau đó có thể được liên kết với các lỗi được phát hiện trong các hình ảnh EL để hiểu rõ hơn nguyên nhân gốc rễ của hiệu suất mô-đun và sự suy giảm theo thời gian. Trong công trình hiện tại này, bộ dữ liệu được gán nhãn được công khai và kết quả từ mười hai mô hình học sâu được so sánh và tóm tắt để xác định các mô hình có thể phù hợp hơn để phát hiện lỗi trong hình ảnh EL của các mô-đun PV. So sánh bao gồm cùng một mô hình U-Net được trình bày trong Tài liệu tham khảo [37] (xem Bảng 1, mô hình '1a') với kết quả từ quá trình đào tạo trên bộ dữ liệu đã cập nhật.

3. Vật liệu và phương pháp

3.1. Hình ảnh phát quang điện

Hình ảnh EL của các mô-đun PV được chế tạo từ các ô silicon tinh thể là rất cần thiết để phát hiện lỗi vì các vết nứt nhỏ và các khu vực không hoạt động ảnh hưởng đến hiệu suất của mô-đun nhưng thường không thể phát hiện bằng mắt thường. Hình ảnh EL được chụp bằng camera được tối ưu hóa để ghi lại

Bảng 1
Mã số mô hình và mô tả.

--	Trọng lượng lớp	Ngành kiến trúc	Tác giả Github	Các tham số có thể đào tạo
1-một	Bình đẳng	Mạng U	Nữ thần	12.333.720
1-b	Đảo ngược			
1-c	Phong tục			
2-a	Bình đẳng	Mạng U	Lấy	25.858.887
2-b	Đảo ngược			
2-c	Phong tục			
3-a	Bình đẳng	Mạng PSP	Kamikawa	58.838.784
3-b	Đảo ngược			
3-c	Phong tục			
4-a	Bình đẳng	DeepLabv3+	Yakubovsky và Kawakita	22.443.368
4-b	Đảo ngược			
4-c	Phong tục			

phát xạ photon gần bước sóng 1100 nm, bên ngoài quang phổ ánh sáng khả kiến. Mô-đun PV được kết nối với nguồn điện và điện

dòng điện ba chiều được áp dụng để kích thích các photon trong quá trình chụp ảnh. Máy ảnh chụp các bức xạ photon khi các cặp electron-lỗ trống kết hợp lại [17].

Hình 1 cho thấy mười ví dụ về hình ảnh EL từ tập dữ liệu. Hàng trên cùng bao gồm các tế bào từ các tấm silicon đa tinh thể có đặc điểm các góc vuông và ranh giới hạt xuất hiện dưới dạng các vùng tối nhỏ trên khắp ô. Hàng dưới cùng bao gồm các ô từ các tấm silicon đơn tinh thể với các góc tròn đặc trưng và thiếu ranh giới hạt đáng chú ý do định hướng tinh thể đơn của tấm. Các hình ảnh cũng hiển thị các ví dụ về một số tính năng như khoảng cách giữa các ô, kết nối ruy băng và văn bản. Các khuyết tật được hiển thị bao gồm các vết nứt, vùng không hoạt động, khuyết tật đường lưới và ăn mòn.


3.2. Bộ dữ liệu

Bộ dữ liệu bao gồm 593 hình ảnh EL của các tế bào năng lượng mặt trời có nguồn gốc từ ba nguồn riêng tư và hai nguồn công khai [40,41] với số lượng wafer đa tinh thể và đơn tinh thể gần bằng nhau. Số lượng hình ảnh được gán nhãn ban đầu vượt quá 600, nhưng một số hình ảnh đã bị loại trừ sau khi chuyên gia PV xem xét kiểm soát chất lượng. Các đóng góp từ các nguồn riêng tư bao gồm các hình ảnh EL cấp mô-đun trong khi các đóng góp từ các nguồn công khai bao gồm các hình ảnh EL cấp ô. Các hình ảnh gốc đã được xử lý trước theo phương pháp được mô tả trong Tài liệu tham khảo [37]. Hình ảnh 512 × 512 cuối cùng chứa một ô đầy đủ ở trung tâm được bao quanh bởi các ô liền kề, cạnh mô-đun hoặc đệm tùy thuộc vào nguồn hình ảnh và vị trí của ô trong hình ảnh cấp mô-đun. Hai nguồn công khai đã công bố hình ảnh ô đơn lẻ và do đó yêu cầu đệm ở cả bốn phía để duy trì ô đầy đủ ở trung tâm của mỗi hình ảnh.

Các hình ảnh trong tập dữ liệu chuẩn được tuyển chọn bởi một chuyên gia PV từ hơn 80.000 hình ảnh có sẵn từ năm nguồn dữ liệu com đã được ghép lại. Các hình ảnh được chuyên gia lựa chọn trong quá trình quét trực quan các mẫu được chọn ngẫu nhiên từ 80.000 hình ảnh để tạo thành một bản đại diện mẫu cảm ứng của các ô đơn tinh thể và đa tinh thể có các đặc điểm và khuyết tật chung để mô hình có thể được khái quát hóa nhất có thể với một mẫu tương đối nhỏ. Chuyên gia PV đã xác định 12 đặc điểm vốn có trong hầu hết các mô-đun PV để cung cấp bối cảnh cho các mô hình phân đoạn ngữ nghĩa. Trong bài báo này, một đặc điểm đề cập đến một thành phần cụ thể của mô-đun PV như thanh cái, kết nối ruy băng hoặc khoảng cách giữa các ô. Không nên nhầm lẫn điều này với một đặc điểm do nhà khoa học dữ liệu thiết kế để cải thiện dự đoán. Chuyên gia PV cũng đã xác định 12 khuyết tật bên ngoài các ô mặt trời như vết nứt, vùng không hoạt động và khuyết tật đường lưới có thể ảnh hưởng tiêu cực đến hiệu suất của mô-đun. Tổng hợp lại, các đặc điểm

Các đặc điểm và khuyết điểm kết hợp lại để tạo ra 24 lớp cho phân loại cấp độ pixel.

Sau đó, mặt nạ sự thật cơ bản được tạo cho mỗi hình ảnh trong tập dữ liệu bằng cách sử dụng GNU Image Manipulation Program (GIMP) [42] để chỉ định mã màu duy nhất cho mỗi lớp. Các mẫu đã chọn được phân phối cho một nhóm người dán nhãn được đào tạo để xác định các tính năng và khuyết điểm.



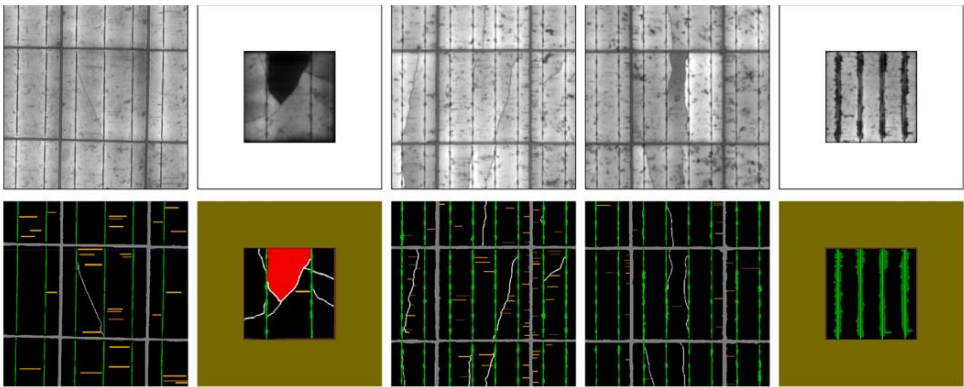
Hình 1. Hình ảnh EL từ tấm silicon đa tinh thể (trên) và tấm silicon đơn tinh thể (dưới).

Người dán nhãn cũng được chỉ định một bộ hình ảnh chung để có thể đánh giá quá trình về tính nhất quán và đào tạo thêm. yêu cầu trong giai đoạn đầu. Sau đó, các hình ảnh được gắn nhãn để phân tích để xác định và sửa bất kỳ điểm ảnh nào không nhất quán với mã màu RGB được xác định trước. Cuối cùng, chuyên gia PV đã xem xét các mặt nạ thực tế và cung cấp hướng dẫn cho một chuyên gia dán nhãn để sửa đổi lần cuối. Hình 2 cho thấy hình ảnh EL và mặt nạ thực tế tương ứng cho các ô silicon đa tinh thể được hiển thị trong Hình 1. Việc dán nhãn mặt nạ thực tế gặp nhiều thách thức khi dán nhãn các vết nứt dài và hẹp, các tác động như vết nứt và khuyết tật được lưu trữ. Một sự sai lệch nhỏ giữa hình ảnh và mặt nạ thực tế có thể dễ dàng dẫn đến kết quả dự đoán tính giả và kết quả âm tính giả khi đối tượng quan tâm chỉ rộng vài pixel như trường hợp vết nứt. Trong Tài liệu tham khảo [36], mặt nạ thực tế gán các vùng lớn của hình ảnh cho các vết nứt và khuyết tật được lưu trữ mở rộng vượt xa các pixel cụ thể liên quan đến bất kỳ khuyết tật nào như được thấy trong hình ảnh EL. Trong khi phương pháp gắn nhãn trong Tài liệu tham khảo [36] giảm thiểu tác động từ các lỗi dọc theo các cạnh, thì việc định vị các khuyết tật lại kém chính xác. Bộ dữ liệu được trình bày trong công trình này cung cấp độ phân giải tốt hơn cho kích thước và hình dạng của vết nứt (màu trắng) và khuyết tật được lưu trữ (màu cam) như thể hiện trong Hình 2.

Bộ dữ liệu được chia thành các tập hợp con để đào tạo, xác thực và thử nghiệm. Năm mươi hình ảnh có tỷ lệ vết nứt, khuyết tật được lưu trữ và các vùng không hoạt động được chỉ định để thử nghiệm, chia đều cho các tấm wafer đơn và đa silicon. Năm mươi bốn hình ảnh được chọn ngẫu nhiên từ các hình ảnh còn lại để xác thực. Các hình ảnh còn lại được chỉ định để đào tạo và tăng cường bằng cách sử dụng phép quay 180°, phản chiếu và lật tạo ra 896 hình ảnh ô đơn-si và 1016 hình ảnh ô đa-si, tổng cộng có 1912 hình ảnh trong tập dữ liệu đào tạo.

3.3. Mô hình học sâu

Bảng 1 tóm tắt 12 mô hình học sâu được giám sát hoàn toàn



Hình 2. Hình ảnh EL và mặt nạ thực tế cho một mẫu pin silicon đa tinh thể.

được đào tạo và thử nghiệm để xác định kiến trúc có hiệu suất tốt nhất cho tập dữ liệu chuẩn này. ID mô hình được sử dụng trong phân tích tiếp theo để xác định từng mô hình trong số 12 mô hình. Mã python để đào tạo từng mô hình được điều chỉnh từ mã được công bố trên kho lưu trữ GitHub tương ứng [43–47]. U-Net được đưa vào vì nó hoạt động tốt với một tập dữ liệu được gắn nhãn nhỏ [48] và nó tiên phong trong mô hình mã hóa-giải mã đối xứng với các kết nối bỏ qua [38] tạo thành cơ sở của nhiều mô hình học sâu hiện tại. Một U-Net thứ hai phức tạp hơn được đưa vào để xác định xem các tham số có thể đào tạo bổ sung có dẫn đến dự đoán tốt hơn so với U-Net nhỏ hơn hay không. PSPNet được chọn vì độ sâu và độ phức tạp của mô hình bao gồm một mô-đun nhóm kim tự tháp mới để cải thiện khả năng hiểu cảnh phức tạp [49]. Deeplabv3+ được chọn vì hứa hẹn sẽ cải thiện các dự đoán, đặc biệt là dọc theo ranh giới đối tượng [50].

Entropy chéo có trọng số được chọn cho hàm mất mát đào tạo vì nó được sử dụng rộng rãi để phân đoạn ngữ nghĩa với các tập dữ liệu mất cân bằng [51]. Mỗi mô hình được đào tạo với ba tập trọng số lớp khác nhau. Các trọng số lớp bằng nhau (Bộ A) gán một giá trị là một cho tất cả các lớp ($w_{A1} = w_{A2} = \dots = w_{Ac} = 1$) trong đó, w_{Ac} là trọng số lớp bằng nhau cho lớp thứ c. Các trọng số lớp 'nghịch đảo' (Bộ B) gán một giá trị cho mỗi lớp bằng nghịch đảo của phần trăm trung bình của các điểm ảnh trong mỗi lớp trên tất cả các hình ảnh trong tập dữ liệu đào tạo. (1)

$$w_{Bc} = \frac{1}{\text{trung vị}(pc1, pc2, \dots, pcn)} \tag{1}$$

w_{Bc} = trọng số lớp nghịch đảo cho lớp thứ c pcn = phần trăm pixel trong lớp thứ c cho hình ảnh thứ n n = số lượng hình ảnh trong tập dữ liệu thử nghiệm Trọng số lớp tùy chỉnh (Bộ C) được xác định trước dựa trênengi phán đoán cẩn thận để cải thiện khả năng phát hiện vết nứt, được lưu trữ và không các khu vực tích cực bằng cách gán trọng số lớn hơn cho các lớp đó (Bảng 2).

Tỷ lệ 100:1 cho vết nứt so với nền được thiết lập để tăng cường phát hiện vết nứt và giảm thiểu tác động của nhiễu từ ranh giới hạt trong

Bảng 2

Trọng số lớp tùy chỉnh.

Sự miêu tả	Giá trị
wCbackground	0.2
wCribbons	3.0
wCgridline	10.0
wCinactive	10.0
wCrack	20.0
nếu không	1.0

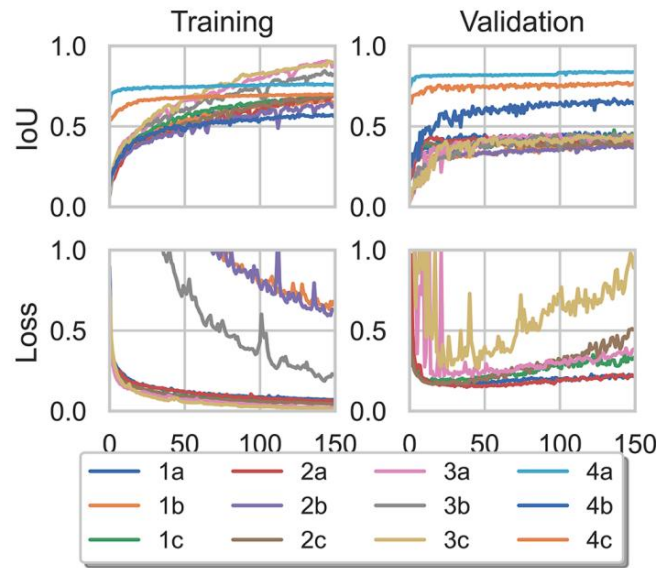
các tế bào năng lượng mặt trời đa tinh thể. Trọng số lớp cho dự đoán lỗi và vùng không hoạt động được đặt thành mười để cải thiện khả năng phát hiện so với các khuyết tật khác. Trọng số lớp cho ruy băng được đặt thành 3 để cải thiện khả năng phát hiện tính năng này và sử dụng nó để phân loại loại tế bào theo số lượng ruy băng kết nối trong công việc trong tương lai. Lựa chọn trọng số tùy chỉnh đã được xác thực bằng Thiết kế Thí nghiệm (DOE) sàng lọc 16 lần chạy sử dụng các trọng số tùy chỉnh này làm điểm trung tâm. Các giá trị thấp được đặt thành một nửa trọng số tùy chỉnh và các giá trị cao được đặt thành một nửa trọng số nghịch đảo. Phân tích DOE cho thấy các trọng số tùy chỉnh được xếp hạng trong số các giải pháp tốt nhất để phát hiện nền, vết nứt, dự đoán lỗi, ruy băng và vùng không hoạt động trên tập dữ liệu chuẩn này.

Hình 3 biểu diễn nhật ký đào tạo và xác thực từ tất cả mười hai mô hình. Tuy nhiên, không phải tất cả các hàm mất mát đều được hiển thị vì thang đo được chọn cho đồ họa này. Mất mát đào tạo vượt quá một cho tất cả DeepLabv3+ mô hình. Độ mất xác thực vượt quá một đối với DeepLabv3+ và các mô hình còn lại có trọng số lớp nghịch đảo.

3.4. Tổng quan về phương pháp

Hình 4 tóm tắt phương pháp luận được áp dụng cho công trình này. Các hình ảnh EL và nhân thực tế đã được tuyển chọn, chia thành các tập hợp con, tăng cường và đào tạo bằng ba trọng số lớp khác nhau. Các mô hình đã được sử dụng để tạo mặt nạ dự đoán cho từng hình ảnh trong tập dữ liệu thử nghiệm trong đó mỗi pixel được dán nhãn từ 0 đến 23 tùy ứng với lớp dự đoán. Mặt nạ được tô màu để tạo điều kiện phân tích trực quan từng mặt nạ. IoU trung bình đã được tính toán cho mỗi kết hợp hình ảnh/lớp và được vẽ để so sánh. Các hình ảnh EL và ứng dụng

Mặt nạ thực tế đã được công bố trên github (<https://github.com/TheMakiran/BenchmarkELImages>).



Hình 3. Hàm IoU và mất mát trung bình cho U-Net_12 (1a/b/c), U-Net_25 (2a/b/c), PSPNet (3a/b/c) và DeepLabv3+ (4a/b/c).

4. Kết quả và thảo luận

Hình 5 trình bày mặt nạ dự đoán cho ảnh EL của một ô (CFVS 00035_r8_c4) từ tất cả 12 mô hình. Ô này được chọn vì nó chứa ba khuyết tật chính cần quan tâm: vết nứt, khuyết tật dự đoán lỗi và vùng không hoạt động. Các hàng tương ứng với mô hình: U-Net_12 (hàng 1), U-Net_25 (hàng 2), PSPNet (hàng 3) và DeepLabv3+ (hàng 4). Cột

umns tương ứng với trọng số lớp: trọng số lớp bằng nhau (a), trọng số lớp nghịch đảo (b) và trọng số lớp tùy chỉnh (c). Cả bốn mô hình đều tạo ra mặt nạ dự đoán tương tự trên ba tập trọng số lớp, tức là tất cả các hàng đều trông giống nhau. Tất cả chúng đều phát hiện khoảng cách giữa các ô (màu xám) và các dải ruy băng (màu xanh lá cây) tốt. Tuy nhiên, trọng số lớp bằng nhau dự đoán ít/nhỏ hơn các vết nứt so với trọng số lớp nghịch đảo và trọng số lớp tùy chỉnh.

Mặt nạ từ ngữ được tạo ra từ trọng số lớp nghịch đảo và trọng số lớp tùy chỉnh có xu hướng hiển thị các vết nứt giãn nở và các khuyết tật dự đoán lỗi.

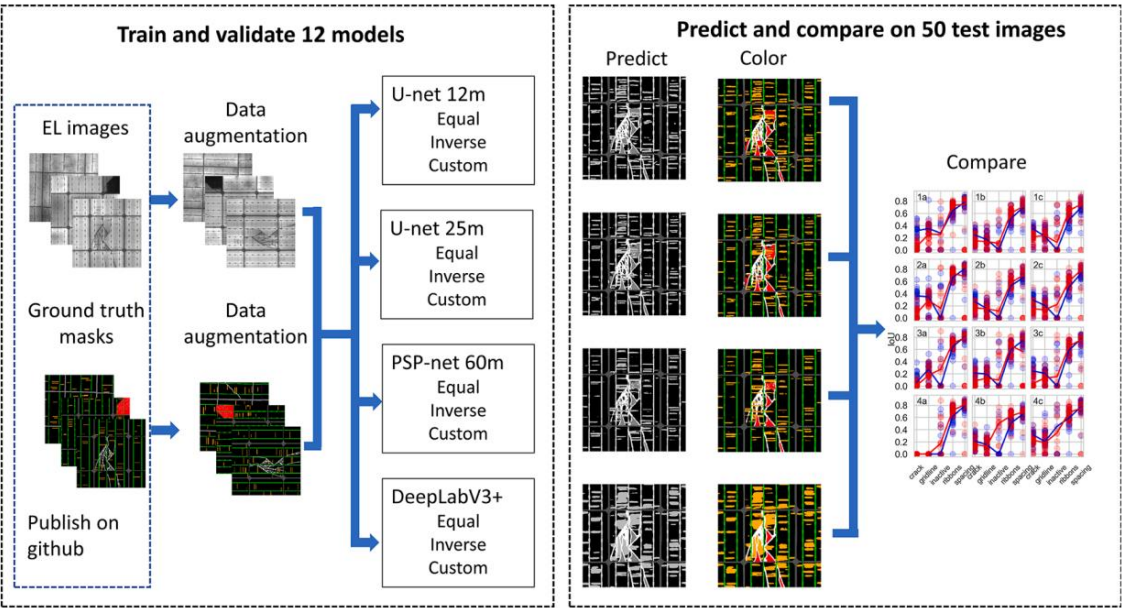
Hình 6 cho thấy IoU cho ba khuyết tật và hai tính năng trên bản thử nghiệm từ 12 mô hình cho tập dữ liệu thử nghiệm. Các dự đoán kết nối

mIoU cho mỗi lớp và màu sắc tương ứng với các tấm silicon đơn tinh thể (màu xanh lam) và đa tinh thể (màu đỏ). Bố cục lưu ý phù hợp với Hình 5 để tạo điều kiện so sánh trực quan giữa một hình ảnh mẫu và kết quả kết hợp cho tập dữ liệu thử nghiệm. Tất cả các mô hình đều phát hiện các đặc điểm (khoảng cách và dải) tốt hơn các khuyết tật (vết nứt, dự đoán lỗi và vùng không hoạt động). Điều này tương quan với kích thước tương đối của các tính năng và khuyết tật. Các khuyết tật chiếm nhiều điểm ảnh hơn trong hình ảnh so với các khuyết tật. Dựa trên giá trị trung bình cho số lượng pixel trong tập dữ liệu thử nghiệm, các vết nứt chiếm 557 pixel, các vùng không hoạt động chiếm 1288 pixel và các dự đoán lỗi chiếm 1750 pixel. Khoảng cách chiếm 12.529 pixel và các dải ruy băng chiếm 12.871 pixel. Do đó, các đặc điểm lớn hơn khoảng 10 đến 20 lần so với các khuyết tật, điều này có thể giải thích mIoU cao hơn cho các đặc điểm so với các khuyết tật.


Kết quả cho cả wafer đa tinh thể và wafer đơn tinh thể được quan sát thấy trên DeepLabv3+ với trọng số tùy chỉnh. mIoU cho các vết nứt và khuyết tật lưu ý thường cao hơn trên silicon đơn tinh thể so với wafer đa tinh thể.

Hình 7 cho thấy bản đồ nhiệt cho mIoU của năm lớp được chọn trên 12 mô hình và giá trị trung bình của mIoU đối với các khuyết tật (vết nứt, lưu ý, đồng, không hoạt động) và các tính năng (ruy băng, khoảng cách). Các ô màu xanh lá cây đậm hơn tương ứng với mIoU cao trong mỗi cột và các ô màu đỏ tương ứng với mIoU thấp. Tất cả các mô hình có trọng số lớp bằng nhau (1a, 2a, 3a, 4a) đều có điểm tương đối cao đối với các tính năng lớn hơn (0,73-0,75) và điểm tương đối thấp đối với các lỗi (0,04-0,24). mIoU đối với các tính năng lớn hơn tương đối tốt với các giá trị IoU được báo cáo trong Tài liệu tham khảo [52] để phát hiện các vật thể như xe đạp (0,41), thuyền (0,68), ghế (0,43), bàn (0,65), ghế sofa (0,64) và TV (0,73). Tuy nhiên, các ví dụ trong Tài liệu tham khảo [52] cũng minh họa những thách thức xung quanh việc phát hiện các vật thể dài và hẹp như chân chim, chân bàn, chân ghế, đuôi mèo và lốp xe tạo thành một phần của vật thể lớn hơn. Những tính năng nhỏ hơn này thường bị giảm, giãn ra hoặc hoàn toàn mất tích trong các dự đoán được trình bày trong Tài liệu tham khảo. [52]. Điểm IoU trung bình trong Tài liệu tham khảo [52] dao động từ 62,2% đến 78% trên một loạt các đối tượng mặc dù thực tế là nhiều đặc điểm nhỏ hơn đã bị thiếu trong các dự đoán. mIoU cho các vết nứt và dự đoán lỗi được báo cáo trong Hình 7 thấp để hiểu vì các vết nứt và dự đoán lỗi chỉ bao gồm các đặc điểm dài và hẹp, rất khó để xác định chính xác ở độ phân giải cấp pixel. mIoU trung bình cao nhất đối với các khuyết tật (0,28) được tạo ra bởi DeepLabv3+ với trọng số lớp tùy chỉnh (4c) khiến nó trở thành lựa chọn tốt nhất để phát hiện các khuyết tật dài và hẹp trong tập dữ liệu này. Kết quả này có thể là do khả năng phát hiện được cải thiện dọc theo ranh giới đối tượng của mô hình DeepLabv3+ như đã nêu trong Tài liệu tham khảo [50].

Hình 8 cho thấy bản đồ nhiệt cho mức thu hồi trung bình (mRc1) và tương quan phản hồi trung bình cho cùng năm lớp và mô hình được thể hiện trong Hình 7. Các mô hình sử dụng trọng số lớp bằng nhau (1a, 2a, 3a, 4a) cho thấy mRc1 trung bình thấp nhất đối với các khuyết tật (0,05-0,3). Các mô hình sử dụng trọng số lớp nghịch đảo (1b, 2b, 3b, 4b) cho thấy mRc1 trung bình cao nhất đối với các khuyết tật (0,48-0,77). Các số liệu thống kê này phù hợp với các hình ảnh trong Hình 5 cho thấy các vết nứt giãn nở và các khuyết tật dự đoán lỗi trong các dự đoán từ các mô hình khi áp dụng trọng số lớp nghịch đảo so với các mô hình

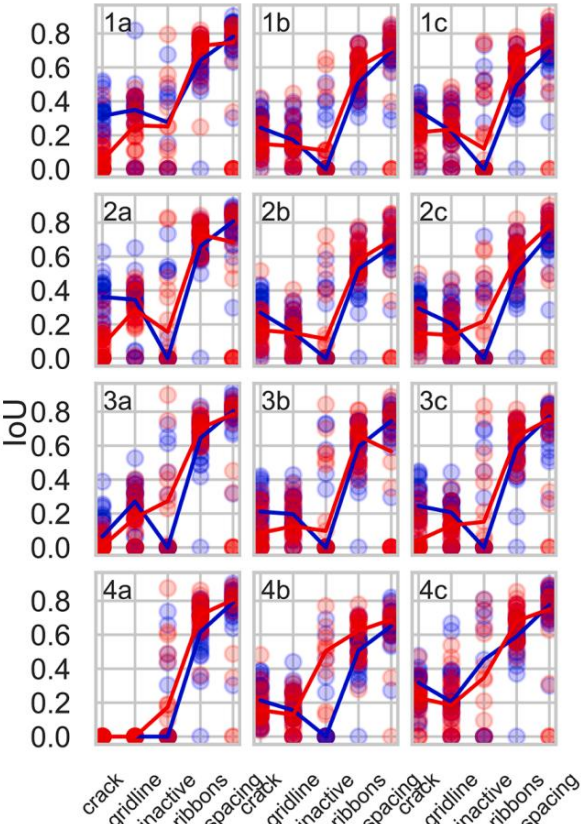


Hình 4. Tóm tắt đồ họa của phương pháp.



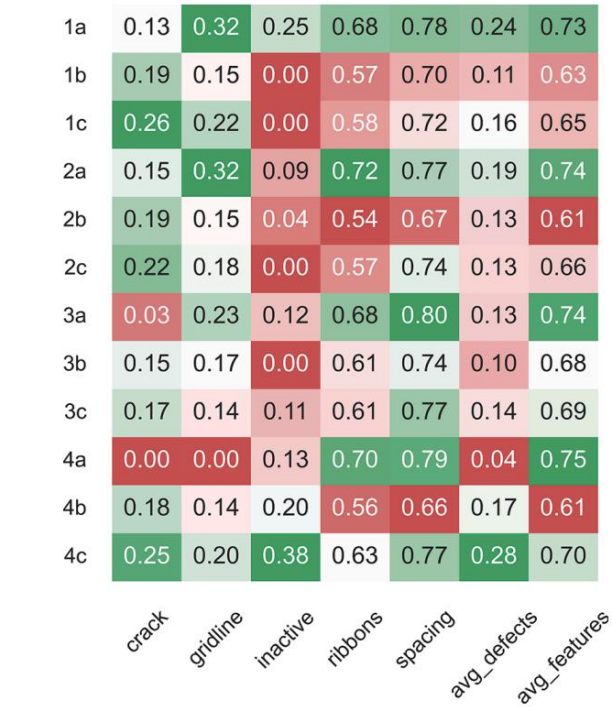
Hình 5. Mặt nạ dự đoán cho ô CFVS 00035_r8_c4: U-Net_12 (hàng 1), U-Net_25 (hàng 2), PSPNet (hàng 3), DeepLabv3+ (hàng 4), trọng số lớp bằng nhau (cột a), trọng số lớp nghịch đảo (cột b) và trọng số lớp tùy chỉnh (cột c).

với trọng số lớp bằng nhau. Các mô hình sử dụng trọng số lớp tùy chỉnh (1c, 2c, 3c, 4c) cũng cho thấy mRcl trung bình tương đối cao đối với các khuyết tật và khuyết tật gián nở trực quan trong Hình 5. DeepLabv3+ với trọng số lớp tùy chỉnh (4c) nằm trong số những mô hình có hiệu suất cao nhất về mRcl trung bình đối với cả các tính năng và khuyết tật. mRcl đối với vết nứt (0,86) và khuyết tật đường lư ới (0,85) từ



Hình 6. IoU cho tính thể đơn (vòng tròn màu xanh), tính thể đa (vòng tròn màu đỏ)) và mIoU (đường liền) cho các khuyết tật và đặc điểm được chọn trong 50 hình ảnh thử nghiệm trên 12 mô hình.

mô hình 4c như thể hiện trong Hình 8 cũng so sánh thuận lợi với việc thu hồi các vết nứt (0,82) và các khuyết tật lư ới/tiếp xúc (0,78) được báo cáo trong Tài liệu tham khảo [36]. Trong khi DeepLabv3+ (4c) cho thấy khả năng thu hồi cao trung bình trên ba lớp lỗi, mIoU vẫn tương đối thấp do độ chính xác thấp. Hình 9 cung cấp một số thông tin chi tiết để giải thích độ chính xác thấp. Mặt nạ thực tế phản ánh chính xác các vết nứt và lỗi lư ới trong



Hình 7. mIoU cho năm lớp trên 12 mô hình và giá trị trung bình của mIoU đối với các tính năng và khuyết điểm.



Hình 8. mRcl cho năm lớp trên 12 mô hình và giá trị trung bình của mRcl cho các tính năng và khuyết điểm.

hình ảnh EL tương ứng. Mật độ dự đoán xác định và cục bộ xác định các khuyết tật trong hình ảnh EL, nhưng các khuyết tật này bị giãn ra so với mật độ thực tế dẫn đến độ chính xác thấp.

Độ chính xác của hình ảnh thực tế cũng có thể ảnh hưởng đến IoU và khả năng thu hồi trong quá trình thử nghiệm. Một số sự không khớp giữa EL và mật độ thực tế là không thể tránh khỏi, mặc dù đã có những nỗ lực giảm thiểu vấn đề này trong quá trình dán nhãn. [Hình 10](#) cho thấy góc dư đi bên trái của

ARTS_00020_r7_c3 để minh họa khả năng xảy ra lỗi, đặc biệt là đối với các vật thể dài và hẹp. Lớp khoảng cách trong mật độ dự đoán (màu xám) bao phủ đặc điểm tương ứng trong ảnh EL hoàn toàn hơn so với mật độ thực tế hiển thị một số điểm ảnh tối dọc theo các cạnh của lớp khoảng cách không được che. Tương tự như vậy, lớp ruy băng trong mật độ dự đoán (màu xanh lá cây) có thể phản ánh đặc điểm tương ứng trong ảnh EL tốt hơn so với mật độ thực tế. Các lỗi trong việc dán nhãn dọc theo các cạnh của vết nứt và các khuyết tật dư thừa dư thừa có tác động đặc biệt lớn đến mIoU do tỷ lệ khung hình chu vi trên diện tích cao hơn của các khuyết tật đó. Mật độ dự đoán trong [Hình 10](#) cũng hiển thị một số khuyết tật dư thừa dư thừa bổ sung cần được thêm vào mật độ thực tế.

Các giá trị mIoU thấp cho các khuyết tật được thúc đẩy bởi độ chính xác thấp. Độ chính xác thấp được thúc đẩy nhiều hơn bởi các dự đoán giãn nở của các tính năng chính xác lỗi/khuyết tật thay vì phát hiện các đặc điểm/khuyết tật giả mạo. Làm thế nào bao giờ, mức độ giãn nở và phát hiện sai lệch được coi là chấp nhận được ở giai đoạn này. Tác động của giãn nở có thể được giảm nhẹ bằng cách điều chỉnh trọng số lớp, dẫn đến sự đánh đổi giữa độ thu hồi và độ chính xác. Như thấy trong [Hình 5](#), khi trọng số lớp bằng nhau, sự giãn nở của các đặc điểm và khuyết tật là tối thiểu.

Ngoài các khiếm khuyết và tính năng chính được phân tích ở trên, các mô hình cũng học cách phát hiện các tính năng và khiếm khuyết khác bất chấp mối quan hệ kích thước mẫu thực sự nhỏ. [Hình 11](#) cho thấy hình ảnh EL, giá trị thực tế và mật độ dự đoán cho một hình ảnh có nguồn từ [\[19\]](#), một trong những tập dữ liệu công khai được sử dụng để đào tạo. Các tác giả ban đầu đã đào tạo các mô hình để phân loại hình ảnh là 'tốt', 'nứt' hoặc 'bị ăn mòn'. Trong công trình này, mô hình đã phát hiện và định vị được lỗi ăn mòn trong hình ảnh mặc dù chỉ có 17 hình ảnh có lỗi ăn mòn trong tập dữ liệu đào tạo.

Lỗi ăn mòn (màu xanh lá cây đậm) được phát hiện xung quanh đặc điểm ruy băng (màu xanh lá cây tươi sáng). Đặc điểm đệm ô liu lớn được thêm vào xung quanh ô trong quá trình xử lý trước đã được phát hiện rõ ràng, cũng như đặc điểm viền nhỏ hơn (màu nâu) bao quanh ô. Một số lỗi dư thừa dư thừa đã được phát hiện nhưng vết nứt thì không. Mô hình cũng học cách bỏ qua đúng ranh giới hạt phổ biến trong các ô silicon đa tinh thể.

5. Kết luận

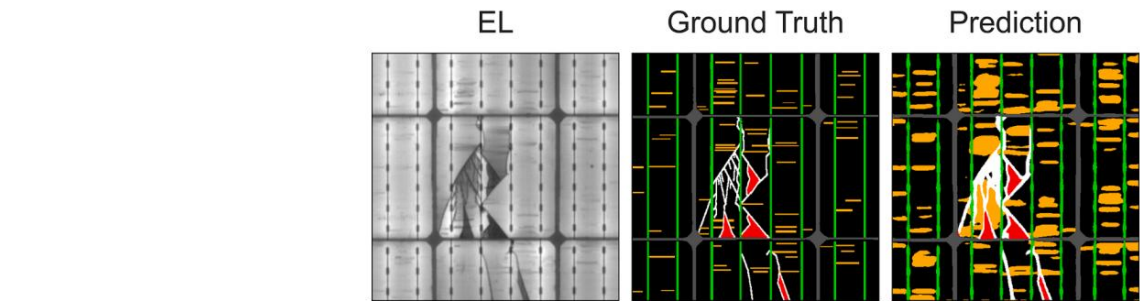
Bốn mô hình học sâu (U-Net_12, U-Net_25, PSPNet và DeepLabv3+) đã được đào tạo bằng cách sử dụng các trọng số lớp bằng nhau, các trọng số lớp nghịch đảo và các trọng số lớp tùy chỉnh cho tổng cộng mười hai bộ dự đoán cho mỗi 50 hình ảnh thử nghiệm. Các mô hình đã được đào tạo để đồng thời phát hiện 24 lớp trong hình ảnh EL của các tế bào quang điện mặt trời bằng cách sử dụng phân đoạn ngữ nghĩa mentation. Mười hai lớp tương ứng với các đặc điểm nội tại của một tế bào quang điện, và mười hai lớp tương ứng với các khuyết tật bên ngoài. Bài báo này tập trung vào việc phát hiện ba khuyết tật quan trọng và hai đặc điểm chung trong tế bào quang điện silicon tinh thể. DeepLabv3+ với trọng số lớp tùy chỉnh được phát hiện có mIoU trung bình cao nhất trên ba khuyết tật quan trọng được xác định trong tập dữ liệu này. mIoU cho các đặc điểm là

cao hơn đáng kể so với mIoU đối với các khiếm khuyết của tất cả các mô hình được thử nghiệm. Đáng chú ý là các mô hình đạt được mIoU và mRcl thấp hơn trên các vùng nhỏ, nơi các khuyết tật hàng như vết nứt và dư thừa dư thừa so với các đặc điểm lớn như khoảng cách và dải ruy băng. Điều này có thể được thúc đẩy nhiều hơn bởi các đặc điểm giãn nở trong mật độ dự đoán và ít hơn do phân loại sai lệch không đáng có. Các mô hình được thử nghiệm có hiệu quả trong việc phát hiện, định vị và định lượng nhiều đặc điểm và khuyết tật trong hình ảnh EL của pin mặt trời. Do đó, các mô hình này có thể được sử dụng để không chỉ phát hiện sự hiện diện của khuyết tật mà còn theo dõi sự tiến triển của chúng theo thời gian khi các mô-đun được chụp lại hình ảnh trong suốt vòng đời của chúng.

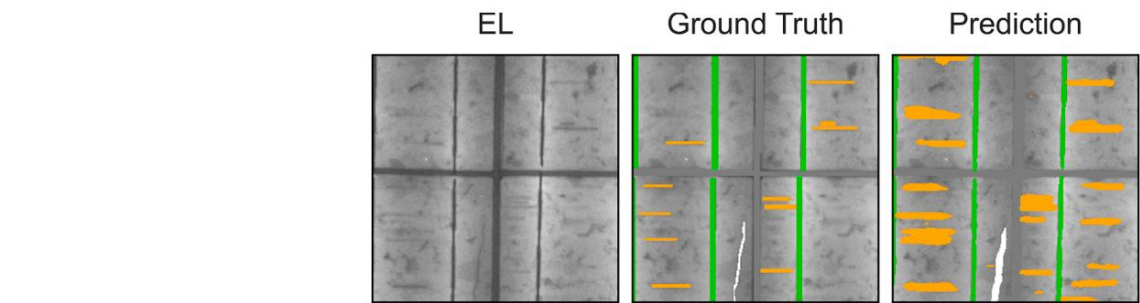
Những đóng góp độc đáo từ công trình này bao gồm tập dữ liệu chuẩn được công bố trên github và số liệu hiệu suất chuẩn cho phân đoạn ngữ nghĩa trên hình ảnh EL của tế bào quang điện mặt trời.

Công việc tương lai


Công việc trong tương lai sẽ tập trung vào học bản giám sát để kết hợp thông tin từ hơn 80.000 hình ảnh EL không có nhãn có sẵn. Các kỹ thuật dịch hình ảnh sang hình ảnh sẽ được nghiên cứu để cải thiện



Hình 9. EL, mặt nạ thực tế và mặt nạ dự đoán từ Deeplabv3+ với trọng số lớp tùy chỉnh (4c) cho CFVS 00035_r8_c4.



Hình 10. Góc dư đi bên trái của ARTS_00020_r7_c3 hiển thị lỗi ghi nhận dọc theo các cạnh của dải ruy băng và khoảng cách giữa các ô trong ảnh thực tế dẫn đến lỗi về độ chính xác và khả năng thu hồi.



Hình 11. EL, giá trị thực tế và mặt nạ dự đoán từ Deeplabv3+ với trọng số lớp tùy chỉnh (4c) cho SDLE_00513 cho thấy sự ăn mòn của các kết nối ruy băng.

độ chính xác của hình ảnh thực tế. Cuối cùng, tập dữ liệu thực tế sẽ được cập nhật và tăng lên để kết hợp các tính năng và khuyết tật mới như ô cắt một nửa, vết xước và ăn mòn cạnh.

Tuyên bố về lợi ích cạnh tranh

Các tác giả tuyên bố rằng họ không có bất kỳ mối quan hệ cá nhân hoặc lợi ích tài chính cạnh tranh nào có thể ảnh hưởng đến công trình được trình bày trong bài báo này.

Tính khả dụng của dữ liệu

Dữ liệu sẽ được công khai trên kho lưu trữ github được tham chiếu trong giấy.

Lời cảm ơn

Các tác giả muốn cảm ơn Tiến sĩ Kittessa Roro và CSIR về công nghệ hỗ trợ kỹ thuật, thiết bị đo lường, mẫu thử nghiệm và hỗ trợ tài chính cho chương trình tiến sĩ dẫn đến sản phẩm này. Các tác giả muốn cảm ơn CFV Labs và ARTsolar đã cung cấp hình ảnh EL và nhóm người dân nhận đã chú thích chúng: Nandi Bau, Sibusiso Mgidi,

Rifumo Mzimba, Siyathandana Nontolwana, Kian Reddy và Kyle Wootton từ Đại học Witwatersrand; và Keketso Moletsane. Công trình này dựa trên nghiên cứu được hỗ trợ một phần bởi Quỹ nghiên cứu quốc gia Nam Phi (Số tài trợ: 118075). Các tác giả cũng cảm ơn Trung tâm Máy tính hiệu suất cao (CHPC), Nam Phi đã cung cấp các nguồn lực tính toán cho dự án nghiên cứu này.

Tài liệu tham khảo

[1] T. Fuyuki, H. Kondo, T. Yamazaki, et al., Khảo sát ảnh của dân tộc thiểu số chiều dài khuếch tán của chất mang trong pin mặt trời silicon đa tinh thể bằng phương pháp phát quang điện, Appl. Phys. Lett. 86 (2005), <https://doi.org/10.1063/1.1978979>.

[2] M. Reuter, L. Stoicescu, JH Werner, Phát quang điện tử của mô-đun PV: các khuyết tật làm sáng tỏ. Sách trắng của Solarzentrum Stuttgart GmbH. https://www.solarzentrum-stuttgart.com/uploads/file/platzhalter_vortrag_spezial_hagelschaden_DaySy_April2015_04.pdf.

[3] S. Koch, T. Weber, C. Sobottka, et al., Chụp ảnh phát quang điện ngoài trời của mô-đun quang điện tinh thể: nghiên cứu so sánh giữa kiểm tra thủ công trên mặt đất và khảo sát trên không bằng máy bay không người lái, trong: Biên bản Hội nghị và Triển lãm Năng lượng Mặt trời Quang điện Châu Âu lần thứ 32, 2016.

[4] WB Hobbs, B. Hamzavy, CB Jones, et al., Chụp ảnh phát quang điện trong tư ởng: phương pháp, so sánh với chụp ảnh trong nhà và những thay đổi quan sát được trong các mô-đun trong hơn một năm, trong: Biên bản Hội nghị thế giới lần thứ 7 của IEEE năm 2018 về chuyển đổi năng lượng quang điện (WCPEC) (Hội nghị chung của IEEE PVSC lần thứ 45, PVSEC lần thứ 28 và EU PVSEC lần thứ 34), Waikoloa Village, HI, IEEE, 2018, tr. 3257-3260.

[5] KGBedrich, YS Khoo, Y. Wang, Phương pháp, hệ thống và thiết bị xử lý hình ảnh để chụp và/hoặc xử lý hình ảnh phát quang điện, và phương tiện bay, Số bằng sáng chế W02021137764, 2021.

[6] KG Bedrich, M. Bliss, TR Betts, R. Gottschalg, Chụp ảnh phát quang điện của các thiết bị PV: hiệu chuẩn camera và hiệu chỉnh hình ảnh, trong: *Biên bản Hội nghị chuyên gia quang điện IEEE lần thứ 43 năm 2016 (PVSC)*, Portland, OR, Hoa Kỳ, IEEE, 2016, tr. 1532-1537.

[7] C. Mantel, S. Spataru, H. Parikh, et al., Hiệu chỉnh độ méo phối cảnh trong hình ảnh phát quang điện của tấm pin quang điện, trong: *Biên bản Hội nghị thế giới lần thứ 7 về chuyển đổi năng lượng quang điện (WCPEC)* của IEEE năm 2018 (Hội nghị chung của IEEE PVSC lần thứ 45, PVSEC lần thứ 28 và EU PVSEC lần thứ 34), 2018, tr. 0433-0437.

[8] M. Owen-Bellini, DB Sulas-Kern, G. Perrin, et al., Phương pháp chụp ảnh phát quang điện tại chỗ của các mô-đun quang điện trong điều kiện môi trường khác nhau, *IEEE J. Photovolt.* 10 (2020) 1254-1261, <https://doi.org/10.1109/JPHOTOV.2020.3001723>.

[9] M. Kontges, I. Kunze, S. Kajari-Schroder, " et al., Định lượng rủi ro mất điện trong các mô-đun PV do các vết nứt nhỏ, trong: *Biên bản Hội nghị Năng lượng Mặt trời Quang điện Châu Âu lần thứ 25, 2010*, tr. 9.

[10] M. Abdelhamid, R. Singh, M. Omar, Đánh giá các kỹ thuật phát hiện vết nứt nhỏ cho pin mặt trời silicon, *IEEE J. Photovolt.* 4 (2014) 514-524, <https://doi.org/10.1109/JPHOTOV.2013.2285622>.

[11] H. Gopalakrishna, R. Yadav, E. Chan, JN Munday, P. Berzel, MD Kempe, et al., Đánh giá độ bền của các mô-đun PV bằng cách sử dụng các công cụ xử lý hình ảnh. Các khái niệm mới trong chuyển đổi và độ tin cậy của bức xạ mặt trời và nhiệt, *SPIE*, San Diego, Hoa Kỳ, 2018, tr. 36.

[12] KG Bedrich, M. Luo, M. Pravettoni, et al., Phát quang điện định lượng phân tích hình ảnh để ước tính hiệu suất của các mô-đun PV chịu ảnh hưởng của PID, *IEEE J. Photovolt.* 8 (2018) 1281-1288, <https://doi.org/10.1109/JPHOTOV.2018.2846665>.

[13] M. Bdour, Z. Dalala, M. Al-Addous, et al., Đánh giá toàn diện về các loại vết nứt nhỏ và những tác động có thể xảy ra đối với sự suy giảm công suất trong các tấm pin mặt trời quang điện, *Sustainability* 12 (2020) 6416, <https://doi.org/10.3390/su12166416>.

[14] E. Sovetkin, EJ Achterberg, T. Weber, BE Pieters, Mô hình phân đoạn ngữ nghĩa bộ mã hóa-giải mã cho hình ảnh phát quang điện của mô-đun quang điện màng mỏng, *IEEE J. Photovolt.* 11 (2021) 444-452, <https://doi.org/10.1109/JPHOTOV.2020.3041240>.

[15] M. Dimish, Y. Hu, Thử nghiệm nhanh về tác động của vết nứt đến hiệu suất công suất đầu ra và hoạt động nhiệt của tế bào quang điện, *Báo cáo khoa học 12 (1) (2022) 1-11*.

[16] AM Karimi, JS Fada, NA Parrilla, và cộng sự, PV tổng quát và cơ học dự đoán hiệu suất mô-đun từ thị giác máy tính và máy học trên hình ảnh phát quang điện, *IEEE J Photovolt.* 10 (2020) 878-887, <https://doi.org/10.1109/JPHOTOV.2020.2973448>.

[17] U. Jahn, M. Herz, M. Kontges, et al (2018), IEA PVPS T13-10 2018 Đánh giá về hình ảnh hồng ngoại và phát quang điện cho các ứng dụng từ ứng PV: Chương trình Hệ thống Điện quang của Cơ quan Năng lượng Quốc tế: Nhiệm vụ 13 PVPS của IEA, Nhiệm vụ phụ 3.3: báo cáo IEA-PVPS T13-12:2018. Cơ quan Năng lượng Quốc tế, Paris, http://iea-pvps.org/wp-content/uploads/2020/01/Review_on_IR_and_EL_Imaging_of_PV_Field_Applications_by_Task_13.pdf.

[18] S. Deitsch, C. Buezhop-Lutz, E. Sovetkin, A. Steland, A. Maier, F. Gallwitz, & C. Phân đoạn Riess của các ô mô-đun quang điện trong hình ảnh phát quang điện. *arXiv* 2018. Bản in từ *arXiv* [arXiv: 1806.06530](https://arxiv.org/abs/1806.06530).

[19] AM Karimi, JS Fada, MA Hossain, et al., Dự đoán tỷ lệ tổn thất cho quang điện mô-đun xử lý hình ảnh phát quang điện và phân loại tính năng suy giảm, *IEEE J Photovolt.* 9 (5) (2019) 1324-1335.

[20] C. Mantel, F. Villebro, G. Alves dos Reis Benatto, et al., Học máy dự đoán các loại khuyết tật cho hình ảnh phát quang điện của tấm pin quang điện. Ứng dụng của Máy học, SPIE, San Diego, Hoa Kỳ, 2019.

[21] E. Sovetkin, A. Steland, Xử lý tự động và phát hiện pin mặt trời trong hình ảnh phát quang điện quang điện, *Kỹ thuật tích hợp hỗ trợ máy tính* 26 (2) (2019) 123-137.

[22] S. Deitsch, V. Christlein, S. Berger, C. Buezhop-Lutz, A. Maier, F. Gallwitz, C. Riess, Phân loại tự động các ô mô-đun quang điện bị lỗi trong hình ảnh phát quang điện, *Năng lượng mặt trời* 185 (2019) 455-468.

[23] MW Akram, G. Li, Y. Jin, et al., Phát hiện tự động các khuyết tật của tế bào quang điện dựa trên CNN trong hình ảnh phát quang điện, *Energy* 189 (2019), 116319, <https://doi.org/10.1016/j.energy.2019.116319>.

[24] W. Tang, Q. Yang, K. Xiong, W. Yan, Lỗi tự động dựa trên học sâu xác định mô-đun quang điện bằng hình ảnh phát quang điện, *Năng lượng mặt trời* 201 (2020) 453-460, <https://doi.org/10.1016/j.solener.2020.03.049>.

[25] C. Ge, Z. Liu, L. Fang, et al., Cơ chế dựa trên mạng nơ-ron tích chập mờ lai để phát hiện khuyết tật của tế bào quang điện bằng hình ảnh phát quang điện, *IEEE Trans. Parallel Distrib. Syst.* (2020), <https://doi.org/10.1109/TPDS.2020.3046018>, 1-1.

[26] MY Demirci, N. Besli, A. Gümüscü, Trích xuất và phân loại tính năng sâu hiệu quả để xác định các ô mô-đun quang điện bị lỗi trong hình ảnh phát quang điện, *Hệ thống chuyên gia có ứng dụng* 175 (2021), 114810, <https://doi.org/10.1016/j.eswa.2021.114810>.

[27] W. Tang, Q. Yang, W. Yan, Thuật toán dựa trên học sâu để phát hiện nhiều loại khuyết tật trong pin mặt trời bằng hình ảnh EL trên không cho các nhà máy quang điện, *Comput.*

Mô hình. Kỹ thuật. Khoa học. 130 (2022) 1423-1439, <https://doi.org/10.32604/cmes.2022.018313>.

[28] C. Huang, Z. Zhang, L. Wang, PSOPruner: Phương pháp cắt tỉa mạng nơ-ron tích chập sâu dựa trên PSO để phân loại lỗi mô-đun PV, *IEEE J. Photovolt.* (2022) 1-9, <https://doi.org/10.1109/JPHOTOV.2022.3195099>.

[29] Y. Zhao, K. Zhan, Z. Wang, W. Shen, Phát hiện tự động các lỗi đa loại trong các mô-đun quang điện dựa trên học sâu và ứng dụng trong dây chuyền sản xuất thực tế, *Prog. Photovolt. Res. Appl.* 29 (2021) 471-484, <https://doi.org/10.1002/pip.3395>.

[30] X. Zhang, Y. Hao, H. Shangquan, et al., Phát hiện các khuyết tật bề mặt trên pin mặt trời bằng cách hợp nhất các mạng nơ-ron tích chập đa kênh, *Infrared Phys. Technol.* 108 (2020), 103334, <https://doi.org/10.1016/j.infrared.2020.103334>.

[31] B. Su, H. Chen, P. Chen, et al., Phát hiện lỗi sản xuất pin mặt trời dựa trên học sâu với mạng chú ý bổ sung, *IEEE Trans Ind Inf* 17 (2021) 4084-4095, <https://doi.org/10.1109/TII.2020.3008021>.

[32] DM Tsai, SC Wu, WC Li, Phát hiện lỗi của pin mặt trời trong hình ảnh phát quang điện bằng cách sử dụng tái tạo hình ảnh Fourier, *Solar Energy Mater. Pin mặt trời* 99 (2012) 250-262, <https://doi.org/10.1016/j.solmat.2011.12.007>.

[33] S. Spataru, P. Hacke, D. Sera, Tự động phát hiện và đánh giá pin mặt trời các vết nứt nhỏ trong hình ảnh phát quang điện sử dụng các bộ lọc phù hợp, trong: *Biên bản Hội nghị chuyên gia quang điện lần thứ 43 của IEEE năm 2016 (PVSC)*, 2016, trang 1602-1607.

[34] H. Chen, H. Zhao, D. Han, K. Liu, Phát hiện vết nứt chính xác và mạnh mẽ bằng cách sử dụng lọc bằng chúng có thể điều khiển được trong hình ảnh phát quang điện của pin mặt trời, *Opt. Kỹ thuật Laser* 118 (2019) 22-33, <https://doi.org/10.1016/j.optlaseng.2019.01.016>.

[35] MRU Rahman, H. Chen, Kiểm tra khuyết tật trong hình ảnh phát quang điện của tế bào quang điện đa tinh thể bằng cách sử dụng học sâu, *IEEE Access* 8 (2020) 40547-40558, <https://doi.org/10.1109/ACCESS.2020.2976843>.

[36] J. Fiorelli, DJ Colvin, R. Frota, et al., Phát hiện và định vị khuyết tật tự động trong các tế bào quang điện bằng cách phân đoạn ngữ nghĩa của hình ảnh phát quang điện, *IEEE J. Photovolt.* 12 (1) (2021) 53-61.

[37] L. Pratt, D. Govender, R. Klein, Phát hiện và định lượng khuyết tật trong hình ảnh phát quang điện của các mô-đun PV mặt trời bằng cách sử dụng phân đoạn ngữ nghĩa U-net, *Renew. Energy* 178 (2021) 1211-1222, <https://doi.org/10.1016/j.renene.2021.06.086>.

[38] S. Hao, Y. Zhou, Y. Guo, Một khảo sát ngắn gọn về phân đoạn ngữ nghĩa với học sâu, *Neurocomputing* 406 (2020) 302-321, <https://doi.org/10.1016/j.neucom.2019.11.118>.

[39] I. Ulku, E. Akagündüz, Khảo sát về Kiến trúc dựa trên học sâu để phân đoạn ngữ nghĩa trên hình ảnh 2D, *Appl. Artif. Intell.* (2022) 1-45, <https://doi.org/10.1080/08839514.2022.2032924>.

[40] RH French, AM Karimi, JL Braid, 4). Bộ dữ liệu hình ảnh phát quang điện (EL) của mô-đun PV dự đoán tác động của nhiệt ẩm từng bước. <https://doi.org/10.17605/OSF.T014QRVT>.

[41] C. Buezhop, S. Deitsch, A. Maier, et al., Điểm chuẩn để nhận dạng trực quan các tế bào quang điện bị lỗi trong hình ảnh phát quang điện, trong: *Biên bản Hội nghị và Triển lãm Năng lượng Mặt trời PV Châu Âu lần thứ 35, 2018*.

[42] S. Kimball, P. Mattis và Nhóm phát triển GIMP, *GIMP 2.10.32*, 1995-2022, kiểm tra lần cuối vào ngày 25/1/2023, <https://www.gimp.org>.

[43] D. Gupta (2021) Phân đoạn hình ảnh Keras: Triển khai Segnet, FCN, UNet, PSPNet và các mô hình khác trong Keras [Mã nguồn], Truy cập ngày 23 tháng 1 năm 2022, <https://github.com/divangupta/image-segmentation-keras>.

[44] N. Tomar (2022) Semantic-Segmentation-Architecture [Mã nguồn], Truy cập ngày 23 tháng 1 năm 2022, <https://github.com/nikhilroxtomar/Semantic-Segmentation-Architecture>.

[45] Y. Kamikawa (2020) keras-PSPNet [Mã nguồn], Truy cập ngày 23 tháng 1 năm 2022, <https://github.com/ykamikawa/tf-keras-PSPNet>.

[46] S. Kawakita (2021) example_camvid_multiclassB_quitai.ipynb [Mã nguồn], Truy cập ngày 23 tháng 1 năm 2022, https://github.com/shirokawakita/multiclass-segmentation/blob/main/example_camvid_multiclassB_quitai.ipynb.

[47] P. Yakubovskiy (2020) Mô hình phân đoạn trong Pytorch [Mã nguồn], Đã truy cập Ngày 10 tháng 4 năm 2022, https://github.com/quvel/segmentation_models.pytorch.

[48] O. Ronneberger, P. Fischer, T. Brox, U-Net: mạng tích chập để phân đoạn hình ảnh y sinh, trong: *Biên bản Hội nghị quốc tế về tính toán hình ảnh y tế và can thiệp hỗ trợ máy tính*, Cham, Springer, 2015.

[49] H. Zhao, J. Shi, X. Qi, et al., Mạng phân tích cảnh kim tự tháp, trong: *Biên bản Hội nghị IEEE về Tâm nhìn máy tính và Nhận dạng mẫu*, IEEE, 2017, trang 2881-2890.

[50] LC Chen, Y. Zhu, G. Papandreou, et al., Bộ mã hóa-giải mã với tích chập tách rời atrous để phân đoạn hình ảnh ngữ nghĩa, trong: *Biên bản báo cáo Hội nghị châu Âu về thị giác máy tính (ECCV)*, 2018.

[51] S. Jodon, Khảo sát các hàm mất mát cho phân đoạn ngữ nghĩa, trong: *Biên bản Hội nghị IEEE năm 2020 về Trí thông minh tính toán trong Tin sinh học và Sinh học tính toán (CIBCB)*, 2020, trang 1-7.

[52] G. Lin, C. Shen, A. van den Hengel, I. Reid, Đào tạo từng phần hiệu quả các mô hình có cấu trúc sâu để phân đoạn ngữ nghĩa, trong: *Biên bản Hội nghị IEEE về Thị giác máy tính và Nhận dạng mẫu*, Las Vegas, NV, IEEE, 2016, tr. 3194-3203.