




Danh sách nội dung có sẵn tại [ScienceDirect](#)

Chuyển đổi và quản lý năng lượng

trang chủ tạp chí: [www.elsevier.com/locate/enconman](http://www.elsevier.com/locate/enconman)



Phát hiện và chẩn đoán lỗi dựa trên mạng lưới dư thừa sâu của các mảng quang điện bằng cách sử dụng đường cong dòng điện-điện áp và điều kiện môi trường xung quanh

Zhicong Chena,b, Yixiang Chena,b, Lijun Wu,a,\*, Shuying Chenga,b, Peijie Lina,b

<sup>a</sup> Khoa Vật lý và Kỹ thuật thông tin, Đại học Phúc Châu, 2 Đường XueYuan, 350116 Phúc Châu, Trung Quốc  
<sup>b</sup> Trung tâm đổi mới hợp tác khoa học và kỹ thuật quang điện Giang Tô, 213164 Thư ông Châu, Trung Quốc

THÔNG TIN BÀI VIẾT

Từ khóa:  
Mảng quang điện  
Phát hiện và chẩn đoán lỗi  
Đường cong đặc tính dòng điện-điện áp  
Mạng lưới dư thừa sâu  
Học sâu

TÓM TẮT

Các kỹ thuật phát hiện và chẩn đoán lỗi tự động cho mảng quang điện đóng vai trò quan trọng trong việc thúc đẩy hiệu quả, độ tin cậy và tính an toàn của hệ thống quang điện. Trong những thập kỷ gần đây, nhiều phương pháp tiếp cận trí tuệ nhân tạo thông thường đã được áp dụng thành công để tự động thiết lập mô hình phát hiện và chẩn đoán lỗi bằng cách sử dụng các mẫu dữ liệu lỗi, nhưng hầu hết trong số chúng đều dựa vào việc trích xuất tính năng thủ công hoặc kiến thức chuyên môn để xây dựng các mô hình chẩn đoán, điều này không hiệu quả và có thể bỏ qua một số tính năng hữu ích tiềm ẩn. Ngoài ra, chúng thường sử dụng mạng nơ-ron nông với hiệu suất hạn chế. Để giải quyết các vấn đề này, bài báo này đề xuất một phương pháp phát hiện và chẩn đoán lỗi thông minh mới cho mảng quang điện dựa trên mô hình mạng dư thừa mới được thiết kế, được đào tạo bằng thuật toán học sâu ước tính mô men thích ứng, có thể tự động trích xuất các tính năng từ các đường cong dòng điện-điện áp thô và độ rọi và nhiệt độ xung quanh, đồng thời cải thiện hiệu suất hiệu quả với mạng sâu hơn. Để xác thực mô hình chẩn đoán lỗi được đề xuất, một mô hình mô phỏng dựa trên Simulink được thiết kế cho một mảng quang điện trong phòng thí nghiệm thực tế và cả mô phỏng lỗi và thí nghiệm thực tế đều được thực hiện để có được các tập dữ liệu lỗi mô phỏng và thử nghiệm. Hơn nữa, hai mô hình học sâu phổ biến khác được sử dụng để so sánh, bao gồm mạng nơ-ron tích chập và bộ mã hóa tự động tích chập. Cả kết quả so sánh mô phỏng và thử nghiệm thực tế đều chứng minh rằng phương pháp dựa trên mạng dư thừa được đề xuất đạt hiệu suất tổng thể cao và tốt nhất về độ chính xác, hiệu suất khái quát hóa, độ tin cậy và hiệu quả đào tạo.

1. Giới thiệu

Với tình trạng thiếu hụt năng lượng hóa thạch và ô nhiễm môi trường ngày càng trầm trọng, nhu cầu cấp thiết về các nguồn năng lượng sạch và bền vững để đáp ứng nhu cầu tiêu thụ năng lượng và bảo vệ môi trường ngày càng tăng. Trong số các nguồn năng lượng tái tạo khác nhau, năng lượng mặt trời ngày càng được chú ý nhiều hơn vì tính bền vững, sạch sẽ và khả dụng rộng rãi, và sản xuất điện quang điện (PV) là cách chính để khai thác năng lượng mặt trời.

Theo báo cáo mới nhất của Cơ quan Năng lượng Quốc tế (IEA), công suất lắp đặt tích lũy toàn cầu của các hệ thống điện quang điện đã tăng trưởng theo cấp số nhân trong những thập kỷ qua và đạt ít nhất 505 Giga Watt vào cuối năm 2018, trong đó 99,8 Giga Watt của các hệ thống điện quang điện đã được lắp đặt trên toàn thế giới vào năm 2018 [1]. Là các thành phần cơ bản của quá trình chuyển đổi năng lượng quang điện, các mảng quang điện bao gồm một số lượng lớn các mô-đun quang điện và hệ thống phức tạp, và chúng thường hoạt động trong môi trường ngoài trời khắc nghiệt. Do nhiều yếu tố tiềm ẩn (như ăn mòn, gió mạnh, mưa lớn, mưa đá,

(bắn, tiếp xúc với tia cực tím, chu kỳ nhiệt, gặm nhấm, có thể vận chuyển/lắp đặt/bảo trì không phù hợp, v.v.), chúng dễ bị ảnh hưởng bởi nhiều loại và mức độ lỗi hoặc bất thường [2], chẳng hạn như lỗi ngắn mạch (đường dây-đường dây và đường dây xuống đất) [3], che bóng một phần [4], suy thoái do lão hóa [5], lỗi mạch hở [6], lỗi hồ quang DC [7], điểm nóng [8], suy thoái do điện thế gây ra (PID) [9], vết nứt nhỏ [10], v.v. Để bảo vệ hệ thống PV khỏi các sự kiện thảm khốc, một số thiết bị bảo vệ thông thường thường được lắp đặt trên các mảng PV phía DC [11], chẳng hạn như thiết bị bảo vệ quá dòng (OCPD), phát hiện và ngắt lỗi tiếp đất (GFDI), ngắt mạch lỗi hồ quang (AFCI), v.v. Tuy nhiên, các lỗi nhỏ ban đầu với độ không khớp thấp hoặc trở kháng cao vẫn không được bảo vệ và rất khó và tốn thời gian để phát hiện thủ công, điều này có thể làm giảm hiệu suất phát điện và suy thoái hệ thống, thậm chí làm trầm trọng thêm các thảm họa hỏa hoạn [12]. Do đó, các công nghệ phát hiện và chẩn đoán lỗi tự động (FDD) là rất cần thiết để phát hiện các lỗi sớm này nhằm vận hành và bảo trì các nhà máy điện PV hiệu quả, đáng tin cậy và an toàn, đang thu hút ngày càng nhiều sự quan tâm nghiên cứu từ

\* Tác giả liên hệ tại: Khoa Vật lý và Kỹ thuật thông tin, Đại học Phúc Châu, Số 2 Đường XueYuan, 350116 Phúc Châu, Trung Quốc.  
Địa chỉ email: [lijun.wu@fzu.edu.cn](mailto:lijun.wu@fzu.edu.cn) (L. Vũ).

<https://doi.org/10.1016/j.enconman.2019.111793>

Nhận ngày 21 tháng 5 năm 2019; Nhận dự định đăng đã sửa đổi ngày 2 tháng 7 năm 2019; Chấp nhận ngày 6 tháng 7 năm 2019  
0196-8904/ © 2019 Elsevier Ltd. Bảo lưu mọi quyền.

cộng đồng học thuật và công nghiệp trong những năm gần đây [13].

Trong thập kỷ qua, nhiều kỹ thuật FDD khác nhau đã được đưa ra đối với mảng PV. Về nguyên lý cảm biến, các phương pháp chẩn đoán lỗi được báo cáo bao gồm hình ảnh nhiệt [14], phát quang điện (EL) hình ảnh [15], đo điện dung đất (ECM) [16], thời gian phản xạ miến (TDR) [17] và giám sát đặc điểm điện [18]. Các phương pháp hình ảnh nhiệt dựa vào camera hồng ngoại (IR) để thu thập hình ảnh nhiệt được bức xạ bởi các mô-đun PV trong hoạt động thực tế điều kiện. Mặc dù chúng có thể phát hiện hiệu quả các lỗi điểm nóng của năng lượng mặt trời cấp độ tế bào, nhưng độ tin cậy bị ảnh hưởng mạnh mẽ bởi ánh sáng mặt trời. Thay vào đó, Các phương pháp EL chủ động áp dụng điện áp phân cực thuận trên các mô-đun PV và sau đó sử dụng máy ảnh để thu được ánh sáng phát ra từ các tế bào năng lượng mặt trời. Vết nứt nhỏ hoặc các khiếm khuyết của các tế bào năng lượng mặt trời bên trong của các mô-đun PV có thể dễ dàng được quan sát từ hình ảnh EL, nhưng cần có nguồn điện bên ngoài và PV các mô-đun nên được chuyển vào một căn phòng tối. Phương pháp ECM là được đề xuất bởi Takashima et al. [19] và được sử dụng để phát hiện và định vị ngắt kết nối trong chuỗi PV bằng cách đo điện dung đất và sau đó so sánh các giá trị của chuỗi bình thường và chuỗi có khả năng bị lỗi chuỗi. Các phương pháp TDR được sử dụng để phát hiện và xác định vị trí thay đổi trở kháng do lão hóa hoặc lỗi tiếp đất, thông qua việc đo tín hiệu đặc biệt vào Chuỗi PV và đo tín hiệu phản xạ để so sánh giữa chuỗi bình thường và chuỗi lỗi [17]. Cả ECM và TDR phương pháp có thể nhận ra vị trí lỗi và không nhạy cảm với bức xạ, nhưng ECM được dành riêng để phát hiện mạch hở trong khi TDR chỉ để phát hiện sự thay đổi trở kháng. Theo tài liệu, các phương pháp đặc tính điện là phương pháp chiếm ưu thế, có thể phát hiện, phân loại và định vị các loại lỗi khác nhau trực tiếp bằng cách sử dụng điện các thông số (điện áp, dòng điện, công suất và đường cong IV) cùng với điều kiện môi trường xung quanh (bức xạ và nhiệt độ) [20]. Nghiên cứu này tập trung vào các phương pháp dựa trên đặc điểm điện. Theo quan điểm của nguyên tắc chẩn đoán lỗi, đặc điểm điện dựa trên phương pháp có thể được phân loại thêm thành mô hình vật lý và/hoặc tín hiệu phương pháp ngưng dựa trên xử lý và phương pháp trí tuệ nhân tạo (AI) dựa trên dữ liệu và/hoặc quy tắc [21]. Các phương pháp FDD dựa trên ngưng ngưng dựa vào việc trích xuất thủ công và phân tích các chỉ số lỗi để xác định quy trình và ngưng để đánh giá trạng thái lỗi. Đầu tiên, một số chỉ số nhạy cảm với lỗi được trích xuất từ dữ liệu điện đo được và lý thuyết của chúng các giá trị kỹ thuật được tính toán bằng mô hình vật lý và các điều kiện môi trường được đo lường, chẳng hạn như mất điện với tỷ lệ điện áp/dòng điện [22], được chuẩn hóa điện áp và dòng điện [23], dạng sóng điện áp hoạt động [24], hoạt động cửa số điện áp [25], độ dốc của đường cong công suất chuẩn hóa [26], công suất/chỉ số điện áp/dòng điện [27], sự khác biệt chuẩn hóa của nguồn điện DC/điện áp [28], bảy chỉ số (dòng điện và điện áp ở công suất tối đa điểm, dòng điện ngắn mạch, điện áp mạch hở, điện trở nối tiếp, hệ số điện dẫn đủ và điện áp nhiệt) [29], các tham số mô hình được trích xuất từ đường cong I đến V [30], đạo hàm của lỗi đường cong IV đến điện áp [31], và vân vân. Dựa trên phân tích các chỉ số được trích xuất, phát hiện lỗi các thủ tục sau đó được đề xuất bằng cách so sánh các chỉ số với ngưng được xác định trước. Để giảm thiểu tác động của tiếng ồn đo lường và khai thác các đặc tính thời gian, nhiều kỹ thuật xử lý tín hiệu khác nhau cũng được áp dụng trên chuỗi thời gian của dữ liệu được giám sát để phát hiện lỗi phát hiện, chẳng hạn như biểu đồ trung bình động có trọng số theo cấp số nhân [32] và các biến thể của nó [33], phân tích thống kê bằng kiểm định t [34] và kiểm định tỷ lệ tỷ lệ đồng cục bộ [35], gói wavelet [36], bộ lọc Kalman [37], v.v. trên. Các thuật toán FDD dựa trên ngưng đã đề cập ở trên đều đã được chứng minh là có hiệu quả và hiệu suất, nhưng việc trích xuất thủ công các chỉ số lỗi và việc xác định ngưng ngưng ứng rất tốn thời gian, và hiệu suất tổng quát hóa bị hạn chế. Hơn nữa, hiệu suất phát hiện lỗi có thể bị ảnh hưởng rất nhiều bởi độ chính xác của Các mô hình PV và khả năng chẩn đoán các lỗi khác nhau khá hạn chế.

Trong thập kỷ gần đây, nhiều phương pháp FDD dựa trên AI đã được đề xuất cho các mảng PV cũ ng như để giải quyết các vấn đề về ngưng truyền thống dựa trên phương pháp sử dụng các mẫu dữ liệu phong phú hoặc kiến thức chuyên môn để tự động xây dựng các mô hình chẩn đoán lỗi chính xác [38]. Trong

văn học, chủ yếu có ba lớp kỹ thuật AI được sử dụng cho FDD của mảng PV, bao gồm máy học (ML), hệ thống suy luận mờ (FIS) và lai ghép của chúng. Nhiều thuật toán ML thông thường đã được sử dụng để khám phá và ứng dụng cho FDD của mảng PV. Những FDD dựa trên ML này các phương pháp thông thường sử dụng các mẫu dữ liệu phong phú để tự động xây dựng lên các mô hình FDD hộp đen, có thể được phân loại thành các phương pháp có giám sát, bán giám sát và không giám sát. ML có giám sát phương pháp FDD dựa trên các mẫu dữ liệu được gắn nhãn để xây dựng mô hình. Có nhiều thuật toán ML có giám sát được sử dụng cho FDD của PV mảng, chẳng hạn như cây quyết định (DT) [39], rừng ngẫu nhiên [21], nhân tạo mạng nơ-ron (ANN) [40], máy vectơ hỗ trợ (SVM) [41], máy học ex-treme (ELM) [42], mạng nơ-ron xác suất (PNN) [43], v.v. Mặc dù các phương pháp dựa trên ML có giám sát có thể xây dựng các mô hình FDD đáng tin cậy và chính xác, việc có được một mô hình lớn là rất tốn kém số lượng dữ liệu được gắn nhãn. Thay vào đó, chỉ có các phương pháp ML bán giám sát yêu cầu một lượng nhỏ dữ liệu được gắn nhãn, trong khi các phương pháp ML không giám sát thậm chí chỉ cần các mẫu dữ liệu không có nhãn. Một số bán giám sát và các thuật toán ML không giám sát cho FDD của mảng PV đã được đề xuất, bao gồm học bán giám sát dựa trên đồ thị [44], dựa trên đỉnh mặt độ phân cụm [45], phân cụm K-means [46], phân cụm không giám sát với PNN [47] và phân cụm dựa trên sự giãn nở và xói mòn [48]. Tuy nhiên, độ chính xác bị ảnh hưởng mạnh bởi sự phân bố của các mẫu dữ liệu. Khác với các phương pháp ML, các phương pháp dựa trên FIS dựa vào ngôn ngữ mờ các bộ và quy tắc mờ thu được từ kinh nghiệm của chuyên gia để nhanh chóng thiết lập mô hình FDD [49], có thể thực hiện suy luận giống như con người dựa trên phát hiện và phân loại lỗi [50]. Kết hợp các lợi thế của các thuật toán ML và FIS, một số phương pháp AI lai đã được sử dụng cho FDD của các mảng PV, bao gồm cụm C-mean mờ [51], bộ phân loại thần kinh mờ thích ứng [52]. Mặc dù các phương pháp ML và/hoặc FIS này có thể xây dựng các mô hình FDD hiệu quả tự động, chúng vẫn dựa vào các tính năng lỗi được trích xuất thủ công từ dữ liệu thô dựa trên phân tích nghiêm ngặt tác động của lỗi, điều này sẽ làm giảm hiệu quả mô hình hóa và bỏ qua một số tính năng hữu ích tiềm ẩn dẫn đến hiệu suất hạn chế. Với sự cải thiện nhanh chóng hiệu suất của bộ xử lý, đặc biệt là các kỹ thuật tính toán song song (như nền tảng CUDA do NVIDIA cung cấp), khả năng tính toán của máy tính đang tăng nhanh chóng, hỗ trợ rất nhiều cho sự thịnh vượng của các kỹ thuật AI phức tạp trong những năm gần đây. Đặc biệt, học sâu (DL) các kỹ thuật dựa trên mạng nơ-ron sâu (DNN) đang nhanh chóng nổi lên và đang được áp dụng thành công cho ngày càng nhiều mục đích dân sự và ứng dụng công nghiệp, chẳng hạn như phân loại hình ảnh, nhận dạng đối tượng và theo dõi, chẩn đoán y tế, v.v. [53]. Ngược lại với các thuật toán ML nông thông thường, hầu hết các DNN dựa trên DL có thể đạt được hiệu suất cao hơn thông qua các cấu trúc mạng sâu hơn và tự động học các tính năng phức tạp với biểu diễn trừu tượng trực tiếp từ dữ liệu thô, có thể khắc phục được những nhược điểm của thuật toán ML nông [54]. Một số thuật toán DL đã được áp dụng trong lỗi chẩn đoán các chủ đề khác (ví dụ, máy móc cơ khí) [55], chẳng hạn như mạng nơ-ron tích chập (CNN) [56], bộ mã hóa tự động thư a thốt [57], mạng lưu trí niềm tin sâu (DBN) [58], v.v. Gần đây, một số thuật toán DL đã được đề xuất để chẩn đoán lỗi hệ thống PV, chẳng hạn như CNN [59], máy dài hạn ngắn hạn (LSTM) [60]. Về mặt lý thuyết, mặc dù mạng lưu trí sâu hơn có thể tạo ra hiệu suất cao hơn, chúng nhiều hơn khó đào tạo và có xu hướng bị mất dần hoặc bùng nổ gradient, dẫn đến hội tụ chậm và các vấn đề quá khớp [61]. Để giải quyết những thiếu sót này, các mạng lưu trí dư thừa sâu (ResNet) với kết nối tắt giữa các lớp ẩn được đề xuất đầu tiên bởi He et al. [62] đang nổi lên, có thể cải thiện hiệu quả đào tạo và độ chính xác cho các mạng sâu hơn. ResNet đã được áp dụng thành công trên chẩn đoán lỗi hộp số và được chứng minh là tốt hơn các thuật toán DL khác [63], và nó được các tác giả áp dụng để lập mô hình chính xác của các mô-đun PV cũ ng như [64]. Xét về những ưu điểm của kỹ thuật DL, đặc biệt là ResNet cấu trúc, nghiên cứu này tập trung vào phát hiện và chẩn đoán lỗi dựa trên DL của các mảng PV phía DC của hệ thống PV. Những đóng góp chính là được tóm tắt trong các khía cạnh sau:

- (1) Một cấu trúc ResNet hai chiều mới được thiết kế và áp dụng để xây dựng mô hình FDD của mảng PV bằng cách sử dụng dữ liệu thô của IV đường cong đặc tính và điều kiện môi trường xung quanh. ResNet được đề xuất bao gồm các khối dự, các lớp tích chập, nhóm trung bình lớp và phân loại tuyến tính.
- (2) Đường cong đặc tính IV do ban đầu của các điều kiện khác nhau được lấy mẫu xuống bằng nội suy song tuyến tính để giảm kích thước dữ liệu, sau đó chúng được kết hợp với độ rọi và nhiệt độ tương ứng để tạo thành các mẫu dữ liệu hai chiều cho đào tạo mô hình dựa trên ResNet
- (3) Một mô hình mảng PV dựa trên Simulink được xây dựng cho một phòng thí nghiệm nhỏ mảng PV tỷ lệ để mô phỏng một số lỗi sớm phổ biến ở bất kỳ điều kiện môi trường xung quanh để xác minh mô hình FDD cơ sở ResNet. Dựa trên trên mô hình mô phỏng, tác động của các lỗi khác nhau lên các đường cong đặc tính IV được phân tích để chỉ ra khả năng lỗi phân loại theo hình dạng đường cong.
- (4) Các loại và mức độ khác nhau của các thí nghiệm lỗi sớm được thực hiện trên mảng PV quy mô nhỏ và mô hình dựa trên Simulink để có được đường cong IV và độ rọi và nhiệt độ tương ứng dự đoán điều kiện môi trường khác nhau. Sau đó, FDD dựa trên ResNet được đề xuất mô hình được đào tạo và thử nghiệm dựa trên dữ liệu mô phỏng và thực tế mẫu. Các kết quả mô phỏng và thí nghiệm thực tế đều xác nhận rằng Mô hình FDD dựa trên ResNet được đề xuất có độ chính xác, độ tin cậy và hiệu suất tổng quát cao.
- (5) Hai DNN hiện đại khác, bao gồm CNN và tích chập bộ mã hóa tự động (CAE) cũng được thử nghiệm để so sánh với ResNet được đề xuất. Kết quả so sánh chứng minh đề xuất Mô hình FDD dựa trên ResNet đạt được độ chính xác, khả năng tổng quát hóa, độ tin cậy và hiệu quả đào tạo tốt nhất.

Phần còn lại của bài báo này được cấu trúc như sau. **Phần 2** mô tả mô hình mảng PV dựa trên Simulink và mô phỏng các lỗi khác nhau và phân tích tác động của các lỗi lên đường cong IV. Trong **Phần 3**, cấu trúc ResNet mới và thuật toán học tập là chi tiết, và sau đó là quy trình xây dựng mô hình FDD dựa trên ResNet được mô tả. Các thí nghiệm lỗi được thực hiện để có được mô phỏng và các tập dữ liệu thực trong **Phần 4**, dựa trên đó FDD dựa trên ResNet phương pháp được xác nhận. Cuối cùng, một số kết luận quan trọng được rút ra.

2. Mô hình hóa và phân tích các lỗi mảng quang điện sớm

Trong phần này, một phương pháp mô hình hóa chính xác của một mảng PV thực hệ thống thử nghiệm đầu tiên được giới thiệu. Sau đó, phương pháp mô phỏng của một số lỗi ban đầu phổ biến trong các điều kiện môi trường khác nhau được mô tả. Cuối cùng, mô phỏng lỗi được thực hiện để nghiên cứu tác động của các lỗi trên đường cong đặc tính IV đầu ra của mảng PV. Như ng, thiết lập thử nghiệm của mảng PV thực tế và hệ thống thử nghiệm sẽ được trình bày chi tiết trong **Phần 4**.

2.1. Mô hình hóa một mảng quang điện thực tế

Để xác nhận phương pháp FDD được đề xuất, một hệ thống mảng PV phòng thí nghiệm quy mô nhỏ và mô hình PV dựa trên Simulink tương ứng đầu tiên được xây dựng như thể hiện trong **Hình 1**. Mô hình hệ thống PV được thiết kế để tiến hành mô phỏng lỗi mảng PV với cường độ chiếu xạ có thể kiểm soát và nhiệt độ và để có được đặc tính IV tương ứng và các điều kiện môi trường xung quanh. Mô hình hệ thống PV sử dụng nguồn điện áp được kiểm soát bằng tín hiệu dốc để mô phỏng máy thử IV thực tế như minh họa trong **Hình 1(a)**. Mảng PV bao gồm mười tám tấm PV silicon đơn tinh thể mô-đun (Model: GL-100) được cấu hình thành ba chuỗi PV song song với sáu mô-đun PV (PVM) trong mỗi chuỗi. Đặc biệt, được sử dụng rộng rãi mô hình diode đơn hiệu quả (SDM) được áp dụng để mô hình hóa các mô-đun PV, mạch tương đương được minh họa trong **Hình 1(b)** và (c). Cụ thể, phương trình mô hình SDM cho pin mặt trời cơ bản là được xác định bởi Công thức (1). Vì mô-đun PV được cấu thành từ các tấm pin mặt trời giống hệt nhau các ô nối tiếp và/hoặc song song, phương trình mô hình của mô-đun PV

có thể được mô tả bằng Công thức (2), giả sử rằng điện áp đầu cuối và dòng điện được phân bố đều vào các tế bào năng lượng mặt trời [65].

III thí nghiệm 
$$\frac{(q \cdot V_{IR})}{nKT} = 1 - \frac{V_{IR}}{R_{sh}}$$
 (1)

IN I exp ph s 
$$\frac{(q \cdot V_{IR} N)}{nKT} = 1 - \frac{V_{IR} N}{R_{sh}}$$
 (2)

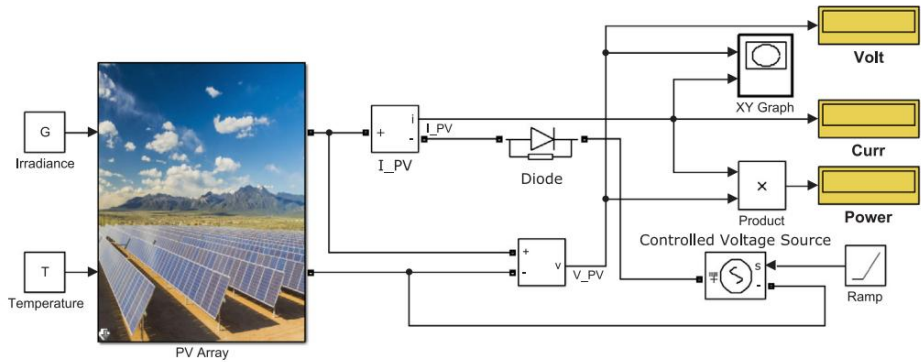
Trong các phương trình (1) và (2), có năm tham số mô hình cần được xác định, bao gồm dòng điện quang (Iph), hệ số lý tưởng của diode (n), độ bão hòa dòng điện (Is), điện trở nối tiếp (Rs) và điện trở phản lưu (Rsh); Hằng số q biểu thị giá trị tuyệt đối của điện tích electron (1,60218 × 10<sup>-19</sup>C) và K là hằng số Boltzman (1,38065 × 10<sup>-23</sup> J/K); Ns và Np là số lượng tế bào quang điện nối tiếp và chuỗi tế bào song song với mô-đun PV tương ứng; T là tế bào năng lượng mặt trời nhiệt độ tuyệt đối. Nói chung, các tham số mô hình nội bộ chủ yếu thay đổi theo điều kiện hoạt động, bao gồm độ rọi và nhiệt độ. Trong mô hình đề xuất, Iph được cấu hình để thay đổi theo nhiệt độ và độ chiếu xạ theo Công thức (3), trong khi các thông số khác là được cấu hình để cố định nhằm cải thiện hiệu quả của mô hình.

Tại = T ( ) STC 
$$\frac{G}{G_{STC}}$$
 (3)

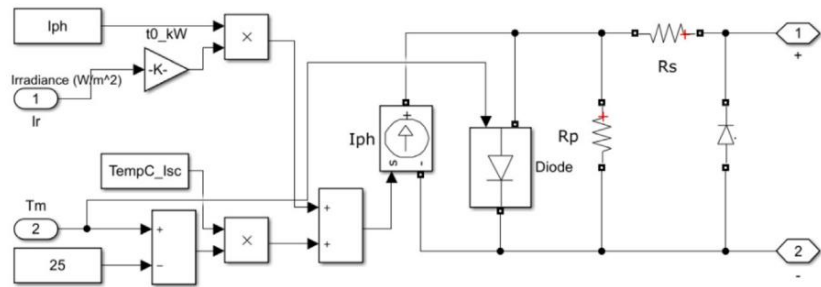
trong đó Iph STC, biểu thị các giá trị của năm tham số mô hình tại Điều kiện STC; T, G, TSTC là nhiệt độ và độ rọi của điều kiện hoạt động (OPC) và điều kiện thử nghiệm tiêu chuẩn (STC điều kiện) tương ứng; Ngoài ra, α là hệ số nhiệt độ của dòng điện quang (Iph). Dựa trên mạch tương đương SDM, nhiều kỹ thuật nhận dạng tham số đã được đề xuất để trích xuất năm tham số từ I đến V đường cong hoặc dữ liệu định mức của các mô-đun PV do nhà sản xuất cung cấp [66]. Trong nghiên cứu này, các phương pháp trích xuất tham số được đề xuất trong [67] là được sử dụng để trích xuất năm tham số mô hình STC từ dữ liệu được đánh giá của Mô-đun PV, bao gồm dòng điện ngắn mạch, điện áp mạch hở và điện áp và dòng điện điểm công suất cực đại (MPP) tại STC. dữ liệu của mô-đun PV GL-100 và các thông số được trích xuất được đưa ra trong **Bảng 1**. Để kiểm chứng mô hình, một số đường cong IV và PV dự đoán các điều kiện khác nhau độ rọi và nhiệt độ được lấy từ mô hình như thể hiện trong **Hình 2**, và có thể thấy rằng chúng về cơ bản phù hợp với dữ liệu định mức của mô-đun PV do nhà sản xuất cung cấp, đặc biệt là hệ số nhiệt độ.

2.2. Mô phỏng và phân tích lỗi mảng quang điện sớm

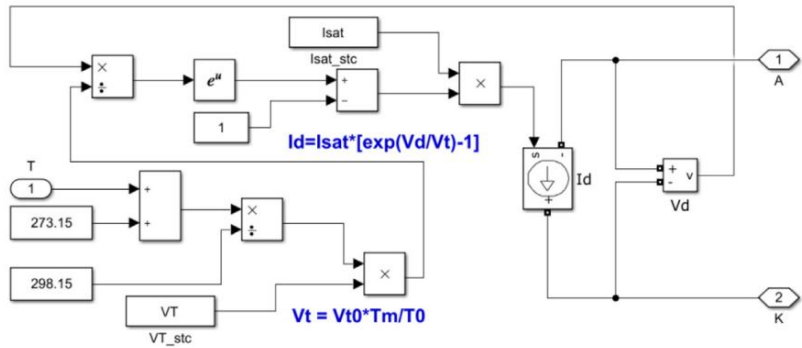
Bài báo này nghiên cứu bốn loại lỗi sớm phổ biến, bao gồm lỗi ngắn mạch, lỗi mạch hở, lỗi suy thoái, và che bóng một phần. Lỗi ngắn mạch biểu thị kết nối ngẫu nhiên hoặc trở kháng thấp giữa hai điểm trong một mảng PV [11], có thể là do hư hỏng lớp cách điện của cáp (do ăn mòn, động vật gặm nhấm) nhai, rò rỉ nước, lão hóa, v.v.), hư hỏng bên trong mô-đun PV, hoạt động sai trong quá trình lắp đặt hoặc bảo trì, v.v. Chập mạch lỗi có thể được phân loại thành lỗi đường dây-đường dây và lỗi đường dây-đất, và chúng sẽ dẫn đến một dòng điện ngược lớn rõ ràng làm giảm công suất đầu ra và thậm chí dẫn đến điện giật và hỏa hoạn. Lỗi mạch hở đề cập đến việc ngắt kết nối cáp hoặc đầu nối, nguyên nhân tương tự như lỗi ngắn mạch và chúng chủ yếu dẫn đến đến tổn thất điện năng. Lỗi suy thoái đề cập đến sự lão hóa ngẫu nhiên của PV các mô-đun, đầu nối và/hoặc cáp có thể bị ăn mòn, tiếp xúc với tia cực tím, v.v. Các lỗi suy thoái thường dẫn đến tăng điện trở nối tiếp tương đương hoặc giảm điện trở song song sức đề kháng, chủ yếu dẫn đến sự suy giảm đáng kể công suất. Bóng râm một phần chủ yếu đề cập đến đầu vào bức xạ khác nhau một phần của PV các mô-đun trong một mảng PV (do bản, bụi bẩn, lá cây, bị cản trở bởi tòa nhà, cây cối, v.v.) [68], có thể gây mất điện và nóng các điểm trong mô-đun PV.



(a) Simulation circuit for I-V testing of the PV array



(b) Model of the PV module



(c) Model of the diode in the PV module model

Hình 1. Mô hình mô phỏng dựa trên Simulink của mảng PV.

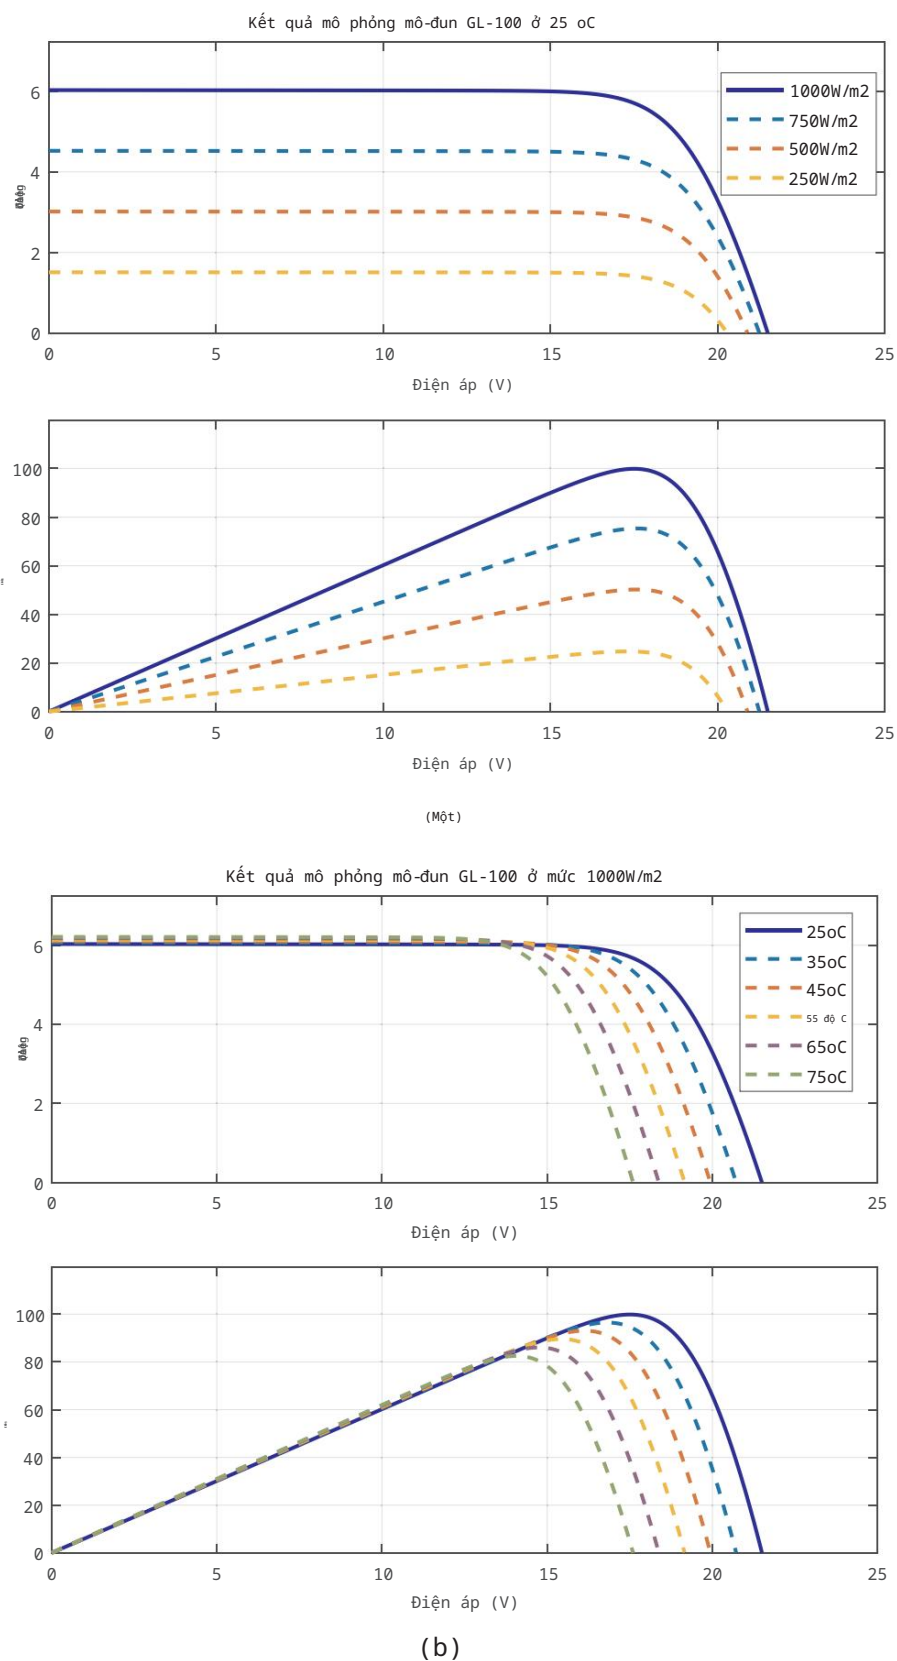
Bảng 1

Thông số kỹ thuật cho mô-đun PV GL-100 làm bằng silicon đơn tinh thể.

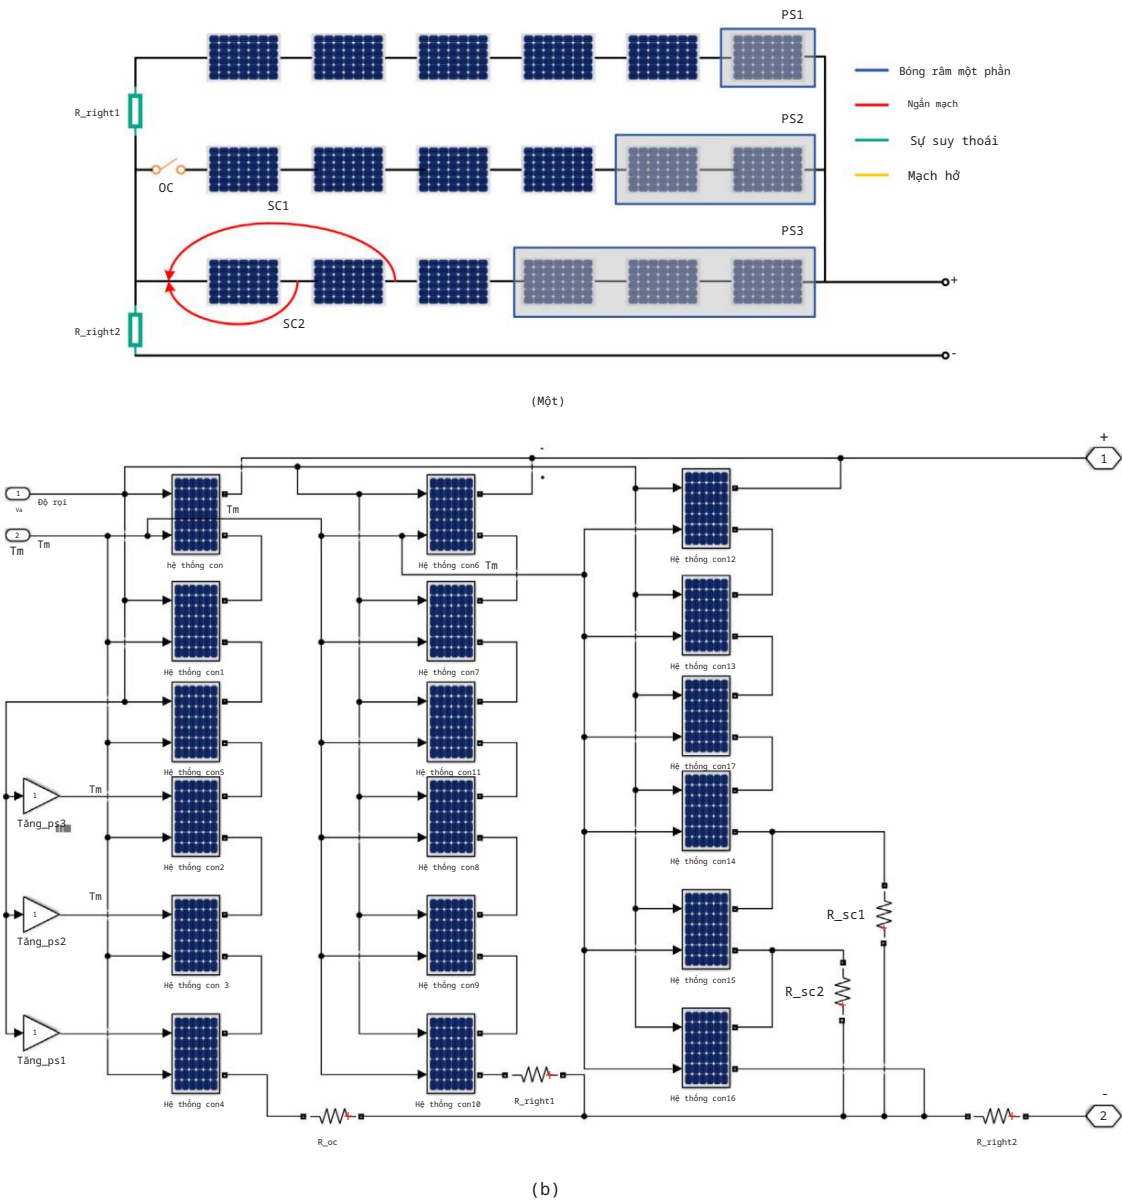
Dữ liệu được đánh giá	Giá trị	Các tham số được trích xuất	Giá trị
Pmpp (T)	100	L <sub>0</sub> , STC (A)	0,18e-6
B <sub>0</sub> (V)	21,5	I <sub>ph</sub> , STC (A)	6.038
I <sub>sc</sub> (A)	6.03	n <sub>STC</sub>	48,3
V <sub>mp</sub> (V)	17,5	R <sub>s</sub> , STC (Ω)	0,1
I <sub>mp</sub> (A)	5.71	R <sub>sh</sub> , STC (Ω)	644,3
Số lượng tế bào năng lượng mặt trời theo chuỗi	36		
Hệ số nhiệt độ I <sub>sc</sub> 0,06%/K			
Hệ số nhiệt độ của V <sub>oc</sub>	78 mV/K		

Hơn nữa, các mức độ khác nhau của bốn loại lỗi đã đề cập ở trên cũng được xem xét trong nghiên cứu này. Cụ thể, tám trường hợp thí nghiệm lỗi cá nhân được thực hiện và nghiên cứu ở quy mô nhỏ mảng PV phòng thí nghiệm, bao gồm hai lỗi ngắn mạch (một mô-đun và hai mô-đun bị ngắn mạch, được ký hiệu là Ngắn mạch 1 và Ngắn mạch 2 tương ứng), lỗi suy thoái chuỗi và mảng (được biểu thị là Sự suy thoái 1 và sự suy thoái 2 tương ứng), và lỗi mạch hở của một chuỗi PV (được biểu thị là Mạch hở), ba bóng râm một phần (một

mô-đun, hai mô-đun và ba mô-đun trong bóng râm, được biểu thị là Shading1, Shading2 và Shading3 tương ứng), như minh họa trong Hình 3(a). Để mô phỏng các lỗi và trạng thái bình thường của mảng PV, một mạch mô phỏng lỗi linh hoạt được thiết kế dựa trên Simulink mô hình, được minh họa trong Hình 3(b). Các lỗi ngắn mạch được mô phỏng bằng cách đặt một điện trở R<sub>sc</sub> có điện trở rất nhỏ giữa các đầu cuối mô-đun PV, trong khi các lỗi mạch hở được mô phỏng bằng thêm một điện trở R<sub>oc</sub> có điện trở rất lớn nối tiếp với PV chuỗi. Các lỗi suy thoái chuỗi và mảng được mô phỏng bằng cách kết nối một điện trở R<sub>de</sub> có điện trở nhỏ nối tiếp với một chuỗi PV hoặc PV mảng. Bóng râm một phần được mô phỏng bằng cách thêm độ khuếch đại vào độ rọi đầu vào của các mô-đun PV có liên quan. Như tóm tắt trong Bảng 2, mô phỏng tình trạng bình thường của mảng PV (PVA) và tám trường hợp của PVA lỗi được thực hiện bằng cách gán các giá trị tư ở ứng cho các tham số của độ lợi hoặc điện trở, bao gồm Gain<sub>ps1</sub>, Gain<sub>ps2</sub>, Gain<sub>ps3</sub>, R<sub>sc1</sub>, R<sub>sc2</sub>, R<sub>de1</sub>, R<sub>de2</sub> và R<sub>oc</sub>. Ngoài ra, để minh họa tác động của các lỗi khác nhau, các đường cong đặc trưng IV và PV của Mảng PV mô phỏng của chín trường hợp được vẽ cùng nhau trong Hình 4(a) và (b), được mô phỏng trong điều kiện môi trường xung quanh điển hình (cường độ chiếu xạ: 800 W/m<sup>2</sup>, nhiệt độ: 25 °C).



Hình 2. Đường cong IV và PV điển hình của mô hình mô-đun PV dựa trên Simulink.



Hình 3. (a) sơ đồ nguyên lý và (b) mạch mô phỏng lỗi.

Bảng 2

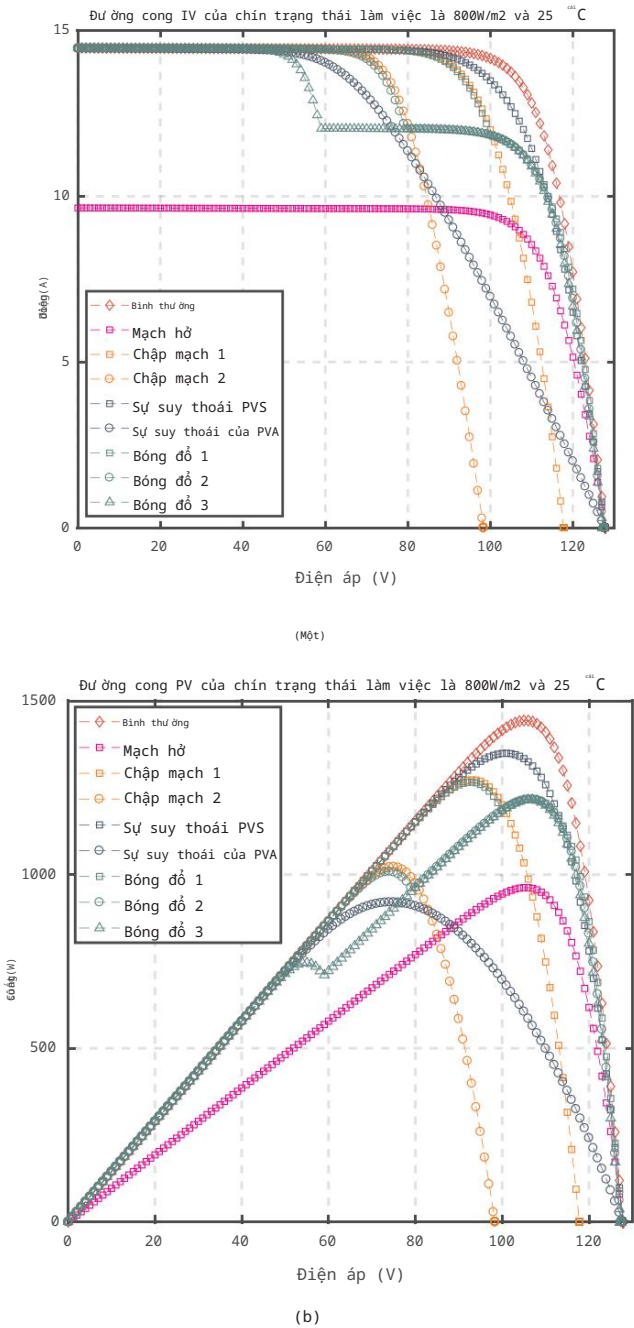
Giá trị tham số của các thành phần được đưa thêm vào ở các trạng thái công việc khác nhau.

Các tham số	Giá trị ở trạng thái bình thường	Giá trị trong trạng thái lỗi
Tăng_ps1	1	0,5
Tăng_ps2	1	0,5
Tăng_ps3		0,5
R_sc1 (Ω)	1	0,001
R_sc2(Ω)	100.000	0,001
R_de1(Ω)	100.000 0,001	3
R_de2(Ω)	0,001	3
R_oc (Ω)	0,001	100.000

Như tóm tắt trong Bảng 2, trạng thái hoạt động bình thường của mảng PV được mô phỏng bằng cách đặt mức tăng (Gain\_ps1, Gain\_ps2 và Gain\_ps3) là 1, điện trở của điện trở nối tiếp (R\_de1, R\_de2 và R\_oc) gần bằng không (0,001), điện trở của điện trở song song (R\_sc1 và R\_sc2) là một giá trị lớn (100000). Theo cách này, các thành phần bổ sung sẽ có rất ít tác động đến mảng PV và mô phỏng có thể chạy bình thường trong môi trường Simulink.

Đối với tám trường hợp khác của mô phỏng lỗi, một số tham số tương ứng được thay đổi thành các giá trị thích hợp khác với các giá trị bình thường. Cụ thể, có ba trường hợp đổ bóng một phần chính với các tham số được đặt như sau: đổ bóng một phần thành PVM1 được biểu thị là "Shading 1" (Gain\_ps1: 0,5), đổ bóng một phần thành PVM1-2 được biểu thị là "Shading 2" (Gain\_ps1: 0,5, Gain\_ps2: 0,5), đổ bóng một phần cho PVM1-3 được biểu thị là "Shading 3" (Gain\_ps1: 0,5, Gain\_ps2: 0,5, Gain\_ps3: 0,5), trong khi các tham số khác được đặt thành bình thường. Trong trường hợp đổ bóng một phần, có thể quan sát thấy từ Hình 4 rằng hình dạng của các đường cong rõ ràng bị méo và có nhiều hơn một đỉnh công suất cực đại cục bộ trong cả đường cong đặc tính IV và PV. Hai lỗi ngắn mạch được định cấu hình và biểu thị là "Ngắn mạch 1" (R\_sc1: 0,001 Ω) và "Ngắn mạch 2" (R\_sc2: 0,001 Ω) tương ứng, trong khi các tham số khác vẫn là thông số bình thường. Như thể hiện trong Hình 4, so với trạng thái bình thường, điện áp mạch hở Voc và điểm công suất cực đại Pm của mảng PV rõ ràng bị giảm do lỗi ngắn mạch, nhưng dòng điện ngắn mạch về cơ bản vẫn giữ nguyên. Lỗi suy giảm chuỗi PV được biểu thị là "suy giảm PVS" và được mô phỏng bằng cách đặt R\_de1 thành 3 Ω, trong khi suy giảm mảng PV được biểu thị là "suy giảm PVA" cũng được mô phỏng bằng cách đặt R\_de2 thành 3 Ω. Có thể thấy





Hình 4. (a) Đur ờng cong đặc trưng IV của m ả ng PV m ỏ ph ỏ ng đ ư ờ i các đi ề u kiện khác nhau đi ề u kiện l ỗ i; (b) Đur ờng cong đặc trưng IV của m ả ng PV m ỏ ph ỏ ng đ ư ờ i theo các l ỗ i khác nhau.

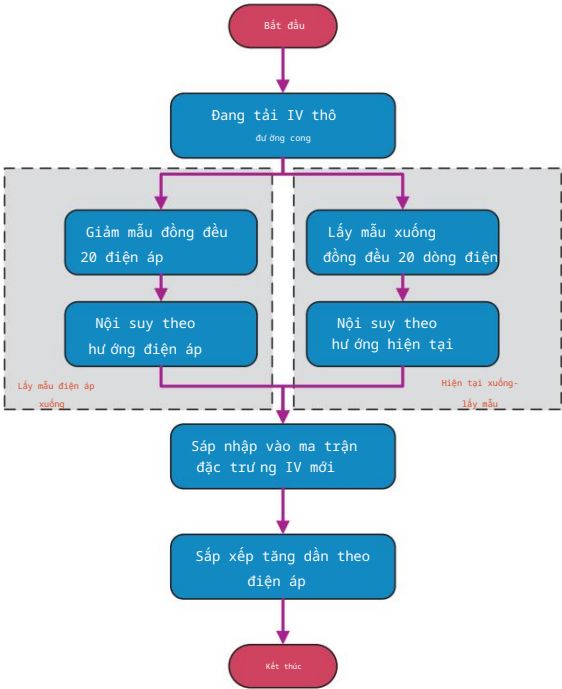
trong Hình 4 dòng điện ngắn mạch và điện áp hở mạch giữ nguyên không thay đổi trong trường hợp suy thoái, như ng điểm MPP thấp hơn cái bình thường. Ngoài ra, việc giảm công suất của sự suy thoái PVA là nghiêm trọng hơn nhiều so với sự suy thoái của PVS. Lỗi mạch hở đư ợ c biểu thị là "Mạch hở" đư ợ c m ỏ ph ỏ ng bằng cách cấu hình R<sub>oc</sub> thành 100000. Trong trường hợp lỗi mạch hở, điện áp mạch hở vẫn không đổi, trong khi dòng điện đầu ra sẽ giảm đáng kể. Theo đó, điểm công suất cực đại P<sub>m</sub> có thể giảm rõ rệt. Do đó, như đư ợ c minh họa trong Hình 4, các lỗi khác nhau rõ ràng có tác động khác nhau đến các đư ờng cong IV đầu ra, có thể ngụ ý tiềm năng khả năng phát hiện và phân loại lỗi trực tiếp dựa trên IV đư ờng cong đặc trưng và đi ề u kiện môi trường xung quanh.

3. Phát hiện và chẩn đoán lỗi dựa trên mạng lư ợ i đư ờ i đư ờ i thừa sâu m ả ng quang điện

Theo quan điểm về hiệu suất cao và tính năng trích xuất tự động khả năng của các kỹ thuật học sâu, sức mạnh mới nổi của học sâu mạng lư ợ i đư ờ i thừa (ResNet) đư ợ c đề xuất để phát hiện và chẩn đoán lỗi (FDD) của các m ả ng PV trực tiếp sử dụng các đư ờng cong đặc trưng IV đầu ra và các đi ề u kiện môi trường xung quanh. Đầu tiên, một số lư ợ i đư ờ i thừa của các đư ờng cong của m ả ng PV đư ợ c thu thập bởi các máy kiểm tra IV trong đi ề u kiện môi trường khác nhau đi ề u kiện cho từng trường hợp trạng thái hoạt động (bao gồm trạng thái bình thường và trạng thái lỗi), chứa nhiều thông tin hơn đư ờ i đư ờ i thừa của các đi ề u kiện hoạt động. Sau đó, các đư ờng cong IV thô và độ chiếu xạ và nhiệt độ xung quanh đư ợ c xử lý trích xuất để xây dựng tập dữ liệu. Tiếp theo, một cấu trúc ResNet mới đư ợ c đề xuất là mô hình FDD. Cuối cùng, mô hình FDD dựa trên ResNet đư ợ c đào tạo và thử nghiệm dựa trên tập dữ liệu đã thiết lập.

3.1. Tiền xử lý dữ liệu

Tiền xử lý các đư ờng cong IV thô và môi trường xung quanh tự động đi ề u kiện là cung cấp dữ liệu chất lượng cao để đào tạo và chạy Mô hình FDD hiệu quả và hiệu suất, bao gồm hai bước. Bước đầu tiên là hạ mẫu các đư ờng cong IV thô. Bước thứ hai là kết hợp các vectơ điện áp và đư ờng cong của mỗi đư ờng cong IV với đi ề u kiện môi trường xung quanh của nó để tạo thành một mẫu dữ liệu hai chiều làm đầu vào của mô hình FDD. Đư ờng cong IV ban đầu thu đư ợ c bởi hầu hết các máy thử IV bao gồm một lư ợ i đư ờ i thừa lớn số điểm dữ liệu có phân phối không đồng đều. Đặc biệt, hầu hết các điểm dữ liệu vẫn nằm trong phạm vi giữa điểm ngắn mạch và MPP, trong khi có ít điểm dữ liệu hơn nhiều giữa MPP và mở điểm mạch. Để cải thiện chất lượng và giảm kích thước dữ liệu của tập dữ liệu để đào tạo mô hình FDD, các đư ờng cong IV thô trước tiên đư ợ c lấy mẫu lại và lấy mẫu xuống để cung cấp các đư ờng cong IV mới đồng nhất phân phối và kích thước dữ liệu nhỏ hơn. Cụ thể, một dòng điện-điện áp dựa trên phương pháp nội suy song tuyến tính đư ợ c đề xuất để giảm mẫu IV thô đư ờng cong theo Phương trình (4) và Phương trình (5), giảm 200 điểm dữ liệu ban đầu thành 40 điểm cho mỗi đư ờng cong IV. Sơ đồ luồng cụ thể của việc lấy mẫu xuống đư ợ c minh họa trong Hình 5. Đầu tiên, 20 điểm dữ liệu mới đư ợ c



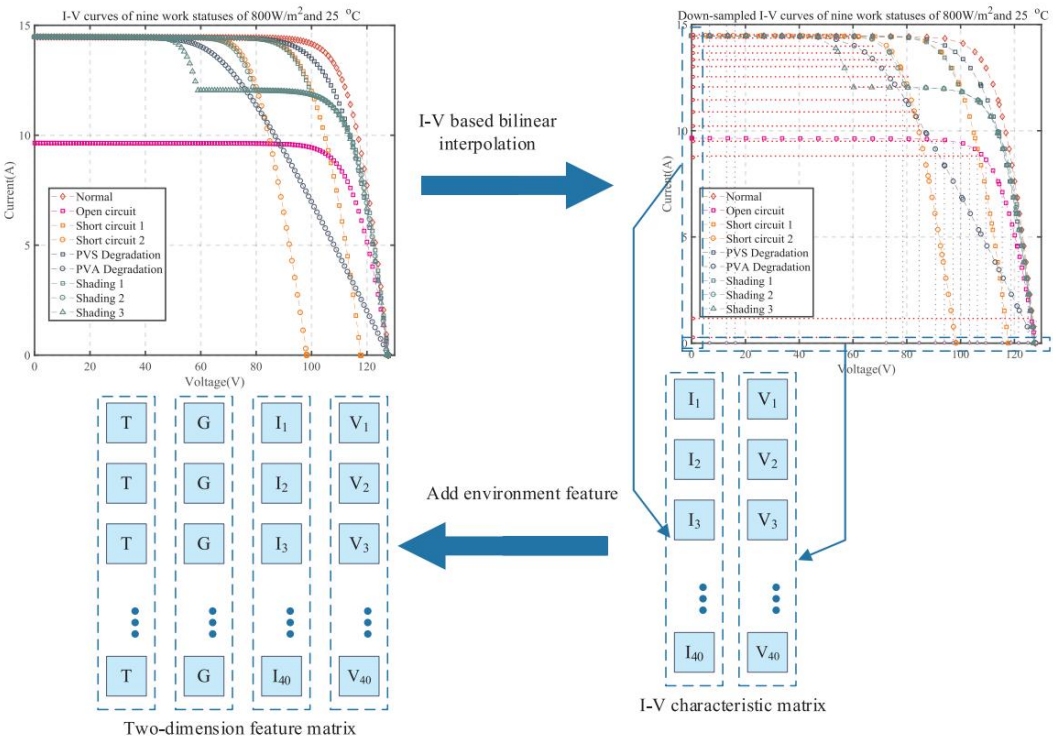
Hình 5. Sơ đồ quy trình lấy mẫu xuống.

được lấy mẫu lại từ đường cong IV thô dọc theo trục điện áp và với điện áp cách đều trong phạm vi [0, Voc], trong khi 20 điện áp mới khác các điểm dữ liệu được lấy mẫu lại dọc theo trục hiện tại với khoảng cách đều dòng điện [0, Isc] tương ứng. Sau đó, điện áp hoặc dòng điện chưa biết của các điểm dữ liệu mới được lấy bằng phép nội suy tuyến tính. Cụ thể, điện áp của 20 điểm dữ liệu mới với dòng điện cách đều được tính toán bằng phép nội suy song tuyến tính như được đưa ra trong Công thức (4), trong khi dòng điện của 20 điểm dữ liệu mới khác với điện áp cách đều được tính toán bằng phép nội suy song tuyến tính như được đưa ra trong Công thức (5). Sau khi thu được cả giá trị điện áp và dòng điện, 40 điểm dữ liệu được lấy mẫu lại mới được hợp nhất và sắp xếp theo thứ tự giảm dần của điện áp, để hình thành đường cong IV mới.

$$I_{new} = \frac{(I_{old} - I_{min}) \cdot (V_{max} - V_{new}) + (I_{max} - I_{old}) \cdot (V_{new} - V_{min})}{V_{max} - V_{min}} \quad (4)$$

$$V_{new} = \frac{(V_{old} - V_{min}) \cdot (I_{max} - I_{new}) + (V_{max} - V_{old}) \cdot (I_{new} - I_{min})}{I_{max} - I_{min}} \quad (5)$$

trong đó IRx và VRx biểu diễn điện áp và dòng điện cách đều nhau của các điểm dữ liệu được lấy mẫu lại tương ứng, trong khi IRx,n và VRx,n là các dòng điện và điện áp nội suy tương ứng với các điện áp cách đều nhau (VRx) và dòng điện (IRx). Ngoài ra, V1, V2, I1 và I2 là giá trị điện áp và dòng điện của các điểm dữ liệu bên trái và bên phải đường cong IV thô, gần nhất với các điểm dữ liệu được lấy mẫu lại. Độ lớn của các đường cong đặc tính IV đầu ra của một mảng PV phụ thuộc rất nhiều vào điều kiện môi trường đầu vào. Do đó, cường độ bức xạ và nhiệt độ phải được đưa vào mẫu dữ liệu, để loại bỏ tác động của các điều kiện môi trường khác nhau lên tập dữ liệu. Theo quan điểm đó, mạng nơ-ron tích chập có tính năng mạnh mẽ trích xuất tính năng tự động trên dữ liệu hai chiều (như hình ảnh), các đường cong IV và điều kiện xung quanh được hình thành thành hai chiều, như thể hiện trong Hình 6. Đầu tiên, độ xói và nhiệt độ là được lập lại để tạo thành một vectơ cột có cùng độ dài với các đường cong IV tương ứng. Sau đó, vectơ nhiệt độ, vectơ bức xạ và IV ma trận đường cong được nối lại để cuối cùng tạo thành đặc điểm của dữ liệu mẫu ma trận hai chiều 40 × 4, như minh họa trong Hình 6. Trong Ngoài ra, phương pháp mã hóa một nóng được sử dụng để dán nhãn các mẫu dữ liệu.



Hình 6. Minh họa quá trình xử lý dữ liệu trước.

Cụ thể, các mã một nóng ([1, 0, 0, 0, 0, 0, 0, 0], [0, 1, 0, 0, 0, 0, 0, 0], [0, 0, 0, 0, 0, 0, 0, 0], [0, 0, 0, 0, 0, 0, 0, 1]) được sử dụng để dán nhãn cho chín số khác nhau điều kiện hoạt động trong nghiên cứu này, bao gồm Bình thường, Bóng râm1, Shading2, Shading3, Degradation1, Degradation2, Ngắn mạch1, Ngắn mạch Mạch 2 và Mạch hở (như được trình bày chi tiết trong tiểu mục 2.2).

Cuối cùng, tất cả các mẫu dữ liệu được chia ngẫu nhiên thành ba tập hợp con, bao gồm bộ đào tạo, bộ xác thực giữ lại và bộ kiểm tra. Đề xuất mô hình được thiết lập bằng cách sử dụng tập dữ liệu đào tạo và sau đó được cải thiện thêm bằng cách sử dụng tập xác thực giữ lại, trong khi các mẫu dữ liệu chưa biết trong tập dữ liệu thử nghiệm được sử dụng để kiểm tra mô hình đã được đào tạo về độ chính xác và hiệu suất tổng quát.

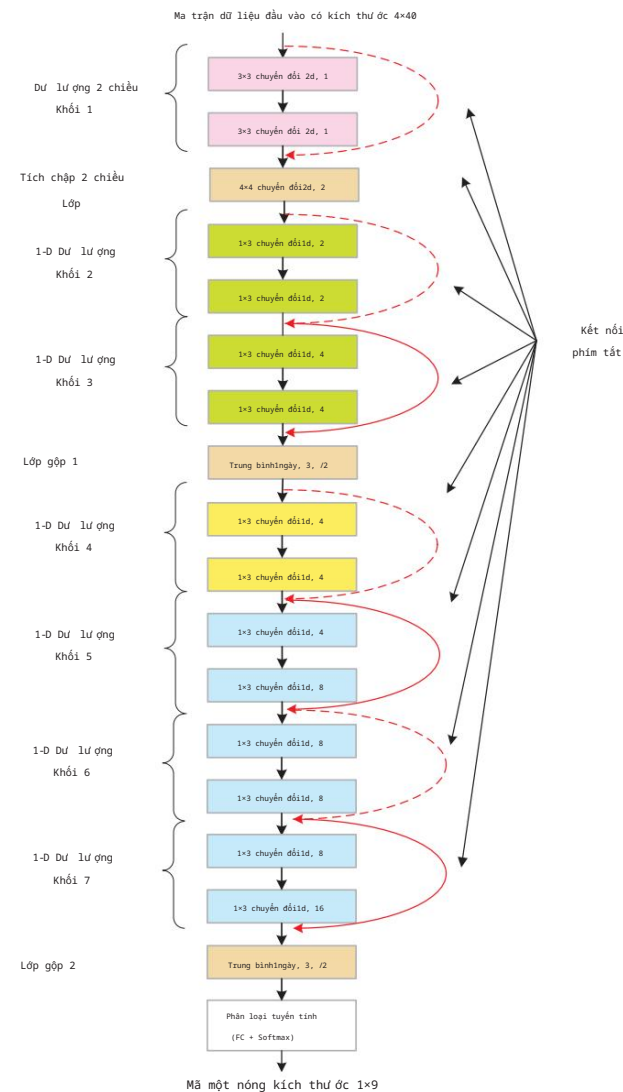
3.2. Mô hình phát hiện và chẩn đoán lỗi dựa trên mạng lưới diều thừa sâu

Ngược lại với các phương pháp học máy truyền thống, chẳng hạn như mạng nơ-ron lan truyền ngược (BPNN), máy vectơ hỗ trợ (SVM), máy học cực đại (ELM) v.v., các kỹ thuật học sâu như có độ chính xác và hiệu suất tổng quát tốt hơn n. Đặc biệt, hầu hết các kỹ thuật học sâu đều có khả năng tự động trích xuất tính năng phi tuyến tính. Là một trong những mạng nơ-ron sâu phổ biến nhất cấu trúc mạng trong lĩnh vực học sâu, mạng diều thừa sâu (ResNet) lần đầu tiên được He et al. [62] đề xuất vào năm 2015 để nhận dạng hình ảnh, được sử dụng rộng rãi trong nhiều tác vụ nhận dạng mẫu khác nhau bây giờ. So với các phương pháp học sâu khác, chẳng hạn như CNN đơn thuần, lợi thế của ResNet bao gồm tốc độ đào tạo cao hơn n, truyền grad-dient dễ dàng hơn n và mạng lưới diều thần kinh sâu hơn n với ít sự biến mất hoặc bùng nổ grad-dient hơn n, v.v. Đặc biệt, dựa trên cấu trúc ResNet, các mạng sâu hơn n có thể được khai thác để đạt được hiệu suất cao hơn n cho cả nhiệm vụ hồi quy và phân loại. Do đó, trong bài báo này, ResNet được khám phá như một bộ phân loại đa năng để phát hiện và chẩn đoán trạng thái bình thường và các lỗi khác nhau của một mảng PV. Kiến trúc của ResNet gốc gồm 34 lớp được đề xuất cho phân loại hình ảnh phức tạp như được trình bày chi tiết trong Bảng 3, bao gồm 2 chiều các lớp tích chập, các lớp gộp và các lớp được kết nối đầy đủ. Tuy nhiên, nó quá phức tạp đối với vấn đề chẩn đoán mảng PV với ít hơn n nhiều các tính năng, gây ra hiệu suất tính toán thấp và thậm chí là vấn đề quá khớp. Do đó, một ResNet đơn giản hóa được đề xuất trong bài báo này



Cấu hình chi tiết của ResNet 34 lớp ban đầu.

Tên lớp	Kích thước đầu ra	Kiến trúc chi tiết cho đề xuất
Conv2D	112×112×64	k = 3, s = 1, padding = 'same', activation = 'relu'
Conv2D	56×56×64	MaxPool, k = 2, s = 2, padding = 'same', activation = 'relu'
Conv2D	28 × 28 × 128	k = 3, s = 1, padding = 'same', activation = 'relu'
Conv2D	14 × 14 × 256	k = 3, s = 1, padding = 'same', activation = 'relu'
Conv2D	7 × 7 × 512	k = 3, s = 1, padding = 'same', activation = 'relu'
Phân loại tuyến tính	1 × 1	Trùng khớp với đầu vào, không có lớp ẩn



Hình 7. Kiến trúc cho mô hình ResNet đơn giản được đề xuất.

để chẩn đoán lỗi PV.

Xem xét những lợi thế đã đề cập ở trên của ResNet, một cấu trúc đơn giản của mạng ResNet được đề xuất là FFD mô hình cho mạng PV. Như minh họa trong [Hình 7](#), ResNet được đề xuất cấu trúc bao gồm các lớp khác nhau, bao gồm (1) Các khối còn lại: tham chiếu đến hai lớp tích chập với một kết nối nhúng tắt; (2)

Input: the mini-batch data  $X_{n \times m} = \{x_1, x_2, \dots, x_m\}$

Output:  $Y = \{y_i = \text{BatchNorm}_{\gamma, \beta}(x_i)\}, i = 1, 2, \dots, m$

$$\mu_{\beta} = \frac{1}{M} \sum_{i=1}^M x_i$$

$$\sigma_{\beta}^2 = \frac{1}{M} \sum_{i=1}^M (x_i - \mu_{\beta})^2$$

$$\hat{X}_i = \frac{x_i - \mu_\beta}{\sqrt{\sigma_\beta^2 + \epsilon}}$$

$$y_i = \gamma \hat{x}_i + \beta \equiv \text{BatchNorm}(x_i)$$

Hình 8. Quy trình cụ thể của phép biến đổi chuẩn hóa theo lô.

Các lớp tích chập (Conv): tự động trích xuất các tính năng hiệu quả từ các bản đồ đặc trưng đầu vào theo một tập hợp các trường tiếp nhận nhỏ (hoặc hạt nhân) với độ sâu đủ; (3) Các lớp gộp trung bình (AvgPool): lấy mẫu xuống ma trận đặc điểm bằng cách chia đầu vào thành các vùng hình chữ nhật và tính toán giá trị trung bình của mỗi vùng; (4) Phân loại tuyến tính: đặt dự đoán phân loại bằng quyết định tuyến tính. Những lớp khác nhau này trong ResNet được đề xuất để trình bày chi tiết như sau.

(1) **Lớp tích chập:** Là một cấu trúc học sâu phổ biến, lớp tích chập hai chiều tiêu chuẩn (Conv2d) có thể giảm các tham số miễn phí trong quá trình đào tạo và thúc đẩy hiệu suất nhờ vào những lợi thế của lĩnh vực tiếp nhận địa phương và chia sẻ trọng lượng. So với lớp được kết nối đầy đủ, Conv2d xử lý các đầu vào bằng cách sử dụng một loạt các bộ lọc (gọi là hạt nhân trong bài báo này) trong một vùng nhỏ (trường tư ng ứng) với các kết nối cục bộ. Về cơ bản, quá trình tính toán trong lớp tích chập là một phép toán để trượt từng bộ lọc trên ma trận đầu vào và tính tích vô hướng trên hạt nhân và đầu vào ở mọi vị trí, có cùng nguyên lý như tích chập một chiều (Conv1d). Quá trình tính toán cụ thể của Conv2d được xác định trong Công thức (6), trong khi Conv1d được xác định bằng tư ng quan chéo toán tử như Eq. (7).

$$\text{Conv2d}(\cdot) \times \bar{k} \times (\cdot) \quad (6)$$

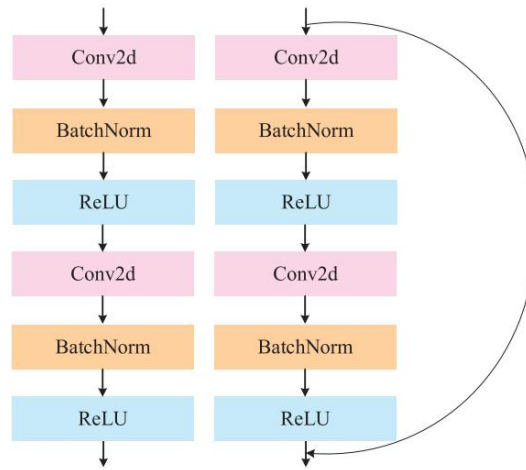
$$\text{Conv1d}(\cdot) \times \underset{m=0}{C_{\text{trong } 1}} K \times K \quad (7)$$

trong đó  $x$  là đầu ra 2 chiều từ lớp trước và  $i, j$  được sử dụng để ghi lại tọa độ trong đầu vào 2 chiều. Ngoài ra,  $K$  biểu thị ma trận hạt nhân  $m \times m$ , là một tham số có thể học được trong quá trình đào tạo quá trình.  $w$  và  $h$  là chỉ số vị trí trong ma trận hạt nhân 2 chiều. Trong Phương trình (7),  $Kk$  là kích thước hạt nhân có nơ-ron đầu vào thứ  $k$  và  $*$  là toán tử tương quan chéo không có phần đệm bằng không.


(2) **Lớp gộp:** Lớp gộp, thường được chèn vào các lớp kế tiếp các lớp tích chập, chủ yếu được sử dụng để giảm kích thước không gian của bản đồ đặc điểm và kiểm soát hiệu quả việc quá khớp như Phức hợp trình (8) và (9). Đặc biệt, tính toán kích thước giống như Conv1d và Conv2d. Trong bài báo này, nhóm trung bình (AvgPool) được chọn để vận hành trên từng độ sâu và lát cắt của bản đồ đặc điểm một cách độc lập, thay thế toàn bộ tầng pooling nhận bằng cách tính trung bình.

$$r_{a_{ngoài}} = \frac{tu_{\text{đang w}}}{s} + 1 \quad (8)$$

$$h_{\text{ngoi}} = \frac{h_{\text{tong}} \cdot \tan \alpha}{S} + 1 \quad (9)$$



(a) Architecture of the 2-D plain convolution block (left) and the 2-D residual block (right)



(b) Architecture of the 1-D plain convolution block (left) and the 1-D residual block (right)

Hình 9. Cấu trúc bên trong của các khối còn lại.

trong đó  $w$  và  $h$  biểu diễn chiều rộng và chiều cao của ma trận hai chiều đầu vào, trong khi  $w_{out}$  và  $h_{out}$  là chiều rộng và chiều cao của ma trận đầu ra. Trong ngoài ra,  $k_w$  và  $k_h$  là chiều rộng và chiều cao của kích thước hạt nhân.

- (3) Chức năng kích hoạt: Để tìm hiểu các tính năng phức tạp và phi tuyến tính từ tập dữ liệu thô, hàm kích hoạt phi tuyến tính được sử dụng để tăng tính phi tuyến tính của các đặc điểm được trích xuất. Trong bài báo này, hàm kích hoạt phi tuyến tính đơn vị tuyến tính chính lưu (ReLU) được chọn, như được xác định Phụ lục trình (10) trong đó  $x$  là tính năng đầu vào, có thể đẩy nhanh đáng kể sự hội tụ và làm giảm sự biến mất vấn đề về độ dốc. Ngoài ra, hàm kích hoạt đơn giản không có hạn chế là tính toán hiệu quả hơn nhiều, so với Hình chữ S với phép toán mũ.

$$\text{ReLU}(x) = \begin{cases} 0, & x \leq 0 \\ x, & x > 0 \end{cases} \quad (10)$$

- (4) Chuẩn hóa hàng loạt: Các kỹ thuật học sâu thường tham gia tập huấn luyện được chia thành nhiều tập nhỏ gọi là mini-batch và sau đó đào tạo mô hình dựa trên các lô nhỏ, có thể đạt được sự cân bằng tốt giữa sự hội tụ và tính phức tạp của phép tính. Tuy nhiên, phụ thuộc pháp mini-batch có xu hướng chịu sự thay đổi cov-ariate nội bộ có thể làm giảm tốc độ đào tạo và tính ổn định. Batch chuẩn hóa (BatchNorm) được đề xuất bởi Ioffe và Szegedy để giảm sự dịch chuyển biến phụ thuộc nội bộ bằng cách chuẩn hóa các lớp đầu vào thông qua việc mở rộng quy mô và điều chỉnh các hoạt động [69], do đó cải thiện

tốc độ đào tạo và độ tin cậy trong khi giảm thiểu tình trạng quá khớp và các vấn đề biến mất/bùng nổ theo độ dốc với tốc độ học cao hơn. Biến đổi BatchNorm được trình bày chi tiết trong Hình 8, trong đó đầu vào  $x$  bao gồm  $m$  mẫu lô nhỏ và  $n$  biểu diễn kích thước của mỗi mẫu  $x_i$ . Ngoài ra,  $\mu$  và  $\sigma$  là giá trị trung bình và phương sai của các mẫu lô nhỏ tương ứng. Có hai mẫu có thể học được tham số  $\gamma$  và  $\beta$  trong Hình 8. Giá trị mặc định của hằng số cuối cùng hệ số là 0,0001, đây là một giá trị rất nhỏ để tránh số không mẫu số.

- (5) Khối dư: Cấu trúc bên trong của khối dư được hiển thị trong Hình 9. So với CNN thông thường, có một kết nối tắt từ đầu vào đến đầu ra trong một khối dư. Với phím tắt (solid dòng trong Hình 7), các đầu vào có thể được gắn trực tiếp vào đầu ra như được đưa ra trong Công thức (11), khi đầu vào và đầu ra có cùng kích thước. Khi kích thước khác nhau (được chấm trong Hình 7),  $a$  hệ số khớp kích thước được giới thiệu để khớp với đầu vào và kích thước đầu ra như được đưa ra trong Công thức (12).

$$y = Fx \quad (11)$$

$$y = Fx + Wx \quad (12)$$

trong đó  $x$  và  $y$  là đầu vào và đầu ra của các khối còn lại, hàm  $F$  biểu diễn mối quan hệ ánh xạ từ đầu vào đến đầu ra và  $W$  là hệ số khớp kích thước.

Trong Hình 9(a), khối dư 2-D chủ yếu bao gồm 2-D lớp tích chập (Conv2d), lớp chuẩn hóa hàng loạt (BatchNorm)

Bảng 4  
Cấu hình cụ thể cho cấu trúc ResNet được đề xuất.

Lớp	Đầu ra kích thước	Cấu trúc chi tiết của ResNet được đề xuất
Lớp đầu vào	$40 \times 4 \times 1$	
Dữ liệu 2 chiều Khối 1	$40 \times 4 \times 1$	$C_k = 3 \times 3, s_{\text{ngoài}} = 2, p = 1$
		$k = 3 \times 3, C_{\text{ngoài}} = 1, s_{\text{ss}} = p = 1$
		$k = 3 \times 3, C_{\text{ngoài}} = 1, s_{\text{ss}} = p = 1$
Chuyển đổi 2 chiều	$37 \times 1 \times 2$	$k = 4, s_{\text{ss}} = 1, p = 0$
Kích thước	$37 \times 2$	
Vết nứt		
1-D Dữ liệu Khối 1	$37 \times 2$	$3, k = 2, s_{\text{ss}} = 1, p = 1$
		$3, k = 2, s_{\text{ss}} = 1, p = 1$
1-D Dữ liệu Khối 2	$37 \times 4$	$3, k = 4, s_{\text{ss}} = 1, p = 1$
		$k = 3, s_{\text{ss}} = 1, p = 1$
Nhóm trung bình 1	$18 \times 4$	$k = 4, s_{\text{ss}} = 3, 0, s_{\text{ss}} = p$
1-D Dữ liệu Khối 3	$18 \times 4$	$3, k = 2, s_{\text{ss}} = 1, p = 1$
		$3, k = 2, s_{\text{ss}} = 1, p = 1$
1-D Dữ liệu Khối 4	$8 \times 8$	$4, k = 8, s_{\text{ss}} = 2, p = 0$
		$s_{\text{ss}} = 3, C_{\text{ra}} = 8, s_{\text{ss}} = 1, p = 1$
1-D Dữ liệu Khối 5	$8 \times 8$	$3, k = 8, s_{\text{ss}} = 1, p = 1$
		$3, k = 8, s_{\text{ss}} = 1, p = 1$
1-D Dữ liệu Khối 6	$8 \times 16$	$k = 3, s_{\text{ss}} = 16, s_{\text{ss}} = 1, p = 1$
		$k = 3, s_{\text{ss}} = 16, s_{\text{ss}} = 1, p = 1$
Trung bình nhóm 2	$3 \times 16$	$k = 16, C_{\text{ra}} = 4, s_{\text{ss}} = p$
Phân loại tuyến tính	9	Lớp FC và đầu ra Softmax


và hàm kích hoạt ReLU, trong khi khối dữ liệu 1-D chỉ thay đổi lớp tích chập 2 chiều thành lớp tích chập 1 chiều (Conv1d) như được minh họa trong Hình 9(b).

Bảng 5  
Cấu hình chi tiết của cấu trúc CNN được so sánh.

Tên lớp	Đầu ra kích thước	Kiến trúc chi tiết cho đề xuất
Lớp đầu vào	$40 \times 4 \times 1$	
CNN 2 chiều	$37 \times 1 \times 1$	$s_{\text{ss}} = 4, 4, 1, C_{\text{ra}} = k = 0$
Kích thước	$37 \times 1$	
Vết nứt		
CNN 1 chiều	$18 \times 3$	$k = 35, 24, s_{\text{ss}} = 33, 0, s_{\text{ss}} = k =$
CNN 1 chiều	$18 \times 5$	$C_{\text{ra}} = s_{\text{ss}} = p$
MaxPool1D	$8 \times 5$	$k = 4, s_{\text{ss}} = 2$
CNN 1 chiều	$8 \times 8$	$k = 8, s_{\text{ss}} = 3, 5, s_{\text{ss}} = p$
MaxPool1D	$4 \times 8$	$k = 2, s_{\text{ss}} = 2$
CNN 1 chiều	$4 \times 16$	$k = 16, C_{\text{ra}} = 3, 5, s_{\text{ss}} = p$
MaxPool1D	$1 \times 16$	$k = 4, s_{\text{ss}} = 4$
FC	10	Lớp được kết nối đầy đủ
Phân loại tuyến tính	$10 \times 9$	Lớp FC và đầu ra Softmax

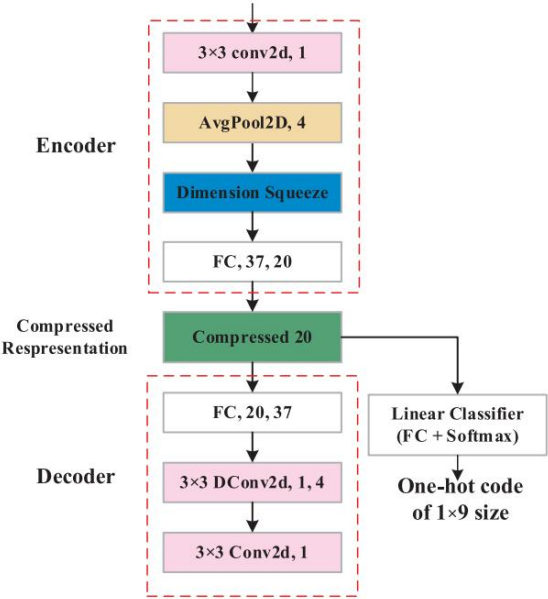
(6) Phân loại tuyến tính: Sau khi trích xuất và nén đặc điểm bằng các lớp tích chập, bộ phân loại tuyến tính được sử dụng để tính toán kết quả phân loại. Trong bài báo này, bộ phân loại tuyến tính được cấu thành của một lớp được kết nối đầy đủ (FC) và một hàm Softmax. Cụ thể, lớp FC kết nối mọi nơ-ron từ lớp này sang lớp khác, có cùng nguyên lý như perceptron nhiều lớp. Phép tính của lớp FC sử dụng tích vô hướng được thể hiện trong Công thức (13). Tuy nhiên, đầu ra của FC là một giá trị liên tục không thể trực tiếp biểu diễn các kết quả phân loại rời rạc. Để thực hiện phân loại, như được định nghĩa trong Công thức (14), hàm Softmax được sử dụng để chuẩn hóa vectơ đầu vào thành vectơ có xác suất thuộc về mỗi lớp và lớp có xác suất lớn nhất là được chọn làm kết quả dự đoán cuối cùng.

Input Data Matrix of 4×40 size



(a)

Input Data Matrix of 4×40 size



(b)

Hình 10. Kiến trúc chi tiết của mạng CNN (a) và mạng CAE (b) để so sánh.

Bảng 6

Cấu hình chi tiết của cấu trúc CAE được so sánh.

Tên lớp	Đầu ra kích thước	Kiến trúc chi tiết cho đề xuất
Hình 3(a) ResNet		
Lớp đầu vào	40 × 4 × 1	
CNN 2 chiều	40 × 4 × 1	Ck = 5, s = 2, p = 1, p = 1
Trung bình 2D 37 × 1 × 1		Ck = 4, s = 1, p = 0
Kích thước bỏp 37		
Lớp FC 20		Lớp được kết nối đầy đủ
Nén đại diện	20	Các tính năng nén được lấy từ Bộ mã hóa
Lớp FC	37	k = 4, s = 2
Kích thước	37 × 1 × 1	
Nhả ra		
DCNN 1-D	40 × 4 × 1	k = 5, s = 2, p = 1
CNN 1 chiều	40 × 4 × 1	Ck = 5, s = 2, p = 1
CNN 1 chiều	4 × 16	Ck = 16, s = 1, p = 0
Phân loại tuyến tính	9	Lớp FC và đầu ra Softmax

$y = Wx + b$  (13)

$$\text{Softmax}(x) = \frac{e^{x_i}}{\sum_{k=1}^K e^{x_k}}, i = 1, 2, \dots, K$$
 (14)

trong đó  $W \in \mathbb{R}^{D \times M}$  là ma trận trọng số của chiều  $N \times D$  và  $x \in \mathbb{R}^{D \times M}$  là bản đồ đặc điểm đầu vào của chiều  $D \times M$ , trong khi  $b$  là độ lệch. Trong Phương trình (14),  $x_i$  là một trong các phần tử trong lớp đầu ra và  $C_o$  là kích thước của đầu ra (9 trong bài báo này).

Cụ thể, cấu trúc ResNet được đề xuất được minh họa trong Hình 7. Lớp đầu vào của ResNet là một ma trận dữ liệu có kích thước  $4 \times 40$ , trong khi đầu ra là một bản đồ nóng có kích thước  $1 \times 9$ . Khối dư 2 chiều đầu tiên được sử dụng để trích xuất tính năng từ dữ liệu đầu vào mà không cần can thiệp thủ công và lớp tích chập 2 chiều sau đây được sử dụng để nén tính năng để có tốc độ đào tạo cao hơn và độ phức tạp tính toán thấp hơn. Sau khi các mô-đun trích xuất tính năng, có sáu khối dư 1-D với một AvgPool được thêm vào giữa khối dư 1-D thứ hai và thứ ba cho nén tính năng tiếp theo. Một AvgPool khác được thêm vào để khớp chiều trước khi phân loại tuyến tính. Cuối cùng, một phân loại tuyến tính (Tuyến tính) được sử dụng để phân loại, bao gồm một lớp FC và Lớp đầu ra Softmax. Lấy cảm hứng từ bài báo ResNet gốc, các khối dư trừ khối dư 1-D được thiết lập để điều chỉnh đầu ra kênh, trong khi lớp tích chập 2 chiều đơn đầu tiên và lớp gộp được sử dụng để cấu hình kích thước của đầu ra. Ngoài ra, kích thước hạt nhân của các khối dư 1-D được đặt thành 4 cho thuật toán thấp hơn sự phức tạp và sự phù hợp kích thước tốt hơn. Cấu hình cụ thể đối với cấu trúc ResNet được đề xuất được liệt kê trong Bảng 4.

So với ResNet ban đầu được đề xuất lần đầu tiên trong [62], kiến trúc của cấu trúc ResNet được đề xuất đầu tiên được đơn giản hóa từ

Bảng 7

Thiết lập siêu tham số trong quá trình đào tạo.

Siêu tham số	Giá trị
N	512
	1e-3
lr	0,995
$\beta_1$ $\beta_2$	0,999
Kỷ nguyên	500
	1e-8

34 lớp đến 18 lớp với độ chính xác được đảm bảo, điều này rất quan trọng cải thiện hiệu quả của mảng PV FDD. Thứ hai, bản đồ đặc điểm là được giảm xuống thành một số vô hướng bằng phép toán Conv2d và Conv1d hoạt động được sử dụng thêm để giảm các tính năng đào tạo cho hiệu quả cao hơn. Hơn nữa, Conv1D được giới thiệu có khả năng trích xuất tính năng tốt hơn so với Lớp được kết nối đầy đủ.

Để đánh giá thêm tính ưu việt của ResNet được đề xuất dựa trên chẩn đoán lỗi, hai cấu trúc học sâu khác thường được sử dụng là được sử dụng để so sánh, bao gồm cả mạng nơ-ron tích chập được kết nối đầy đủ mạng (CNN) và bộ mã hóa tự động tích chập (CAE). Cụ thể kiến trúc của CNN và CAE được trình bày chi tiết trong Hình 10(a) và (b). Trong Ngoài ra, cấu hình cho CNN và CAE được liệt kê trong Bảng 5 và 6. Cụ thể, lấy cảm hứng từ mạng AlexNet và VGG để nhận dạng hình ảnh [70,71], CNN để so sánh được tạo thành từ Conv2d, Lớp gộp và các lớp được kết nối đầy đủ. Trong bài báo này, một số Conv2d là được thay thế bằng Conv1d để đảm bảo các tính năng khớp kích thước và trích xuất các tính năng tự động như Hình 10(a). Về mặt CAE, Giải tích chập (DConv) là phép toán tích chập ngược được sử dụng để tạo ra các tính năng ban đầu và các tính năng tối ưu được xác định bằng cách tính toán sự khác biệt giữa tính năng gốc và tính năng tạo ra tính năng. Cuối cùng, bản trình bày nén tối ưu được sử dụng cho phân loại, được đánh dấu màu xanh lá cây trong Hình 10(b).

3.3. Đào tạo mô hình phát hiện và chẩn đoán lỗi

Sau khi xác định cấu trúc mạng nơ-ron, mạng ResNet cần được đào tạo bằng cách sử dụng tập dữ liệu được gắn nhãn để có được nội bộ trọng số và độ lệch. Sau khi mạng được đào tạo, ResNet dựa trên mô hình có thể được sử dụng để thực hiện phát hiện lỗi và chẩn đoán cho dữ liệu không được gắn nhãn. Là một loại phương pháp học có giám sát, việc đào tạo mô hình ResNet là để giảm thiểu hàm mất mát trên nhãn tập huấn luyện bằng thuật toán học tập. Hàm mất mát được giảm thiểu trong bài báo này được định nghĩa là entropy giữ lại như được đưa ra trong Công thức (15).

Step 1. Set the initial value for  $lr, \beta_1, \beta_2, \epsilon, Epoch$ ;

Step 2. Randomly select optimization parameter  $\theta$  and set  $m = 0, v = 0, epoch = 0$ ;

Step 3. Update the parameters when  $epoch < Epoch$ :

Step 3.1. Increase counters  $epoch += 1$ ;

Step 3.2. Calculate  $g = \frac{1}{n} \nabla_{\theta} \sum_{i=1}^n J(f(x^{(i)}; \theta), y^{(i)})$ ;

Step 3.2. Calculate  $m_{epoch} = \beta_1 \cdot m_{epoch-1} + (1 - \beta_1) \cdot g_{epoch}$ ;

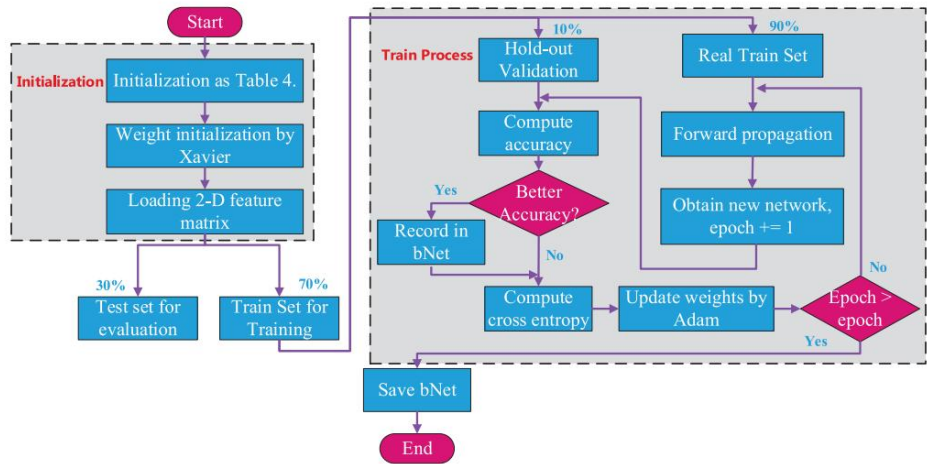
Step 3.3. Calculate  $v_{epoch} = \beta_2 \cdot v_{epoch-1} + (1 - \beta_2) \cdot g_{epoch}^2$ ;

Step 3.4. Calculate  $\hat{m}_{epoch} = \frac{m_{epoch}}{1 - \beta_1^{epoch}}$  and  $\hat{v}_{epoch} = \frac{v}{1 - \beta_2^{epoch}}$ ;

Step 3.5. Update parameters  $\theta$ :  $\theta_{epoch+1} = \theta_{epoch} - lr \frac{\hat{m}_{epoch}}{\sqrt{\hat{v}_{epoch} + \epsilon}}$ ;

Step 4. Return the optimal solution  $\theta$ ;

Hình 11. Mã giả của thuật toán tối ưu hóa Adam.



Hình 12. Sơ đồ quy trình đào tạo mô hình FDD dựa trên học sâu.

**Bảng 8**  
Phân phối các mẫu dữ liệu mô phỏng.

Các loại lỗi	Loại Số	Số lượng mẫu		
		Bộ đào tạo	Xác thực chéo	Bộ thử nghiệm
Bình thường	1	1872	220	893
Bóng đổ 1	2	1872	220	891
Bóng đổ 2	3	1876	220	893
Bóng đổ 3	4	1873	220	893
Sự suy thoái 1	5	1874	219	893
Sự suy thoái 2	6	1878	221	893
Chập mạch 1	7	1872	219	893
Chập mạch 2 8		1871	220	892
Mạch hở	9	846	99	404
Hoàn toàn		15.834	1858	7545

$$J_{\text{W}} = \frac{1}{N} \sum_{n=1}^N \left[ \frac{1}{2} \| \mathbf{y} - \hat{\mathbf{y}} \|^2 + \lambda \left( \frac{1}{2} \sum_{i=1}^M \mathbf{W}_i^T \mathbf{W}_i \right) \right] \quad (15)$$

trong đó N là số phân loại của tất cả các mẫu dữ liệu, đó là bảng 9 trong bài báo này. y<sub>n</sub> là nhãn thực một nóng của một mẫu dữ liệu, trong khi y<sub>n</sub><sup>l</sup> là vectơ xác suất của dự đoán.

Trong bài báo này, ước tính mô men thích ứng (Adam) [72] được sử dụng để đào tạo ResNet được đề xuất, đây là thuật toán tốc độ học tập thích ứng và vượt trội hơn, đặc biệt về tốc độ đào tạo. Thuật toán học tập Adam sử dụng chiến lược tốc độ học tập thích ứng để tìm tốc độ học phù hợp cho từng tham số trong quá trình đào tạo. Cụ thể, Adam duy trì sự suy giảm theo cấp số nhân và sự thích nghi gradient theo ước tính đầu tiên và ước tính mô men thứ hai. Trong Ngoài ra, thuật toán này được thiết kế để sử dụng các đợt đào tạo nhỏ tập dữ liệu trong mỗi lần lặp lại để đạt được sự cân bằng tốt giữa sự hội tụ và độ phức tạp tính toán. Mã giả thuật toán Adam là

**Bảng 9**  
So sánh độ chính xác phân loại của ba mô hình trên các mẫu dữ liệu mô phỏng.

Mục	CNN		CAE		Mạng Lú Di ResNet	
	Độ chính xác đào tạo (%)	Độ chính xác thử nghiệm (%)	Độ chính xác đào tạo (%)	Độ chính xác thử nghiệm (%)	Độ chính xác đào tạo (%)	Độ chính xác thử nghiệm (%)
Bình thường	99,95	100.0	99,95	99,89	100.0	100.0
Bóng đổ 1	100.0	99,66	99,84	99,44	100.0	100.0
Bóng đổ 2	100.0	100.0	100.0	100.0	100.0	100.0
Bóng đổ 3	92,37	92,39	96,85	97,65	100.0	100.0
Sự suy thoái 1	96,58	96,08	87,46	86,00	100.0	99,78
Sự suy thoái 2	99,95	99,89	98,88	99,22	100.0	100.0
Chập mạch 1	100.0	100.0	100.0	100.0	100.0	100.0
Chập mạch 2	100.0	100.0	100.0	100.0	100.0	100.0
Mạch hở	91,84	92,08	59,57	61,39	100.0	100.0


được trình bày chi tiết trong Hình 11. trong đó lr là tốc độ học ban đầu và là hằng số rất nhỏ. β<sub>1</sub> , β<sub>2</sub> là các hệ số chuyển động trung bình, có giá trị mặc định là 0,9 và 0,999 tương ứng. Kỳ nguyên và kỳ nguyên là các số của tổng số lần lặp lại và lần lặp lại hiện tại tương ứng. Ngoài ra, m và v là ước tính mô men thứ nhất và thứ hai. g biểu diễn gradient của hàm mất mát J và n là kích thước lô nhỏ hiện tại. θ đại diện cho các trọng số và độ lệch trong ResNet được đề xuất, cần được tối ưu hóa. f ( ) là mối quan hệ ánh xạ từ các đầu vào đến đầu ra. Các siêu tham số cụ thể được thiết lập như được liệt kê trong Bảng 7.

Hơn nữa, các thuật toán tối ưu hóa dựa trên gradient thường được bị ảnh hưởng bởi giá trị ban đầu θ và các giá trị ban đầu không phù hợp có xu hướng gây ra sự hội tụ chậm và bị mắc kẹt vào tối ưu cục bộ. Để cải thiện chất lượng của điểm ban đầu, quá trình khởi tạo công nghệ Xavier [73], xác định quy mô khởi tạo theo số lượng các neuron đầu vào và đầu ra, được sử dụng để duy trì cùng một phân bố sai từ đầu vào và đầu ra để tránh độ dốc biến mất và bùng nổ. Tóm lại, sơ đồ luồng cụ thể để đào tạo Mô hình FDD mạng PV dựa trên ResNet có thể được minh họa trong Hình 12.

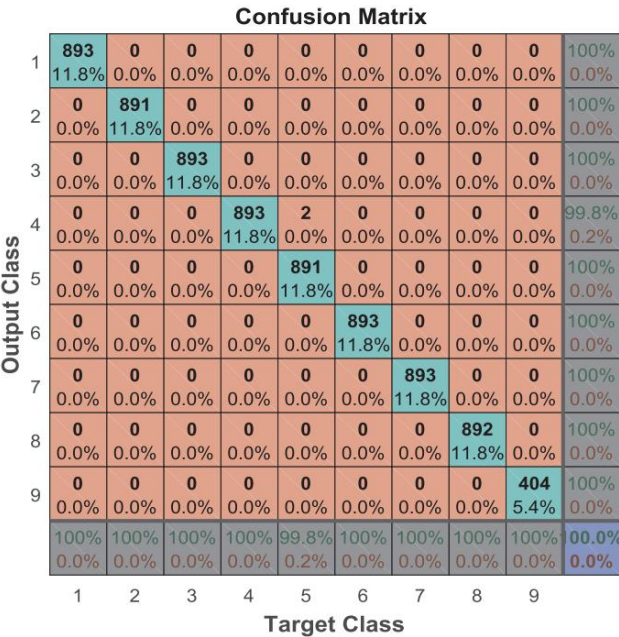
4. Nghiên cứu mô phỏng và thực nghiệm thực tế

Dựa trên một mạng PV quy mô nhỏ trong phòng thí nghiệm và dựa trên Simulink mô hình mô phỏng được trình bày chi tiết trong tiểu mục 2.1, cả mô phỏng và thực tế các thí nghiệm lỗi được thực hiện để có được các tập dữ liệu mô phỏng và thực tế để xác thực phương pháp phát hiện và chẩn đoán lỗi dựa trên ResNet được đề xuất (FDD). Cụ thể, như được mô tả trong tiểu mục 2.2, có bốn loại và tám trường hợp lỗi được nghiên cứu trong bài báo này, bao gồm đổ bóng một phần (Shading1, Shading 2 và Shading 3), suy thoái PVS (Suy thoái 1), suy thoái PVA (Suy thoái 2), ngắn mạch (Ngắn mạch 1 và Ngắn mạch 2) và Mạch hở. Đầu tiên, các lỗi





Hình 13. Biểu đồ radar độ chính xác và đường cong ROC của ba mô hình trên tập dữ liệu mô phỏng.




Hình 14. Ma trận nhầm lẫn của ResNet trên tập dữ liệu mô phỏng.

Bảng 10

So sánh thống kê độ chính xác phân loại trung bình trên dữ liệu mô phỏng mức độ.

Thuật toán	Sự chính xác (%)	Phân tích thống kê trong 20 lần chạy ngẫu nhiên			
		Tối đa	Tối thiểu	Nghĩa là	Tỷ lệ
CAE	Bộ đào tạo	98.333	83.870	94.257	0,042
	Bộ thử nghiệm	98.092	93.314	94.395	0,044
CNN	Bộ đào tạo	99.943	99.009	99,696	0,003
	Bộ thử nghiệm	99,960	98.529	99,672	0,004
Mạng lưới ResNet	Bộ đào tạo	100,00	99,735	99,955	0,001
	Bộ thử nghiệm	100,00	99,642	99,940	0,001

các thí nghiệm được thực hiện trên mảng PV trong nhiều điều kiện môi trường khác nhau để thu được dữ liệu đường cong IV thông qua máy kiểm tra IV. Thứ hai, dữ liệu đường cong IV phù hợp với các điều kiện môi trường được xử lý trước để xây dựng tập dữ liệu, như được trình bày chi tiết trong tiểu mục 3.2. Cuối cùng, dựa trên các tập dữ liệu mô phỏng và thực tế, mô hình FDD dựa trên ResNet được đề xuất là được đào tạo, thử nghiệm và so sánh với hai thuật toán học sâu khác



Hình 15. So sánh đường cong mất mát của mô hình ResNet và CNN trên tập dữ liệu mô phỏng.

dựa trên các mô hình FDD, sau đó thảo luận về kết quả.

Ngoài ra, trong nghiên cứu này, mô hình ResNet được đề xuất được thực hiện sử dụng Pytorch toolkit và tập lệnh Python, và các thuật toán học sâu được chạy trong môi trường Pycharm trên máy tính để bàn với

cấu hình: CPU Inter (R) Core (TM) i5-4430S @ 2,7 GHz, 16 GB (RAM), 2G GTX750Ti (GPU) và hoạt động Ubuntu 16.04 64bit hệ thống.

4.1. Thí nghiệm mô phỏng và phân tích kết quả


Trước khi tiến hành các thí nghiệm lỗi thực tế trên PV phòng thí nghiệm mảng, các thí nghiệm lỗi mô phỏng được thực hiện để xác minh mô hình FDD dựa trên ResNet được đề xuất, như được trình bày chi tiết trong tiểu mục 2.2. Để thực hiện mô hình FDD tổng quát hơn cho các điều kiện môi trường khác nhau, lỗi các thí nghiệm được thực hiện dưới một phạm vi rộng của các bức xạ khác nhau và nhiệt độ để có được các mẫu dữ liệu tương ứng. Cụ thể, độ rọi được kiểm soát trong phạm vi từ 50 W/m2 đến 1000 W/m2 với một bước nhỏ 10 W/m2, và nhiệt độ được cấu hình để thay đổi từ 10 °C đến 70 °C với bước nhỏ là 2 °C. Do đó, có 2976 dữ liệu mẫu cho mọi trường hợp lỗi cũng như trạng thái bình thường, và do đó có tổng cộng 26.784 mẫu dữ liệu trong toàn bộ tập dữ liệu. Sau khi dễ dàng từ một số mẫu dữ liệu bắt đầu do môi trường mô phỏng gây ra, số lượng mẫu dữ liệu mô phỏng hiệu quả là 25237 và số lượng chi tiết của các mẫu dữ liệu cho mỗi trạng thái là

được đưa ra trong Bảng 8.


Để đào tạo và đánh giá FDD dựa trên ResNet được đề xuất



(a) Mảng PV quy mô nhỏ trong phòng thí nghiệm



(b) Cảm biến bức xạ và nhiệt độ không dây



(c) Máy thử IV PROVA1011

Hình 16. Mảng PV trong phòng thí nghiệm và máy kiểm tra PROVA1011 IV.


mô hình, các mẫu dữ liệu cùng loại trong tập dữ liệu được chia ngẫu nhiên thành ba tập con, bao gồm tập huấn luyện với 70% mẫu dữ liệu, tập xác thực giữ lại với 10% tập huấn luyện và tập kiểm tra với 30% mẫu dữ liệu còn lại. Số lượng mẫu dữ liệu cho ba tập con được tóm tắt trong Bảng 8. Cả tập huấn luyện và xác thực giữ lại đều được sử dụng để huấn luyện và xây dựng mô hình FDD dựa trên ResNet, trong khi tập kiểm tra được coi là dữ liệu mới chưa biết để sử dụng để đánh giá hiệu suất tổng quát hóa của mô hình FDD đã thiết lập.

Để đánh giá thêm lợi thế của phương pháp FDD dựa trên ResNet được đề xuất, hai cấu trúc học sâu khác thường được sử dụng để so sánh, bao gồm mạng nơ-ron tích chập được nối đầy đủ (CNN) và bộ mã hóa tự động tích chập (CAE). Để so sánh công bằng, các mô hình CNN và CAE được đào tạo và kiểm tra theo cùng một cách như mô hình dựa trên ResNet được đề xuất. Cụ thể, cấu trúc CNN được thiết kế với 8 lớp tích chập được kết nối đầy đủ, hai lớp max-polling và một bộ phân loại tuyến tính, và cấu trúc CAE bao gồm bốn lớp tích chập, bốn lớp khử tích chập và một bộ phân loại tuyến tính. Cả hai mô hình CNN và CAE đều được đào tạo, sử dụng cùng một thuật toán đào tạo Adam như minh họa trong Hình 10 và cùng các siêu tham số như được liệt kê trong Bảng 7.


Kết quả đào tạo và thử nghiệm cho các mô hình FDD dựa trên CAE, CNN và ResNet trên tập dữ liệu mô phỏng được đưa ra trong Bảng 9, trong đó các kết quả tốt nhất được đánh dấu bằng chữ in đậm. Ngoài ra, biểu đồ radar và Bộ thu

Đường cong đặc tính hoạt động (ROC) được vẽ trong Hình 12 để minh họa kết quả so sánh độ chính xác thử nghiệm cụ thể và tổng thể của ba mô hình FDD khác nhau. Từ Bảng 9 và Hình 13, có thể chứng minh rằng mô hình FDD dựa trên ResNet được đề xuất đạt được độ chính xác đào tạo và thử nghiệm cao nhất trong mọi trường hợp. Mô hình FDD dựa trên ResNet được đề xuất đạt được độ chính xác đào tạo hoàn hảo lên đến 100% và độ chính xác thử nghiệm gần lên đến 100% ngoại trừ trường hợp Suy thoái 1. So với mô hình dựa trên ResNet, mặc dù cả hai mô hình CNN và CAE đều đạt được độ chính xác đào tạo và thử nghiệm lên đến 100% trong trường hợp Bóng mờ 2 và Ngắn mạch 1, nhưng độ chính xác không đủ cao trong các trường hợp lỗi khác. Ví dụ, độ chính xác khi huấn luyện và kiểm tra của mô hình CNN lần lượt là 92,37% và 92,39% trong trường hợp của Shading 3, và độ chính xác khi huấn luyện và kiểm tra của mô hình CNN chỉ lần lượt là 59,57% và 61,39% trong trường hợp lỗi mạch hở. Để phân tích sâu hơn hiệu suất của mô hình FDD dựa trên ResNet được đề xuất, ma trận nhầm lẫn phân loại cho bộ kiểm tra được biểu diễn trong Hình 14 để trực quan hóa không chỉ độ chính xác của bộ phân loại mà còn cả các loại lỗi được chẩn đoán sai được dự đoán. Như có thể thấy trong Hình 14, chỉ có hai mẫu suy thoái PVS được mô phỏng bị chẩn đoán sai là lỗi Shading 3.


Để kiểm tra và so sánh độ tin cậy, các mô hình FDD dựa trên học sâu được đề xuất được đào tạo và thử nghiệm độc lập trong 20 lần. Sau đó, phân tích thống kê được thực hiện trên độ chính xác trung bình của FDD




(a) Mô phỏng lỗi mạch hở



(b) Mô phỏng các lỗi suy thoái



(c) Mô phỏng bóng râm một phần



(d) Mô phỏng lỗi ngắn mạch

Hình 17. Thiết lập thử nghiệm để mô phỏng lỗi trên mảng PV thực tế.

các mô hình và kết quả được liệt kê trong Bảng 10, trong đó Max biểu thị tối đa, Min biểu thị tối thiểu, Std biểu thị độ lệch chuẩn, và kết quả tốt nhất được in đậm. Đặc biệt, Std có thể được sử dụng như một tiêu chí để đánh giá tính ổn định của các mô hình. Rõ ràng, ResNet được đề xuất đã đạt được kết quả tốt nhất trong cả hai tập dữ liệu. Cụ thể, đã được xác thực rằng ResNet có hiệu suất tổng quát hóa và độ chính xác cao nhất được chỉ ra bởi giá trị trung bình cao nhất độ chính xác trong cả hai bộ đào tạo và thử nghiệm (99,955% và 99,94% tương ứng). Về mặt tính ổn định, ResNet được đề xuất có

độ lệch chuẩn chỉ 0,001 trong số 20 lần chạy độc lập, đó là thấp hơn nhiều so với CNN (0,003 cho tập huấn luyện và 0,004 cho bộ thử nghiệm) và CAE (0,042 cho bộ huấn luyện và 0,044 cho bộ thử nghiệm). Từ các kết quả đã đề cập ở trên, có thể thấy rằng hiệu suất của mô hình ResNet được đề xuất tốt hơn một chút so với CNN. mô hình, trong khi cả hai đều tốt hơn nhiều so với mô hình CAE trên tập dữ liệu mô phỏng.

Để xác minh thêm hiệu quả đào tạo, sự hội tụ của hàm mất mát của các mô hình FDD dựa trên ResNet và CNN trong quá trình



Bảng 11  
Phân bố mẫu dữ liệu thực nghiệm.

Các loại lỗi	Loại	Số lượng mẫu		
		Bộ huấn luyện	Hold-out	Xác thực Bộ kiểm tra
Bình thường	1	403	47	191
Bóng đổ 1	2	297	34	142
Bóng đổ 2	3	79	9	39
Bóng đổ 3	4	92	10	44
Sự suy thoái 1 5		177	20	85
Sự suy thoái 2 6		226	26	109
Chập mạch 1 7		196	22	94
Chập mạch 2 8		171	20	83
Mạch hở	9	229	27	110
Hoàn toàn		1870	215	897

đào tạo được kiểm tra và so sánh thêm. Trong Hình 15, các đường cong hội tụ của hàm mất mát của hai mô hình trong quá trình đào tạo là so sánh, từ đó có thể thấy rõ ràng rằng mô hình ResNet được đề xuất hội tụ nhanh hơn nhiều so với mô hình CNN và sự hội tụ cuối cùng sự mất mát của mô hình ResNet thấp hơn nhiều so với mô hình CNN vì tốt. Do đó, mô hình FDD dựa trên ResNet được xác nhận là tốt hơn hơn mô hình dựa trên CNN về mặt hiệu quả đào tạo.

4.2. Thí nghiệm thực tế và phân tích kết quả

Để xác minh thêm tính khả thi và hiệu suất của đề xuất phương pháp FDD dựa trên ResNet trong các ứng dụng thực tế, một số lỗi thực tế các thí nghiệm được thực hiện trên mảng PV thực tế bao gồm mười tám mô-đun PV silicon đơn tinh thể GL-100 với công suất đỉnh là 18 kW. Như minh họa trong Hình 16(a), mảng PV phòng thí nghiệm bao gồm ba chuỗi PV được kết nối song song với sáu mô-đun PV nối tiếp, được đánh dấu bằng khung màu đỏ. Để đo các đường cong đặc tính IV đầu ra của mảng PV và các điều kiện môi trường tự động ứng, máy thử IV tự động mại (Model: PROVA101) được sử dụng trong thí nghiệm, được sản xuất bởi TES Electrical Electronic Crop. Như đã trình bày trong Hình 16(b) và (c), máy thử IV bao gồm một máy thử IV chính và một cảm biến không dây với giao tiếp Bluetooth. Cảm biến không dây là được lắp trên cùng một mặt phẳng với mô-đun PV để đo sự cố độ rọi và nhiệt độ mặt sau của mô-đun PV, như thể hiện trong Hình 16(b). Máy kiểm tra IV chính có thể di chuyển được và có thể đặt ở những nơi thuận tiện, như thể hiện trong Hình 16(c). Máy kiểm tra IV có thể được cấu hình để tự động đo các đường cong IV đầu ra và tự động ứng điều kiện môi trường của mảng PV trong một khoảng thời gian xác định, tạo điều kiện thuận lợi rất nhiều cho các thí nghiệm lỗi.

Các phương pháp mô phỏng lỗi cho mảng PV thực tế được minh họa trong Hình 17, giống như các mô hình lỗi dựa trên Simulink cho mảng PV, như được trình bày chi tiết trong tiểu mục 2.2. Cụ thể, mạch hở lỗi chỉ được mô phỏng bằng cách ngắt kết nối một mô-đun PV trong chuỗi PV như thể hiện trong Hình 17(a). Lỗi suy thoái 1 được mô phỏng bằng cách thêm điện trở công suất cao 3 Ω nối tiếp với chuỗi PV như thể hiện trong

Bảng 12  
So sánh độ chính xác phân loại trên tập dữ liệu thực nghiệm.


Mục	CNN		CAE		Mạng tự do ResNet	
	Độ chính xác đào tạo (%)	Độ chính xác thử nghiệm (%)	Độ chính xác đào tạo (%)	Độ chính xác thử nghiệm (%)	Độ chính xác đào tạo (%)	Độ chính xác thử nghiệm (%)
Bình thường	95,04	93,19	90,82	86,91	100.0	100.0
Bóng đổ 1	98,68	99,30	95,29	96,48	100.0	100.0
Bóng đổ 2	24.05	15,38	58,23	48,72	100.0	92,31
Bóng đổ 3	95,65	81,82	100.0	100.0	99,95	97,73
Sự suy thoái 1	94,92	91,76	50,28	51,76	100.0	95,29
Sự suy thoái 2	99,56	96,33	87,17	88,99	100.0	96,33
Chập mạch 1	90,82	92,55	72,96	67.02	99,49	100.0
Chập mạch 2	100.0	98,80	93,57	93,98	100.0	100.0
Mạch hở	100.0	100.0	93.01	90,00	100.0	95,45

Hình 17(b). Tự động tự như vậy, lỗi suy thoái 2 được mô phỏng bằng cách chèn cùng một điện trở công suất cao nối tiếp với đầu ra của mảng PV. Lỗi Shading1 được mô phỏng bằng cách phủ một mô-đun PV bằng acrylic bằng, như thể hiện trong Hình 17(c). Tự động ứng, Shading2 và Các lỗi Shading3 được mô phỏng với 2 và 3 mô-đun PV được che bóng tự động ứng. Như thể hiện trong Hình 17(d), lỗi Short Circuit 1 được mô phỏng bằng cách ngắn mạch một mô-đun PV trong chuỗi PV. Ngắn mạch 2 là được mô phỏng bằng cách nối tắt 2 mô-đun PV trong một chuỗi. Các thí nghiệm lỗi đã được thực hiện với các điều đã nói ở trên cấu hình trong một số ngày liên tiếp. Mỗi chuỗi hợp của thí nghiệm lỗi được thực hiện trong một ngày để bao phủ một môi trường xung quanh tự động đối lớn điều kiện. Do điều kiện môi trường không thể kiểm soát và hạn chế của máy kiểm tra IV (cần gần nửa phút để quét một IV), một số đường cong IV bắt đầu không liên quan đến lỗi sẽ bị loại khỏi tập dữ liệu. Sau khi loại trừ các đường cong IV bắt đầu, chỉ còn khoảng 3000 tổng số mẫu dữ liệu thử nghiệm hiệu quả được thu thập. So với tập dữ liệu mô phỏng, chất lượng và số lượng các mẫu dữ liệu trong tập dữ liệu thực tế thấp hơn nhiều, điều này đặt ra thách thức lớn cho FDD mô hình. 70% tổng số mẫu dữ liệu của mỗi điều kiện hoạt động là được chọn ngẫu nhiên làm tập huấn luyện và 30% mẫu còn lại là được sử dụng để thử nghiệm. Phân phối cụ thể của các mẫu dữ liệu thực được trình bày chi tiết trong Bảng 11. Có thể thấy rằng số lượng mẫu dữ liệu cho chín chuỗi hợp điều kiện hoạt động không giống nhau, điều này có thể gây ra giảm hiệu suất trên các mô hình FDD được đào tạo.


Tự động tự như nghiên cứu mô phỏng, ba phương pháp học sâu khác nhau các mô hình, bao gồm CNN, CAE và ResNet, được đào tạo, thử nghiệm và so sánh trên cùng một tập dữ liệu thử nghiệm. Việc đào tạo và thử nghiệm kết quả của ba mô hình được liệt kê trong Bảng 12, trong đó giá trị cao nhất độ chính xác được đánh dấu bằng chữ in đậm, và biểu đồ radar và đường cong ROC của độ chính xác được biểu thị trong Hình 18. Nó có thể được quan sát trong Bảng 12 và Hình 18 cho thấy mô hình ResNet được đề xuất đạt hiệu suất tốt nhất về cả độ chính xác đào tạo và độ chính xác thử nghiệm đối với hầu hết các trường hợp (trừ độ chính xác thử nghiệm của Shading 3 và Open Lỗi mạch). Hơn nữa, mô hình ResNet được đề xuất đạt được rất độ chính xác cao trong đào tạo và thử nghiệm cho tất cả các trường hợp (tất cả các độ chính xác cao hơn 92,31%, phần lớn độ chính xác lên tới 100%) và nó tốt hơn nhiều so với hai mô hình kia hoạt động kém ở một số các trường hợp, chẳng hạn như Shading 2 và Degradation 1. Do đó, so với kết quả của thí nghiệm mô phỏng, mô hình ResNet FDD được đề xuất đạt được hiệu suất rất cạnh tranh.

Để phân tích kết quả phân loại chi tiết của bộ thử nghiệm, ma trận nhầm lẫn mô hình ResNet được đề xuất được biểu diễn trong Hình 19, từ trong đó có thể quan sát được phân loại đúng và sai trung bình tỷ lệ của mô hình phát hiện lỗi được đề xuất lên tới 98,1% và 1,9% tự động ứng. Các loại lỗi chẩn đoán sai chính là Shading 2, Bóng đổ 3, Suy giảm 1, Suy giảm 2 và Mạch hở.

Để kiểm tra và so sánh độ tin cậy, ba mô hình FDD được đào tạo và kiểm tra độc lập 20 lần. Tự động tự như nghiên cứu mô phỏng, Bảng 13 liệt kê kết quả thống kê của giá trị trung bình chung đào tạo và kiểm tra độ chính xác của ba mô hình trong 20 ngẫu nhiên chạy, trong đó kết quả tốt nhất cũn được đánh dấu đậm. Trong



Hình 18. So sánh độ chính xác giữa ba mô hình trên cùng một tập dữ liệu thực.



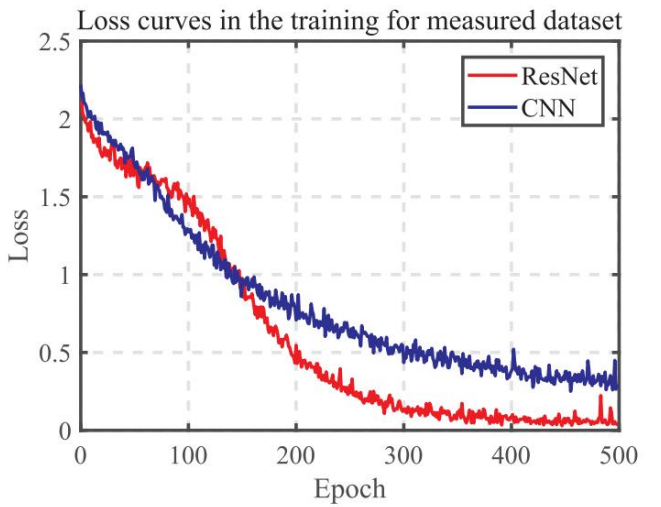
Hình 19. Ma trận nhầm lẫn của độ chính xác thử nghiệm của mô hình ResNet trên tập dữ liệu thực tế.

Bảng 13

So sánh thống kê độ chính xác phân loại trung bình trên tập dữ liệu thực.

Độ chính xác của thuật toán (%)		Phân tích thống kê độ chính xác trong 20 lần chạy ngẫu nhiên			
		Tối đa	Tối thiểu	Nghĩa là	Tầm chuẩn
CAE	Bộ đào tạo	74.866	40.963	58.964	0,121
	Bộ thử nghiệm	73.244	37.124	56.452	0,130
CNN	Bộ đào tạo	96.898	65.829	86.431	0,115
	Bộ thử nghiệm	95.318	61.204	83.431	0,115
Mạng tự động học	Bộ huấn luyện	99.947	91.497	98.463	0,029
	Bộ kiểm tra	98.774	88.852	95.778	0,036

Bảng 13. Có thể thấy rằng mô hình FDD dựa trên ResNet đạt được kết quả tốt nhất về tất cả các biến thống kê, so với các mô hình FDD dựa trên CNN và CAE. Cụ thể, giá trị trung bình thống kê độ chính xác trung bình của quá trình đào tạo và thử nghiệm của mô hình ResNet được đề xuất là



Hình 20. So sánh dự đoán mất mát của mô hình ResNet và CNN trên tập dữ liệu thực.

cao tới 98,463% và 95,778%. Đặc biệt, độ lệch chuẩn của ResNet thấp tới 0,029 và 0,036 đối với bộ đào tạo và bộ thử nghiệm tương ứng và thấp hơn nhiều so với CNN và CAE, trong đó xác nhận rằng mô hình FDD dựa trên ResNet được đề xuất có tính năng cao nhất độ tin cậy trong tập dữ liệu thực tế. Ngoài ra, bằng cách so sánh các kết quả trong Bảng 13 và 10, rõ ràng là độ chính xác thống kê của mô hình ResNet được đề xuất trên tập dữ liệu thực tế rất cạnh tranh với mô hình trên cũ như tập dữ liệu mô phỏng.

Để kiểm chứng và so sánh hiệu quả đào tạo giữa hai phương pháp tốt nhất các mô hình (ResNet và CNN), các dự đoán hội tụ của hàm mất mát trong quá trình đào tạo được biểu diễn trong Hình 20. Có thể quan sát thấy rằng Mô hình ResNet hội tụ nhanh hơn nhiều so với mô hình CNN, đặc biệt là tại kết thúc quá trình đào tạo và cuối cùng đạt đến giá trị tổn thất thấp hơn nhiều. Do đó, mô hình ResNet được xác nhận là hiệu quả hơn. Mô hình CNN một lần nữa xét về hiệu quả đào tạo trên tập dữ liệu thực.

4.3. Thảo luận về ưu điểm và hạn chế

Phần phụ này chủ yếu thảo luận về ưu điểm và hạn chế của phương pháp đề xuất so sánh với ngưỡng chung dựa trên FDD phương pháp. Theo quan điểm dữ liệu, FDD dựa trên ResNet được đề xuất phương pháp dựa trên các dự đoán IV tĩnh và nhiệt độ và cường độ bức xạ xung quanh tương ứng để thực hiện phát hiện chính xác và tốt và chẩn đoán các lỗi sớm phổ biến của một mảng PV, trong khi hầu hết ngưỡng phương pháp dựa trên dữ liệu thời gian thực của các điểm vận hành động.



Rõ ràng, toàn bộ đường cong IV chứa thông tin đầy đủ hơn nhiều so với điểm dữ liệu đơn lẻ, từ đó có thể phát hiện và phân biệt trạng thái lỗi tốt hơn. Ngoài ra, các điểm động thường được coi là các điểm công suất cực đại (MPP), thường không phải là trường hợp thực tế. Trên thực tế, các điểm vận hành bị ảnh hưởng bởi các thuật toán MPPT động và dao động xung quanh các điểm MPP thực được xác định bởi điều kiện môi trường thay đổi. Do đó, chúng tôi cho rằng đường cong IV sẽ chính xác và đáng tin cậy hơn. Tuy nhiên, các đường cong IV khó có thể được lấy trực tuyến bằng các bộ biến tần thông thường, ngay cả khi một số bộ biến tần thông thường có khả năng.

Do đó, phương pháp đề xuất phù hợp hơn với FDD ngoại tuyến của mảng PV sử dụng máy kiểm tra đường cong IV. Thay vào đó, các phương pháp FDD dựa trên ngưỡng thông thường đơn giản, hiệu quả và phù hợp với hoạt động trực tuyến. Theo quan điểm thuật toán, là một loại phương pháp dựa trên máy học, phương pháp được đề xuất sẽ yêu cầu một tập dữ liệu được xác định trước để đào tạo và thiết lập mô hình FDD. Do đó, phương pháp được đề xuất sẽ cần đến nỗ lực tốn kém của con người để thu thập các mẫu dữ liệu về lỗi, nhưng nó có thể xây dựng mô hình FDD chính xác từ tập dữ liệu một cách tự động và khách quan. Thay vào đó, các phương pháp FDD dựa trên ngưỡng thông thường dựa vào việc phân tích và trích xuất nghiêm ngặt các chỉ báo lỗi cũ như ngưỡng và xác định thủ công quy trình FDD, phụ thuộc vào chuyên gia và có thể bị hạn chế về độ chính xác và hiệu suất tổng quát hóa. Về mặt độ phức tạp của tính toán, mặc dù phương pháp FDD dựa trên ResNet được đề xuất yêu cầu tính toán phức tạp để xây dựng mô hình FDD, nhưng nó có thể được triển khai và chạy hiệu quả trên các nền tảng nhúng công suất thấp thông thường, vì chúng có đủ tài nguyên tính toán. Ngược lại, các phương pháp FDD dựa trên ngưỡng rất đơn giản, do đó chúng có thể chạy trên các nền tảng nhúng đơn giản hơn và rẻ hơn nhiều.

5. Kết luận

Trong nghiên cứu này, dựa trên các đường cong đặc trưng IV đầu ra và dữ liệu điều kiện môi trường đầu vào, một phương pháp phát hiện và chẩn đoán lỗi thông minh (FDD) dựa trên mạng sâu (ResNet) mới được đề xuất để phát hiện các loại và mức độ khác nhau của các lỗi phổ biến của mảng PV, bao gồm bóng râm một phần, suy thoái, ngắn mạch và lỗi mạch hở. Đầu tiên, các đường cong đặc trưng IV thô được đo của các điều kiện bình thường và lỗi được lấy mẫu xuống và kết hợp với độ rọi và nhiệt độ để tạo thành các mẫu dữ liệu hai chiều. Thứ hai, một cấu trúc ResNet mới được đề xuất là mô hình FDD, bao gồm các khối dự, các lớp tích chập, các lớp gộp trung bình và bộ phân loại tuyến tính. Cuối cùng, thuật toán học ước tính mômen thích ứng được sử dụng để đào tạo mô hình dựa trên ResNet bằng cách sử dụng các tập dữ liệu đã thu được.

Một mô hình mô phỏng dựa trên Simulink chính xác được thiết kế cho một mảng PV trong phòng thí nghiệm để xác minh mô hình FDD dựa trên ResNet được đề xuất, trên cơ sở đó các thí nghiệm mô phỏng và lỗi thực tế được thực hiện để thu được các mẫu dữ liệu lỗi mô phỏng và lỗi thực nghiệm thực tế trong nhiều điều kiện môi trường khác nhau. Cả kết quả mô phỏng và thí nghiệm thực tế đều xác nhận độ chính xác cao và hiệu suất tổng quát hóa của phương pháp được đề xuất. Trong trường hợp nghiên cứu mô phỏng, độ chính xác đào tạo và thử nghiệm trung bình của mô hình ResNet đã thiết lập trong 20 lần chạy ngẫu nhiên lần lượt lên tới 99,995% và 99,940%. Trong trường hợp nghiên cứu thực tế, độ chính xác đào tạo và thử nghiệm trung bình lần lượt là 98,463% và 95,778%, chỉ thấp hơn một chút so với độ chính xác của mô phỏng. Hơn nữa, độ lệch chuẩn của độ chính xác nằm trong khoảng 1E-3 cho trường hợp mô phỏng và 1E-2 cho trường hợp thực, điều này cũng xác nhận tính ổn định cao của mô hình ResNet.

Hai mô hình học sâu phổ biến khác được đào tạo bởi cùng một tập dữ liệu được sử dụng để so sánh nhằm xác thực lợi thế của mô hình dựa trên ResNet được đề xuất, bao gồm mạng neuron tích chập và bộ mã hóa tự động tích chập. Cả kết quả mô phỏng và so sánh thực nghiệm thực tế đều chứng minh rằng mô hình dựa trên ResNet được đề xuất đạt được hiệu suất tổng thể tốt nhất về độ chính xác, hiệu suất tổng quát hóa, tính ổn định và hiệu quả đào tạo.

Phương pháp FDD dựa trên ResNet được đề xuất hứa hẹn sẽ được tích hợp vào các hệ thống thử nghiệm IV cho các mảng PV và bộ biến tần PV với

Khả năng quét đường cong IV để phát hiện và chẩn đoán lỗi hiệu quả và tự động.

Tuyên bố về lợi ích cạnh tranh

Các tác giả tuyên bố rằng họ không có bất kỳ mối quan hệ cá nhân hoặc lợi ích tài chính cạnh tranh nào có thể ảnh hưởng đến công trình được báo cáo trong bài báo này.

Lời cảm ơn

Các tác giả xin chân thành cảm ơn sự hỗ trợ tài chính một phần từ Quỹ Khoa học Tự nhiên Quốc gia Trung Quốc (Số tài trợ: 61601127 và 61574038), Sở Khoa học và Công nghệ Tỉnh Phúc Kiến Trung Quốc (Số tài trợ: 2019H0006 và 2018J01774) và Quỹ Sở Công nghiệp và Công nghệ Thông tin Tỉnh Phúc Kiến Trung Quốc (Số tài trợ: 82318075).

Tài liệu tham khảo

[1] I. Puvps, TỔNG QUAN VỀ THỊ TRƯỜNG PIN QUANG ĐIỆN TOÀN CẦU NĂM 2018;.

[2] Madeti SR, Singh S. Một nghiên cứu toàn diện về các loại lỗi khác nhau và các kỹ thuật phát hiện cho hệ thống quang điện mặt trời. Sol Energy 2017;158:161-85.

[3] Pillai DS, Prasanth Ram J, Rajasekar N, Mahmud A, Yang Y, Blaabjerg F. Phân tích mở rộng và lỗi đường dây đường dây và lỗi đường dây-đất trong mảng PV và nghiên cứu khả năng tư duy thích với các tiêu chuẩn bảo vệ NEC mỗi nhất. Energy Convers Manage 2019. X, trang 100009, 23/04/2019.

[4] Silvestre S, Kichou S, Chouder A, Nofuentes G, Karatepe E. Phân tích các chỉ số dòng điện và điện áp trong các hệ thống PV (quang điện) dự trữ kết nối lưới hoạt động trong điều kiện bóng râm một phần và lỗi. Năng lượng 2015;86:42-50.

[5] Dhoke A, Sharma R, Saha TK. Phân tích sự suy giảm mô-đun PV và tác động đến cài đặt của các thiết bị bảo vệ quá dòng. Sol Energy 2018;160:360-7.

[6] Akram MN, Lotfifard S. Mô hình hóa và theo dõi sức khỏe của phía DC của quang điện mảng. IEEE Trans Năng lượng bền vững 2015;6(4):1245-53.

[7] Xiong Q, et al. Phát hiện và định vị lỗi quang trong hệ thống quang điện bằng cách sử dụng bản đồ phân bố đặc điểm của dòng điện tự điện song song. IEEE J Photovoltaics 2018;8(4):1090-7.

[8] Bressan M, Gutierrez A, Garcia Gutierrez L, Alonso C. Phát triển biện pháp phòng ngừa điểm nóng thời gian thực bằng cách sử dụng trình mô phỏng hệ thống PV dự trữ cho bóng một phần. Năng lượng tái tạo 2018;127:334-43.

[9] Barbato M, Barbato A, Meneghini M, Tavernaro G, Rossetto M, Meneghesso G. Sự suy thoái tiềm ẩn do cảm ứng của các tế bào quang điện silicon hai mặt loại N: một cuộc điều tra dựa trên các phép đo điện và quang. Sol Energy Mater Sol Cells 2017;168:51-61.

[10] Dhimish M, Holmes V, Mather P. Công nghệ phát hiện vết nứt nhỏ quang điện monique. IEEE Trans Device Mater Reliab 2019.

[11] Alam MK, Khan F, Johnson J, Flicker J. Một đánh giá toàn diện về thăm dò lỗi trong mảng PV: Các loại, phát hiện và kỹ thuật giảm thiểu. IEEE J Photovoltaics 2015;5(3):982-97.

[12] Mellit A, Tina G, Kalogirou S. Phương pháp phát hiện và chẩn đoán lỗi cho hệ thống quang điện: một bản đánh giá. Renew Sustain Energy Rev 2018;91:1-17.

[13] Triki-Lahiani A, Bennani-Ben Abdelghani A, Slama-Belkhdja I. Hệ thống phát hiện và giám sát lỗi cho các hệ thống lắp đặt quang điện: một bản đánh giá. Renew Sustain Energy Rev 2018;82. tr. 2680-2692, 2018/02/01.

[14] Gallardo-Saavedra S, Hernández-Callejo L, Duque-Perez O. Đánh giá công nghệ về thiết bị đo đặc được sử dụng trong quá trình kiểm tra nhiệt độ trong không gian của các nhà máy quang điện. Tài tạo và duy trì năng lượng Rev 2018;93:566-79.

[15] Bedrich KG, et al. Phân tích hình ảnh phát quang điện định lượng để thực hiện ước tính hiệu suất của các mô-đun PV chịu ảnh hưởng của PID. IEEE J Photovoltaics 2018;8(5):1281-8.

[16] Takashima T, Yamaguchi J, Ishida M. Phát hiện ngắt kết nối bằng cách đo điện dung đất trong chuỗi mô-đun quang điện. Prog Photovoltaics Res Appl 2008;16(8):669-77.

[17] Roy S, Alam MK, Khan F, Johnson J, Flicker J. Một sơ đồ phát hiện lỗi tiếp đất mạnh mẽ, độc lập với bức xạ cho các mảng PV dựa trên phép đo phản xạ miễn thời gian phổ trải rộng (SSTDR). IEEE Trans Power Electron 2017.

[18] Yi Z, Etemadi A. Phát hiện lỗi từng dòng cho các mảng quang điện dựa trên phân tích tín hiệu đa độ phân giải và máy vector hỗ trợ hai giai đoạn. IEEE Trans Ind Electron 2017.

[19] Takashima T, Yamaguchi J, Otani K, Oozeki T, Kato K, Ishida M. Nghiên cứu thực nghiệm về vị trí lỗi trong chuỗi mô-đun PV. Sol Energy Mater Sol Cells 2009;93(6-7):1079-82.

[20] Pillai DS, Blaabjerg F, Rajasekar N. Đánh giá so sánh các phương pháp phát hiện lỗi tiên tiến cho hệ thống PV. IEEE J Photovolt 2019.

[21] Chen Z, et al. Chẩn đoán lỗi thông minh dựa trên rừng ngẫu nhiên cho các mảng PV sử dụng điện áp mảng và dòng điện chuỗi. Energy Convers Manage 2018;178:250-64.

[22] Tadj M, Benmouiza K, Chekneane A, Silvestre S. Cải thiện hiệu suất của hệ thống PV bằng cách phát hiện lỗi bằng cách sử dụng phương pháp GISTEL. Energy Convers Manage 2014;80(80):298-304.

[23] Silvestre S, Silva MAD, Chouder A, Guasch D, Karatepe E. Quy trình mới cho các lỗi

Z. Chen và cộng sự

phát hiện trong các hệ thống PV được kết nối lưu trữ điện dựa trên việc đánh giá các chỉ số dòng điện và điện áp. Energy Convers Manage 2014;86:241-9.

[24] Saleh KA, Hooshyar A, El-Saadany EF, Zeineldin HH. Bảo vệ dựa trên điện áp sơ đồ cho các lỗi trong mạng quang điện quy mô tiện ích. IEEE Trans Smart Grid 2017.

[25] Gokmen N, Karatepe E, Silvestre S, Celik B, Ortega P. Một phương pháp chẩn đoán lỗi hiệu quả cho hệ thống PV dựa trên các số điện áp hoạt động. Energy Convers Manage 2013;73:350-60.

[26] Khoshnami A, Sadeghkhani I. Sơ đồ phát hiện lỗi dựa trên công suất hai giai đoạn cho hệ thống quang điện. Sol Energy 2018;176:10-21. 2018/12/01/.

[27] Chaibi Y, Malvoni M, Chouder A, Boussetta M, Salhi M. Ứng dụng đơn giản và hiệu quả phương pháp phát hiện và chẩn đoán lỗi điện và che bóng một phần trong hệ thống quang điện. Energy Convers Manage 2019;196:330-43.

[28] Madeti SR, Singh S. Thuật toán phát hiện lỗi cấp mô-đun trực tuyến cho hệ thống PV hòa lưới và ngoài lưới. Sol Energy 2017;157:349-64.

[29] Dhimish M, Holmes V, Mehrdadi B, Dales M, Chong B, Zhang L. Biến thể bài báo chỉ số cho nhiều cấu hình mảng PV trong điều kiện che bóng một phần và PV lỗi. Năng lượng tái tạo 2017;113:438-60.

[30] Wang W, Liu A, Chung H, Lau RW. Chẩn đoán lỗi của tấm pin quang điện bằng cách sử dụng đặc tính dòng điện-điện áp động. IEEE Trans Power Electron 2016;31(2):1.

[31] Bressan M, El Basri Y, Galeano A, Alonso C. Một phương pháp phát hiện lỗi bóng dựa trên phân tích lỗi chuẩn của dự ứng công IV. Năng lượng tái tạo 2016;99:1181-90.

[32] Garoudja E, Harrou F, Sun Y, Kara K, Chouder A, Silvestre S. Phát hiện lỗi thống kê trong hệ thống quang điện. Sol Energy 2017;150:485-99.

[33] Harrou F, Taghezouit B, Sun Y. Chiến lược mạnh mẽ và linh hoạt để phát hiện lỗi trong các hệ thống quang điện được kết nối với lưu trữ điện. Energy Convers Manage 2019;180. tr. 1153-1166, 15/01/2019/.

[34] Dhimish M, Holmes V, Dales M. Thuật toán phát hiện lỗi song song cho các nhà máy quang điện được kết nối với lưu trữ điện. Năng lượng tái tạo 2017;113:94-111.

[35] Chen L, Wang X. Định vị lỗi thích ứng trong hệ thống quang điện. IEEE Trans 2018;8(1):257-65.

[36] Kumar BP, Ilango GS, Reddy MJB, Chilakapati N. Phát hiện và chẩn đoán lỗi trực tuyến trong hệ thống quang điện bằng cách sử dụng các gói sóng nhỏ. IEEE J Photovoltaics 2018;8(1):257-65.

[37] Kang BK, Kim ST, Bae SH, Park JW. Chẩn đoán công suất đầu ra giảm trong một mảng PV bằng cách sử dụng thuật toán lọc Kalman. IEEE Trans Energy Convers 2012;27(4):885-94.

[38] Youssef A, El-Telbany M, Zekry A. Vai trò của trí tuệ nhân tạo trong thiết kế và kiểm soát hệ thống quang điện: một bản đánh giá. Renew Sustain Energy Rev 2017;78:72-9.

[39] Benkercha R, Moulahoum S. Phát hiện và chẩn đoán lỗi dựa trên thuật toán cây quyết định C4. 5 cho hệ thống PV được kết nối lưu trữ điện. Sol Energy 2018;173:610-34.

[40] Chine W, Mellit A, Lughii V, Malek A, Sulligoi G, Massi Pavan A. Một lỗi mới Kỹ thuật chẩn đoán hệ thống quang điện dựa trên mạng nơ-ron nhân tạo. Năng lượng tái tạo 2016;90:501-12.

[41] Jufri FH, Oh S, Jung J. Phát triển hệ thống phát hiện tình trạng bất thường của quang điện bằng cách sử dụng máy hồi quy kết hợp và máy vectơ hỗ trợ. Năng lượng 2019.

[42] Chen Z, Wu L, Cheng S, Lin P, Wu Y, Lin W. Chẩn đoán lỗi thông minh của mảng quang điện dựa trên máy học cực đại hạt nhân được tối ưu hóa và đặc điểm IV. Appl Energy 2017;204:912-31. 15/10/2017/.

[43] Garoudja E, Chouder A, Kara K, Silvestre S. Một phương pháp tiếp cận dựa trên máy học nâng cao để phát hiện và chẩn đoán lỗi của hệ thống PV. Energy Convers Manage 2017;151:496-513.

[44] Zhao Y, Ball R, Mosesian J, de Palma JF, Lehman B. Học bán giám sát dựa trên đồ thị để phát hiện và phân loại lỗi trong mảng quang điện mặt trời. IEEE Trans Power Electron 2015;30(5):2848-58.

[45] Lin P, Lin Y, Chen Z, Wu L, Chen L, Cheng S. Một phương pháp tiếp cận cụm dựa trên đỉnh mật độ để chẩn đoán lỗi của mảng quang điện. Int J Photoenergy 2017;2017.

[46] Liu G, Zhu L, Wu X, Wang J. Phân cụm chuỗi thời gian và ý nghĩa vật lý đối với hệ thống mảng quang điện có điều kiện làm việc chưa biết. Sol Energy 2019;180:401-11. 2019/03/01/.

[47] Zhu H, Lu L, Yao J, Dai S, Hu Y. Phương pháp chẩn đoán lỗi cho mảng quang điện dựa trên mô hình mạng nơ-ron xác suất và cụm mẫu không giám sát. Sol Energy 2018;176:395-405. 2018/12/01/.

[48] Liu S, Dong L, Liao X, Hao Y, Cao X, Wang X. Một phương pháp phân cụm dựa trên sự giãn nở và xói mòn để chẩn đoán lỗi của mảng quang điện. IEEE Sens J 2019.

[49] Yi Z, Etemadi AH. Phát hiện lỗi cho hệ thống quang điện dựa trên phân tích tín hiệu đa độ phân giải và hệ thống suy luận mờ. IEEE Trans Smart Grid 2017;8(3):1274-83.

[50] Dhimish M, Holmes V, Mehrdadi B, Dales M, Mather P. Thuật toán phát hiện lỗi quang điện dựa trên mô hình dự ứng công lý thuyết và hệ thống phân loại mờ. Năng lượng 2017;140:276-90.

[51] Liu S, Dong L, Liao X, Cao X, Wang X. Chẩn đoán lỗi mảng quang điện dựa trên thuật toán cụm C-means Gaussian Kernel Fuzzy. Cảm biến 2019;19(7):1520.

[52] Belaout A, Krim F, Mellit A, Talbi B, Arabi A. Đa lớp thích ứng thần kinh mờ kỹ thuật phân loại và lựa chọn tính năng để phát hiện và phân loại lỗi mảng quang điện. Renew Energy 2018;127:548-58. 2018/11/01/.

[53] Liu W, Wang Z, Liu X, Zeng N, Liu Y, Alsaadi FE. Một cuộc khảo sát về kiến trúc mạng nơ-ron sâu và các ứng dụng của chúng. Neurocomputing 2017;234:11-26.

[54] Schmidhuber J. Học sâu trong mạng nơ-ron: tổng quan. Mạng nơ-ron 2015;61:85-117.

[55] Khan S, Yairi T. Đánh giá về ứng dụng học sâu trong xử lý các hệ thống quản lý. Mech Syst Sig Process 2018;107:241-65.

[56] Wen L, Li X, Gao L, Zhang Y. Một phương pháp chẩn đoán lỗi dựa trên dữ liệu mạng nơ-ron tích chập mờ. IEEE Trans Ind Electron 2018;65(7):5990-8.

[57] Xu L, Cao M, Song B, Zhang J, Liu Y, Alsaadi FE. Chẩn đoán lỗi mạch hở của bộ chỉnh lưu điện bằng mạng nơ-ron sâu dựa trên bộ mã hóa tự động thứ a thớt. Máy tính thần kinh 2018;311:1-10.

[58] Shao H, Jiang H, Zhang H, Liang T. Chẩn đoán lỗi ổ trục dựa máy điện bằng mạng niềm tin sâu tích chập mờ. IEEE Trans Ind Electron 2018;65(3):2727-36.

[59] Li X, Yang Q, Lou Z, Yan W. Phân tích lỗi mô-đun dựa trên học sâu cho các trạng thái quang điện quy mô lớn. IEEE Trans Energy Convers 2019;34(1):520-9.

[60] Appiah AY, Zhang X, Ayawli BBK, Kyerekeh F. Mạng bộ nhớ dài hạn ngắn dựa trên trích xuất tính năng tự động để chẩn đoán lỗi mảng quang điện. IEEE Access 2019;7:30089-101.

[61] Rawat W, Wang Z. Mạng nơ-ron tích chập sâu để phân loại hình ảnh: một đánh giá toàn diện. Neural Comput 2017;29(9). tr. 2352-2449, 2017/09/01.

[62] He K, Zhang X, Ren S, Sun J Học sâu còn lại để nhận dạng hình ảnh. trình bày tại Hội nghị IEEE năm 2016 về Thị giác máy tính và Nhận dạng mẫu (CVPR), Las Vegas, NV, Hoa Kỳ; 2015.

[63] Zhao M, Kang M, Tang B, Pecht M. Mạng lưu trữ dự thừa sâu với động hệ số wavelet có trọng số để chẩn đoán lỗi hộp số hành tinh. IEEE Trans Ind Electron 2018;65(5):4290-300.

[64] Chen Z, Chen Y, Wu L, Cheng S, Lin P, You L. Mô hình hóa chính xác các mô-đun quang điện sử dụng mạng lưu trữ dự sâu 1-D dựa trên các đặc điểm IV. Energy Convers Manage 2019;186:168-87. 2019/04/15/.

[65] Chen Z, Wu L, Lin P, Wu Y, Cheng S. Xác định các tham số của mô hình quang điện bằng thuật toán đơn giản Nelder-Mead thích ứng lai dựa trên chiến lược đại bàng. Appl Energy 2016;182(2016):47-57.

[66] Abbassi R, Abbassi A, Jemli M, Chebbi S. Xác định các tham số chưa biết của mô hình pin mặt trời: tổng quan toàn diện về các phương pháp tiếp cận khả dụng. Renew Sustain Energy Rev 2018;90:453-74.

[67] Wu L, et al. Trích xuất tham số của các mô hình quang điện từ các dự ứng công đặc tính IV được đo bằng thuật toán phân xạ vùng tin cậy lai. Appl Energy 2018;232C:36-53.

[68] Fadhel S, et al. Phát hiện và phân loại lỗi che bóng PV dựa trên dự ứng công IV bằng cách sử dụng phân tích thành phần chính: ứng dụng cho hệ thống PV bị cỏ lấp. Sol Energy 2019;179:1-10.

[69] Ioffe S, Szegedy C. "Chuẩn hóa theo lô: Tăng tốc đào tạo mạng sâu bằng cách giảm sự dịch chuyển biến phụ thuộc nội bộ", trình bày tại Biên bản Hội nghị quốc tế lần thứ 32 về Hội nghị quốc tế về học máy - Tập 37, Lille, Pháp; 2015.

[70] Krizhevsky A, Sutskever I, Hinton GE, Phân loại ImageNet với Deep Mạng nơ-ron tích chập. Trong Hội nghị quốc tế về Hệ thống xử lý thông tin nơ-ron; 2012.

[71] Simonyan K, Zisserman A. Mạng tích chập rất sâu để nhận dạng hình ảnh quy mô lớn. Comput Sci 2014.

[72] DP Kingma J. Ba Adam: Một phương pháp tối ưu hóa ngẫu nhiên Comput Sci 2014.

[73] Glorot X, Bengio Y. Hiểu được khó khăn của việc đào tạo sâu về phía trước mạng lưu trữ nơ-ron. J Mach Learn Res 2010;9:249-56.