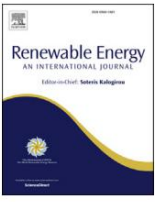


Danh sách nội dung có sẵn tại [ScienceDirect](#)

Năng lượng tái tạo

trang chủ tạp chí: www.elsevier.com/locate/renene



Phát hiện và định lượng lỗi trong hình ảnh phát quang điện của các mô-đun PV mặt trời bằng cách sử dụng phân đoạn ngữ nghĩa U-net



Lawrence Pratt a, b, ^{*}, Thống đốc Devashen [✉], Richard Klein ^b

^a CSIR, Đường Meiring Naude, Pretoria, Nam Phi
^b Khoa Khoa học Máy tính và Toán ứng dụng, Đại học Witwatersrand, Johannesburg, Nam Phi

thông tin bài viết

Lịch sử bài viết:
Nhận ngày 16 tháng 1 năm 2021
Đã nhận được dưới dạng đã sửa đổi
21 tháng 5 năm 2021
Đã chấp nhận ngày 19 tháng 6 năm 2021
Có sẵn trực tuyến ngày 25 tháng 6 năm 2021

Từ khóa:
Phát quang điện
PV
Mạng U
Phân đoạn ngữ nghĩa
Học máy

tóm tắt

Hình ảnh phát quang điện (EL) cho phép phát hiện khuyết tật trong các mô-đun quang điện mặt trời (PV) mà mắt thường không nhìn thấy được, tương tự như cách chụp X-quang giúp bác sĩ phát hiện các vết nứt và gãy xương. Sự phổ biến của nhiều khuyết tật, ví dụ như vết nứt nhỏ, vùng không hoạt động, khuyết tật lưới và khuyết tật vật liệu, trong mô-đun PV có thể được định lượng bằng hình ảnh EL. Các kỹ thuật học sâu hiện đại dành cho thị giác máy tính có thể được áp dụng để trích xuất thông tin hữu ích có trong hình ảnh trên toàn bộ lô mô-đun PV. Phát hiện và định lượng khuyết tật trong hình ảnh EL có thể cải thiện hiệu quả và độ tin cậy của mô-đun PV tại nhà máy bằng cách xác định các vấn đề tiềm ẩn trong quy trình và tại nhà máy PV bằng cách xác định và giảm số lượng mô-đun bị lỗi được lắp đặt. Trong công trình này, chúng tôi đào tạo và thử nghiệm một mô hình phân đoạn ngữ nghĩa dựa trên kiến trúc U-net để phân tích hình ảnh EL của các mô-đun PV được làm từ các tế bào quang điện dựa trên wafer silicon đơn tinh thể và đa tinh thể. Công trình này tập trung vào việc phát triển và thử nghiệm phương pháp học sâu cho thị giác máy tính, độc lập với thiết bị được sử dụng để tạo ra hình ảnh EL, độc lập với thiết kế mô-đun dựa trên wafer và độc lập với chất lượng hình ảnh.

© 2021 Elsevier Ltd. Bảo lưu mọi quyền.

1. Giới thiệu

Sản xuất điện dựa trên quang điện mặt trời (PV) đã tăng nhanh chóng trên toàn thế giới. Đến cuối năm 2019, tổng công suất lắp đặt PV toàn cầu đạt 623,2 GW (GW) [1]. Đến năm 2022, các chuyên gia dự đoán công suất lắp đặt hàng năm trên toàn cầu sẽ đạt từ 100 GW đến 232 GW, tùy thuộc vào kịch bản tăng trưởng [2] và công suất lắp đặt toàn cầu đạt 2840 GW vào năm 2030 [3]. Sự tăng trưởng của các công trình lắp đặt PV mặt trời phần lớn là do chi phí điện thấp hơn do PV mặt trời mới tạo ra so với các nhà máy điện mới dựa trên các công nghệ khác.


Sản xuất điện dựa trên PV mặt trời bắt đầu bằng việc chuyển đổi photon thành electron bên trong mô-đun PV. Chất lượng và độ tin cậy kém của các mô-đun PV sẽ có tác động ngay lập tức và lâu dài đến tính an toàn, hiệu suất và lợi nhuận tài chính từ khoản đầu tư của nhà máy PV. Các mô-đun PV chiếm khoảng 25-35% tổng chi phí của các dự án PV mặt trời quy mô tiện ích trong phạm vi 5-100 MW và chi phí mô-đun vẫn là khoản chi phí lớn nhất đối với các hệ thống PV bất kể quy mô [4]. Các nhà sản xuất đang

áp lực liên tục để cung cấp các mô-đun PV với giá thấp hơn và áp lực này có thể xung đột với nhu cầu của người tiêu dùng đối với một sản phẩm có chất lượng và độ tin cậy cao. Phân tích độc lập và phát hiện lỗi trong hình ảnh phát quang điện (EL) là một phương tiện để người mua yêu cầu nhà sản xuất chịu trách nhiệm về chất lượng và độ tin cậy trong một thị trường cạnh tranh về chi phí.

Các mô-đun PV được làm từ các ô silicon tinh thể dễ bị nứt và các ô nứt có khả năng tạo ra điện năng giảm theo thời gian [5]. Các vết nứt hình thành trong quá trình sản xuất, vận chuyển, lắp đặt mô-đun và ứng suất lớn do gió, tuyết và giao thông của con người trong quá trình vận hành và bảo trì thường xuyên. Hình ảnh EL được sử dụng rộng rãi trong ngành để phát hiện các vết nứt trong các mô-đun PV mặt trời. Hình 1 cho thấy hình ảnh EL điển hình của một mô-đun PV được làm bằng các tấm wafer silicon đơn tinh thể. Mô-đun bao gồm 60 ô được sắp xếp theo lưới 6 10. Các ô thường được kết nối nối tiếp với nhiều dải liên kết trên mỗi ô. Các ô bị nứt nghiêm trọng có thể nhìn thấy ở phía bên trái của hình ảnh EL mà không thể nhìn thấy trong quá trình kiểm tra trực quan bản thân mô-đun.

Các mô-đun PV dễ bị các khuyết tật khác có thể nhìn thấy trong

^{*} Tác giả liên hệ. Hội đồng nghiên cứu khoa học và công nghiệp (CSIR), Đường Meiring Naude, Pretoria, Nam Phi.
Địa chỉ email: lpratt@csir.co.za (L. Pratt).



Hình 1. Hình ảnh EL của mô-đun PV được làm từ các ô đơn tinh thể cho thấy các ô bị nứt ở ba cột bên trái.

Hình ảnh EL. Các khu vực không hoạt động xuất hiện dưới dạng các vùng tối, có hình dạng không đều, nơi các phần của tế bào bị cô lập khỏi mạch ngoài do đến các vết nứt. Các khuyết tật của đường lưới xuất hiện dưới dạng các đường tối chạy vuông góc với các kết nối ruy băng. Các khuyết tật khác có nguồn gốc từ quá trình sản xuất và ứng suất môi trường có thể được quan sát thấy, chẳng hạn như các vết băng, các cạnh tối dọc theo một hoặc hai mặt của ô, sự ăn mòn dọc theo các kết nối ruy băng và các ô chết.

Thị giác máy tính đã chứng minh được tính hiệu quả trong việc tự động xác định các khuyết tật trong hình ảnh EL của tế bào quang điện. Các phương pháp thống kê, máy vectơ hỗ trợ (SVM) và mạng nơ-ron tích chập (CNN) đã được sử dụng để phát hiện vật thể và định vị các loại khuyết tật khác nhau, thường tập trung vào các vết nứt, vùng không hoạt động và khuyết tật lưới. Thị giác máy tính sử dụng phân đoạn ngữ nghĩa cải thiện các phương pháp trước đó bằng cách tạo ra phân loại cấp độ pixel cho phép phát hiện vật thể, phân loại và định lượng nhiều khuyết tật. Với phân loại cấp độ pixel, chất lượng mô-đun PV có thể được phân tích để tìm ra sự khác biệt về mặt thống kê trong các lô từ nhiều nhà cung cấp các mô-đun PV khác nhau và theo thời gian đối với cùng một lô mô-đun PV. Thông tin này sẽ hữu ích trong quá trình mua sắm, vận hành, bảo trì và khiếu nại bảo hành.

Chúng tôi trình bày kết quả từ việc áp dụng mô hình phân đoạn ngữ nghĩa vào ảnh EL của các mô-đun quang điện mặt trời để phát hiện, phân loại và định lượng lỗi. Sau đó, mô hình được áp dụng vào ảnh EL chụp trên một lô mô-đun trải qua trình tự thử nghiệm ứng suất tăng tốc được kiểm soát trong phòng thí nghiệm để tạo ra mật naphan loại lỗi cấp độ pixel cho từng mô-đun theo thời gian. Sau đó, bản đồ phân loại cấp độ pixel được sử dụng để ước tính mức độ phổ biến của từng loại lỗi bằng cách đếm các pixel được gán cho từng loại lỗi trong mỗi ảnh. Bài viết này có thể là bài viết đầu tiên trình bày kết quả sử dụng phân đoạn ngữ nghĩa để phân tích và định lượng nhiều loại lỗi được chụp trong ảnh EL của các tế bào quang điện trong trình tự thử nghiệm ứng suất tăng tốc.

Bài viết tiếp tục với phần tổng quan tài liệu trong Phần 2, phần giới thiệu về hình ảnh EL trong Phần 3, phương pháp trong Phần 4, kết quả trong Phần 5, kết luận trong Phần 6 và lời cảm ơn trong Phần 7.

2. Tổng quan tài liệu

Phát hiện khuyết tật trong hình ảnh quang học của các tế bào quang điện trần đã là chủ đề của một số bài báo, bao gồm một bài báo đánh giá về phát hiện khuyết tật bề mặt trên các tế bào quang điện mặt trời bằng các kỹ thuật thị giác máy tính [6]. Các chủ đề cụ thể về các tấm wafer và tế bào trần bao gồm: các tính năng tự học để phát hiện vết nứt [7]; Đàn hạt

Tối ưu hóa để phát hiện vết nứt [8]; SVM để phát hiện vết nứt [9]; và phát hiện khuyết tật dựa trên độ dịch chuyển trung bình để phát hiện dấu vân tay [10]. Mặc dù phát hiện khuyết tật và vết nứt trên hình ảnh trực quan của các tấm bán dẫn trần rất phù hợp với dây chuyền sản xuất, nhưng chúng không áp dụng được cho mô-đun hoàn thiện. Trong mô-đun hoàn thiện, pin mặt trời được ép nhiều lớp trong một chồng polyme và kính để bảo vệ khỏi môi trường và các lớp đó che khuất bề mặt của pin mặt trời. Do đó, hình ảnh EL được phân tích để thu thập thông tin hữu ích từ mô-đun PV hoàn thiện.

Các ấn phẩm về phát hiện lỗi trong hình ảnh EL của các mô-đun PV nhiều lớp bao gồm công việc về xử lý trước hình ảnh, phát hiện đối tượng và phân loại lỗi. Một số bài báo mô tả các phương pháp cắt hình ảnh EL cấp mô-đun thành các ô thành phần [11e14].

Hình ảnh EL cấp độ tế bào thường được sử dụng trong các quy trình phát hiện và phân loại lỗi hơn là hình ảnh cấp độ mô-đun đầy đủ. Hình ảnh cấp độ tế bào tạo ra một tập dữ liệu đào tạo lớn hơn vì hình ảnh mô-đun thông thường có 60 hoặc 72 tế bào trên mỗi mô-đun trong khi hình ảnh nhỏ hơn ít tốn kém về mặt tính toán hơn để xử lý. Các bài báo khác mô tả các phương pháp xử lý trước như chuẩn hóa hình ảnh [15] và chuyển đổi phối cảnh và xoay [13]. Các phương pháp phát hiện và phân loại khuyết tật trong hình ảnh EL bao gồm: phương pháp thống kê để phát hiện vết nứt ở cấp độ pixel [16], Rừng ngẫu nhiên (RF) và SVM để phát hiện khuyết tật ngón tay, vết nứt và vùng không hoạt động [11]; CNN để phân loại các tế bào tốt, bị nứt hoặc bị ăn mòn [12]; CNN để phân loại các tế bào năng lượng mặt trời có vết nứt, khuyết tật vật liệu và khuyết tật đường lưới [17]; và SVM và CNN để chỉ định xác suất khuyết tật cho các tế bào đơn lẻ trong một mô-đun dựa trên loại khuyết tật [18]. Tang et al. [19] gần đây đã công bố một phương pháp để tăng cường hình ảnh EL bằng cách sử dụng mạng đối nghịch tạo sinh (GAN) để tăng số lượng dữ liệu đào tạo có sẵn và một CNN để phát hiện khuyết tật.

Phân đoạn ngữ nghĩa đã là chủ đề của một số ấn phẩm trên nhiều ứng dụng. Phân đoạn ngữ nghĩa tập trung nhiệm vụ thị giác máy tính từ việc dán nhãn một vùng trong hình ảnh sang dán nhãn từng pixel trong hình ảnh. Mô hình gán một lớp lỗi cho mỗi pixel và trả về một bản sao của hình ảnh gốc được tô màu theo phân loại lỗi. u-net để phân đoạn ngữ nghĩa lần đầu tiên được giới thiệu vào năm 2015 và được đánh giá trên các hình ảnh y sinh của màng tế bào [20]. Mô hình u-net bao gồm một loạt các khối bao gồm các lớp tích chập và các lớp gộp tối đa mã hóa hoặc tìm hiểu các tính năng trong hình ảnh. Sau đó, u-net giải mã kết quả từ bộ mã hóa và lấy mẫu lại đầu ra để khôi phục kích thước hình ảnh gốc với phân loại cấp độ pixel. Phân đoạn ngữ nghĩa đã được sử dụng để đánh giá các cảnh đường bộ [21], khối u não [22], tập dữ liệu cảnh quan thành phố [23], hình ảnh MRI của não [24], tập dữ liệu các đối tượng chung trong bối cảnh (COCO) [25], hình ảnh kính hiển vi điện tử truyền qua quét tiên tiến (STEM) của thép [26] và các tập dữ liệu khác [27]. Zhang và cộng sự [28] gần đây đã công bố một phương pháp phát hiện các vết nứt mỏng trong hình ảnh via hệ kết hợp u-net và GAN tập trung vào việc giải quyết các thách thức trong việc phát hiện các vết nứt mỏng chủ yếu là các pixel nên có thể hữu ích trong công việc trong tương lai để tối ưu hóa phát hiện vết nứt trong hình ảnh EL.

Trong bài báo này, chúng tôi thử nghiệm một mô hình phân đoạn ngữ nghĩa để phát hiện và phân loại lỗi trong hình ảnh EL của các tế bào quang điện được trích xuất chỉ với một chút tiền xử lý hình ảnh. Phân loại từng pixel của mỗi tế bào quang điện cho phép phát hiện và định lượng lỗi trên nhiều lỗi cùng một lúc. Việc định lượng lỗi, tức là số lượng pixel thô được phân loại theo từng loại lỗi, có thể hữu ích trong việc phân tích dữ liệu từ các thí nghiệm trong phòng thí nghiệm, đánh giá số liệu chất lượng trong các lô mô-đun PV và để phân tích kiểm tra cấp nhà máy, với điều kiện là có sẵn hình ảnh EL hỗ trợ. Theo hiểu biết của chúng tôi, đây là công trình đầu tiên áp dụng các kỹ thuật phân đoạn ngữ nghĩa vào hình ảnh EL của các mô-đun PV để phát hiện và phân loại lỗi.

3. Hình ảnh EL của các mô-đun PV

Chụp ảnh EL là một phương pháp hiệu quả để phát hiện các vết nứt nhỏ trong các mô-đun PV được làm từ các ô silicon [29]. Hình ảnh thu được giống như ảnh chụp X-quang, cho phép nhà phân tích phát hiện các khuyết tật không nhìn thấy được trong hình ảnh quang học. Các vết nứt nhỏ có thể hình thành trong quá trình xử lý ô, lắp ráp mô-đun, vận chuyển, lắp đặt và dưới các ứng suất xảy ra tại hiện trường, và các vết nứt này có thể ảnh hưởng tiêu cực đến hiệu suất tại hiện trường [29]. Ước tính có một triệu hình ảnh EL cuối cùng được tạo ra mỗi ngày trên toàn cầu chỉ riêng tại các cơ sở sản xuất mô-đun PV mặt trời, dựa trên 100 GW sản lượng hàng năm với công suất trung bình 300 W cho mỗi tấm pin.

Thông số kỹ thuật IEC 60904-13 mô tả các phương pháp tiêu chuẩn công nghiệp để thu thập hình ảnh EL trong môi trường phòng thí nghiệm. Báo cáo PVPS T13-10:2018 của IEA cũ ng cung cấp hướng dẫn về hình ảnh EL và IR [30]. Tóm lại, dòng điện DC được ép qua mô-đun PV hoặc chuỗi mô-đun PV để tạo ra các cặp lỗ electron trong thiết bị, mô phỏng hiệu ứng của các photon khi mô-đun tiếp xúc với ánh sáng mặt trời. Một camera chuyên dụng chụp ảnh, sau đó phân tích thủ công hoặc tự động để phát hiện và phân loại khuyết tật. Trong những năm gần đây, các phương pháp đã được phát triển để thu thập hình ảnh EL vào ban ngày [31e33] và tại chỗ trong các thử nghiệm ứng suất môi trường [34]. Hình ảnh EL tại chỗ, trên mặt đất và trên máy bay không người lái đã được triển khai thành công [35], do đó, khối lượng hình ảnh EL được thu thập trên các mô-đun thực địa có khả năng sẽ tăng lên trong tương lai.

Hình 2 cho thấy các ví dụ về hình ảnh EL cấp độ tế bào đối với các tế bào silicon đơn tinh thể (mono-si) và silicon đa tinh thể (multi-si). Một tế bào mono-si không có khuyết tật thể hiện bề mặt trong suốt, trong khi một tế bào đa si không có khuyết tật thể hiện các vùng tối không đều do ranh giới hạt tinh thể, do đó làm phức tạp việc phát hiện và phân loại vật thể trên các tế bào đa si. Những hình ảnh này thể hiện nhiều khuyết tật đáng quan tâm: vết nứt, vùng không hoạt động, vết đai, khuyết tật đường lưới ngang và các dải liên kết bị ăn mòn. Các hình ảnh cũ ng thể hiện các dải liên kết và miếng đệm liên kết hàn xuất hiện dưới dạng các đường tối chạy từ trên xuống dưới, mặc dù chúng không phải là khuyết tật.

4. Phương pháp luận

Hình 3 tóm tắt phương pháp luận trong ba giai đoạn: xử lý trước ảnh EL, đào tạo mô hình bằng ảnh EL và dự đoán lỗi trong ảnh EL mới bằng mô hình.

4.1. Tiền xử lý: Nguồn hình ảnh EL

Hình ảnh EL được thu thập từ các nguồn công khai và riêng tư. Hình ảnh EL cấp độ tế bào do ZAE Bayern1 [36] và Trung tâm Độ bền và Kéo dài Tuổi thọ Mặt trời (SDLE) tại Đại học Case Western Reserve2 công bố được tải xuống từ internet. Hình ảnh EL cấp độ mô-đun được cung cấp bởi: 1) CFV Labs, một phòng thí nghiệm thử nghiệm và chứng nhận mô-đun PV tại Hoa Kỳ, 2) ARTsolar, một nhà sản xuất mô-đun PV tại Nam Phi và 3) CSIR, một viện nghiên cứu tại Nam Phi. Hình ảnh EL được chỉ định ID duy nhất và được sắp xếp theo cây thư mục có cấu trúc.

4.2. Tiền xử lý: Tạo hình ảnh cấp độ tế bào

Hình ảnh EL cấp mô-đun đã được cắt xén để trích xuất hình ảnh cấp tế bào năng lượng mặt trời làm đơn vị phân tích cơ bản, theo hướng dẫn của các tác giả trước đây [11,12,16e18]. Hình ảnh EL đã được cắt xén bằng

một hàm python tùy chỉnh dựa trên thư viện PeakUtils. Hình 4 cho thấy một hình ảnh EL cấp mô-đun và các cấu hình tương ứng cho cường độ trung bình của các điểm ảnh dọc theo các hàng và cột tương ứng với tọa độ x, y cho không gian ô. Giao điểm của các đỉnh tương ứng với bốn góc của mỗi ô trong hình ảnh cấp mô-đun. Trong ví dụ này, các đỉnh nhỏ hơn dọc theo các cột tương ứng với các kết nối ruy-băng.

Trong quá trình cắt xén, hình ảnh cấp độ tế bào được mở rộng để bao gồm các nửa tế bào bao quanh mỗi tế bào đầy đủ. Các tác giả đã chọn mở rộng ra ngoài ranh giới tế bào vì hai lý do. Đầu tiên, phương pháp này tạo ra các hình ảnh đào tạo bao gồm các khoảng trống giữa các tế bào mà mô hình có thể sử dụng để phát hiện các loại tế bào đơn sắc so với đa sắc. Các tấm wafer đơn sắc được cắt từ các thỏi tròn tạo thành 'hình vuông giả' có các góc bo tròn tạo ra một đặc điểm hình thoi trong không gian nơi 'góc' tế bào hội tụ trong khi các tấm wafer đa sắc được cắt từ các thỏi chữ nhật để tạo thành các hình vuông có 90 góc không tạo thành hình thoi. Thứ hai, bộ đệm bổ sung đảm bảo rằng tế bào năng lượng mặt trời ở trung tâm có thể nhìn thấy hoàn toàn và không bị cắt ở một hoặc nhiều cạnh, như đôi khi xảy ra khi chỉ cắt xén một tế bào. Hình 5 cho thấy các ví dụ về hình ảnh EL cấp độ tế bào thu được. Tất cả các hình ảnh từ ZAE Bayern và SDLE đều bao gồm phần đệm nhân tạo ở cả bốn cạnh vì chỉ có hình ảnh cấp độ tế bào. Hình ảnh EL cấp mô-đun từ ARTsolar, CFV Labs và CSIR đã được cắt xén để bao gồm các ô xung quanh và/hoặc đệm cho các ô cạnh và góc. Sau khi cắt xén và đệm, mỗi hình ảnh cấp ô hiển thị một ô đầy đủ ở giữa, bắt kể

nguồn.

Cuối cùng, tất cả các hình ảnh tế bào đã được thay đổi kích thước và mã hóa lại. Các hình ảnh EL và mặt nạ thực tế tương ứng đã được thay đổi kích thước thành 512 pixel x 512 pixel để các hình ảnh đầu vào mô hình là nhất quán, bất kể nguồn nào. Sau đó, các mặt nạ thực tế đã được mã hóa lại để mỗi pixel được gán một số duy nhất từ 0 đến 23, tương ứng với đặc điểm hoặc khuyết tật.


4.3. Tiền xử lý: Tạo mặt nạ thực tế bằng GIMP

Mặt nạ sự thật cơ bản biểu diễn phân loại lỗi 'thực' cho mỗi pixel trong ảnh EL. Mặt nạ sự thật cơ bản cùng với các ảnh EL tương ứng tạo thành các cặp quan trọng cần thiết cho việc đào tạo, thử nghiệm và xác thực mô hình. Mặt nạ sự thật cơ bản được tạo ra bằng cách tô màu thủ công một bản sao của các ảnh EL tương ứng để màu của mỗi pixel tương ứng với một lỗi hoặc đặc điểm cụ thể trong ảnh EL tương ứng. Một nhóm cá nhân từ CSIR, Đại học Wits và công chúng đã được đào tạo để tô màu cho các ảnh EL trong GIMP 2.10.14 [37] theo mã màu được quy định.

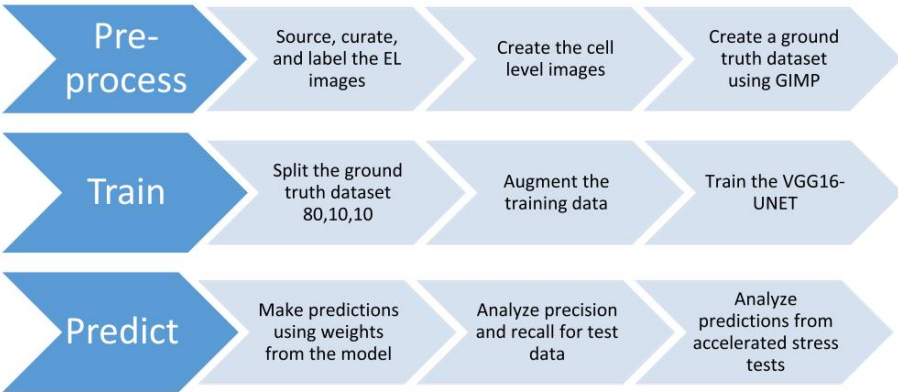
Hình 6 cho thấy mặt nạ thực tế cho các hình ảnh EL tương ứng được hiển thị ở trên trong Hình 5. Mỗi pixel trong mặt nạ thực tế được phân loại là một trong mười hai (12) đặc điểm nội tại hoặc mười một (11) khuyết tật bên ngoài bởi con người và được tô màu cho phù hợp. Các đặc điểm và khuyết tật được liệt kê dưới dạng nhãn trong Hình 7 (a) và Hình 7 (b), tương ứng. Các đặc điểm nội tại của ô bao gồm các vùng là một phần của mô-đun năng lượng mặt trời theo thiết kế, ví dụ: khoảng cách giữa các ô, các kết nối ruy băng, thanh cái và đường viền mô-đun. Các khuyết tật bên ngoài bao gồm các vết nứt, vùng không hoạt động, khuyết tật dấu đai, khuyết tật đường lưới và ăn mòn. Các vùng đệm được tô màu ô liu và bất kỳ pixel nào không được xác định là một trong các đặc điểm hoặc khuyết tật sẽ được tô màu đen.

Hình 7 cho thấy sự phân bố của các đặc điểm và khuyết tật được mã hóa trong mặt nạ thực tế. Do bản chất phân loại đa dạng của thí nghiệm này, kích thước hiệu quả của tập dữ liệu thực tế lớn hơn tổng số hình ảnh vì mỗi hình ảnh được đếm nhiều lần, một lần cho mỗi đặc điểm và khuyết tật trong hình ảnh. Phân tích tiếp theo tập trung vào việc phát hiện các vết nứt,

¹ <https://github.com/zae-bayern/elpv-dataset/tree/master/images>. <https://osf.io/4qtrtv/>.
²



Hình 2. Một số hình ảnh EL từ mono-si và multi-si với a) vết nứt và vùng không hoạt động, b) khuyết tật dấu đai, c) khuyết tật đường lưới, d) vết nứt và vùng không hoạt động, và e) ăn mòn dọc theo các kết nối ruy băng.



Hình 3. Phương pháp ba giai đoạn: xử lý trước ảnh EL, đào tạo mô hình bằng ảnh EL và dự đoán lỗi trong ảnh EL mới bằng mô hình.

Lưới và các khuyết tật không hoạt động vì quy mô mẫu cho các loại khuyết tật còn lại vẫn còn nhỏ.

4.4. Đào tạo: Tạo các tập dữ liệu đào tạo, xác thực và thử nghiệm

Hình ảnh EL cấp độ tế bào và mặt nạ sự thật cơ bản tương ứng được chia thành ba tập dữ liệu riêng biệt: tập dữ liệu đào tạo và xác thực được sử dụng trong quá trình đào tạo mô hình và tập dữ liệu thử nghiệm được sử dụng để đo độ chính xác của mô hình cuối cùng. Mỗi tập dữ liệu bao gồm các hình ảnh EL đã chọn và mặt nạ sự thật cơ bản tương ứng. Đầu tiên, tập dữ liệu thử nghiệm được tạo từ ba mươi (30) tế bào được chọn ngẫu nhiên từ tất cả các tế bào có sẵn có vết nứt hoặc vùng không hoạt động để phân tích tiếp theo có thể tập trung vào các khiếm khuyết chính này với số lượng đủ lớn. Tiếp theo, các tế bào còn lại được chỉ định ngẫu nhiên vào các tập dữ liệu đào tạo và xác thực. Trong số 148 hình ảnh tế bào có mặt nạ sự thật cơ bản, 108 (73%) được chỉ định để đào tạo, 10 (7%) được chỉ định để xác thực và 30 (20%) được chỉ định để kiểm tra.

Sau khi tạo ba tập dữ liệu, các hình ảnh và mặt nạ đào tạo đã được tăng cường. Tăng cường đề cập đến một thông lệ tiêu chuẩn trong học máy, sử dụng hình ảnh gốc và tạo ra nhiều hình ảnh tương tự để có thể tăng tập dữ liệu đào tạo theo cách có ý nghĩa và hữu ích. Trong thí nghiệm này, mỗi hình ảnh đào tạo và mặt nạ thực tế tương ứng đã được tăng cường bằng cách lật ngang, lật dọc và xoay 180 độ. Hình 8 cho thấy một chuỗi hình ảnh cho một ô đại diện từ tập dữ liệu đào tạo, bao gồm mặt nạ thực tế ban đầu, được thay đổi kích thước, mã hóa lại và tăng cường. Việc tăng cường chỉ diễn ra sau khi chia tách để tránh bất kỳ sự lây nhiễm chéo nào, tức là không có hình ảnh tăng cường nào từ tập dữ liệu đào tạo xuất hiện trong các tập dữ liệu xác thực hoặc thử nghiệm. Mỗi hình ảnh EL và mặt nạ thực tế tương ứng tạo ra một

tổng cộng bốn hình ảnh và mặt nạ để đào tạo. Các bộ xác thực và kiểm tra không được tăng cường.

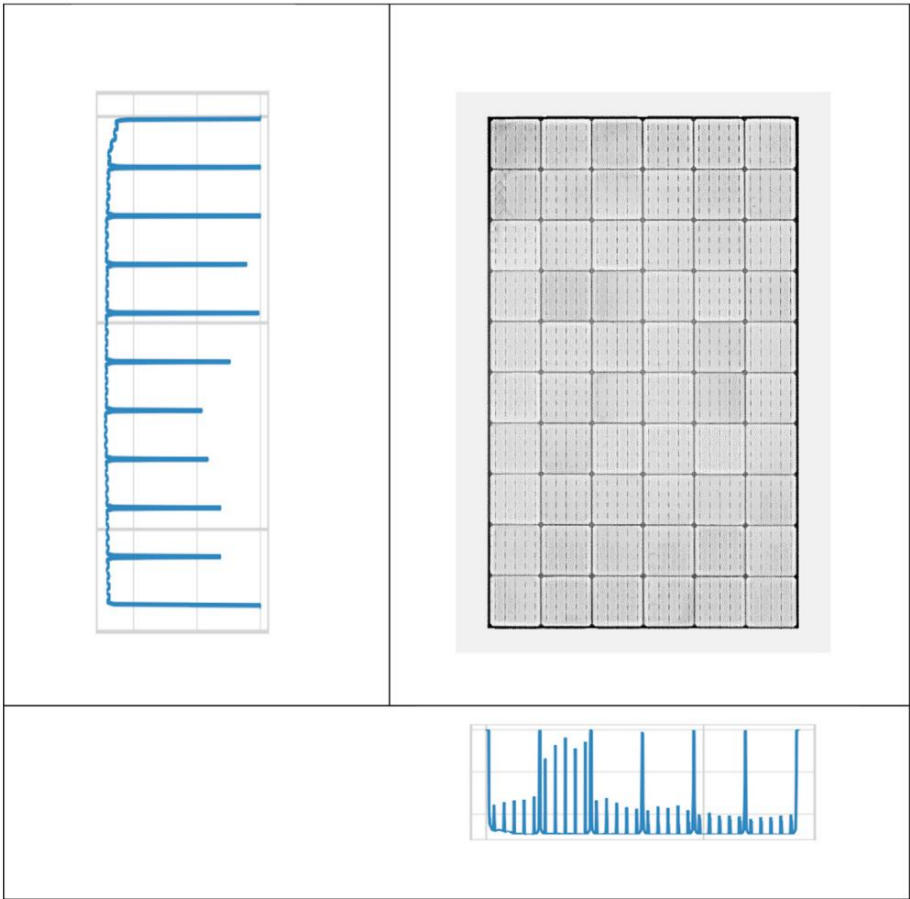
4.5. Đào tạo: Đào tạo mô hình u-net

Mô hình u-net để phân đoạn ngữ nghĩa đã được điều chỉnh cho hình ảnh EL bắt đầu bằng mã máy tính do Gupta [38] công bố. Mô hình triển khai mô hình cơ sở VGG-16 (bộ mã hóa) và mô hình phân đoạn ngữ nghĩa U-NET (bộ giải mã), với hơn 12 triệu tham số cần học, tức là được tối ưu hóa để giảm lỗi trong dự đoán. Chi tiết về mô hình u-net được để lại cho người đọc vì chúng nằm ngoài phạm vi của bài viết này. Sau khi được đào tạo trên hình ảnh EL, mô hình có thể phân tích hình ảnh EL mới và dự đoán phân loại có khả năng xảy ra nhất cho từng pixel trong hình ảnh EL mà không cần bất kỳ diễn giải nào của con người. Mô hình được đào tạo trên hình ảnh EL và mặt nạ chân lý cơ bản tương ứng trong tập dữ liệu đào tạo, sử dụng trọng số được đào tạo trước từ tập dữ liệu ImageNet làm điểm khởi đầu cho các tham số trong mô hình.


5. Kết quả thực nghiệm và thảo luận

5.1. Bộ dữ liệu thử nghiệm


Bộ dữ liệu thử nghiệm bao gồm ba mươi (30) hình ảnh EL với ít nhất một số vết nứt hoặc vùng không hoạt động. Các hình ảnh thử nghiệm được đưa vào mô hình đã đào tạo và mô hình tạo ra ba mươi (30) mặt nạ dự đoán, một cho mỗi hình ảnh EL. Mặt nạ dự đoán là bản đồ màu tương ứng với hình ảnh thử nghiệm hiển thị dự đoán tốt nhất của mô hình cho mỗi phân loại pixel. Bản đồ dự đoán trông giống như mặt nạ thực tế, ngoại trừ mặt nạ dự đoán được tạo ra từ mô hình và mặt nạ thực tế được tạo ra theo cách thủ công.




Hình 4. Hồ sơ được tạo từ cường độ trung bình theo hàng và theo cột với các đỉnh tương ứng với vùng khoảng cách ô của toàn bộ hình ảnh mô-đun.



Hình 5. Ví dụ về hình ảnh EL cấp độ tế bào, một hình ảnh từ mỗi nguồn: a) Tế bào đa si ARTsolar được cắt từ cạnh của một mô-đun đầy đủ, b) Tế bào đa si đơn ZAE Bayern có đệm ở bốn mặt, c) Tế bào đơn si CFV Labs được cắt từ tâm của một mô-đun đầy đủ, d) Tế bào đơn si CSIR được cắt từ tâm của một mô-đun đầy đủ và e) Tế bào đa si đơn SDLE có đệm ở bốn mặt.



Hình 6. Ví dụ về mặt nạ thực tế hiển thị các điểm ảnh được tô màu theo các giá trị quy định: màu xanh lá cây cho các dải kết nối (a, b, c); màu nâu cho cạnh mô-đun (a); màu trắng cho các vết nứt (b, c); màu đỏ cho các khu vực không hoạt động (b, c); thanh vàng cho các vết đai (d); màu xanh lam cho khoảng cách xương chó (d); màu cam cho các khuyết tật đường lưới (a, c); màu ô liu cho phần đệm (a, b, e); màu xanh lá cây đậm cho các kết nối bị ăn mòn (e); và màu đen cho nền (a, b, c, d, e).



Hình 7. Phân bố phân loại pixel theo nguồn, được nhóm theo (a) các đặc điểm nội tại và (b) các khuyết tật bên ngoài).

Phần này sẽ so sánh giữa mặt nạ dự đoán do máy tính tạo ra và mặt nạ thực tế thủ công cho tập dữ liệu thử nghiệm, bắt đầu bằng biểu đồ tóm tắt của tất cả các ô và sau đó đi sâu vào các vùng cụ thể của các ô cụ thể. Phân tích tập trung cụ thể vào bốn đặc điểm chung (nền, đệm, ruy băng và khoảng cách) và ba khuyết điểm chính (vết nứt, vùng không hoạt động và đường lưới).


Hình 9 cho thấy sự phân bố của điểm chính xác và điểm thu hồi cho từng hình ảnh và phân loại trong tập dữ liệu thử nghiệm. Độ chính xác và điểm thu hồi là hai số liệu phổ biến được sử dụng trong học máy để đánh giá mức độ mô hình phân loại đúng một pixel (độ chính xác) và mức độ mô hình xác định vị trí lỗi (thu hồi). Các giá trị gần bằng một cho thấy sự thống nhất tốt giữa đầu ra mặt nạ thực tế từ quá trình kiểm tra thủ công và đầu ra mặt nạ dự đoán từ mô hình máy tính. Nhìn chung, độ chính xác và điểm thu hồi cao hơn đối với các đặc điểm so với lỗi, có thể là do số lượng pixel cao hơn đối với các đặc điểm bao phủ một vùng lớn hơn của hình ảnh. Mô hình hoạt động tốt như nhau trên cả hình ảnh ô đơn sắc và đa sắc khi phát hiện các đặc điểm, nhưng hoạt động tốt hơn trên ô đơn sắc khi phát hiện lỗi. Hiệu suất được cải thiện trên các ô đơn sắc có thể là một hàm của kích thước mẫu lớn hơn trong tập dữ liệu đào tạo (69 ô đơn sắc so với 39 ô đa sắc) và bề mặt ô mịn hơn, không có ranh giới hạt nhìn thấy được trên hình ảnh ô đa sắc. Bảy (7) ô có vết nứt không được phát hiện, bốn ô đơn sắc và ba ô đa sắc. Trong các ô này, các vết nứt là các đường đơn chiếm chưa đến 0,2% số điểm ảnh trong hình ảnh thực tế và ngay cả một chuyên gia cũ ng khó có thể xác định được.

Hình 10 cho thấy các hình ảnh liên quan đến hai tế bào từ tập dữ liệu thử nghiệm. Các hình ảnh EL gốc được cắt từ các hình ảnh EL mô-đun đầy đủ. Các mặt nạ thực tế được tạo ra từ quá trình kiểm tra của con người đối với hình ảnh EL. Các mặt nạ dự đoán được tạo ra bởi mô hình u-net đã được đào tạo dựa trên hình ảnh EL gốc làm đầu vào. Một mô hình học máy tốt sẽ tái tạo mặt nạ sự thật cơ bản với độ chính xác và khả năng thu hồi cao, đây sẽ là sự phản ánh tốt của hình ảnh EL gốc, tức là 'sự thật'. Mặt nạ dự đoán cho hai pin mặt trời này chứng minh tiềm năng cho

phân đoạn ngữ nghĩa để tạo ra ước tính hợp lý về vị trí, phân loại và định lượng các khiếm khuyết trong hình ảnh EL. Mặt nạ dự đoán là biểu diễn số của hình ảnh EL quang học với mỗi điểm ảnh được phân loại thành một trong các khuyết tật, đặc điểm hoặc nền mục tiêu, sau đó cho phép phân tích thống kê quy mô lớn các hình ảnh EL trên nhiều lô mô-đun có kích thước đầy đủ.

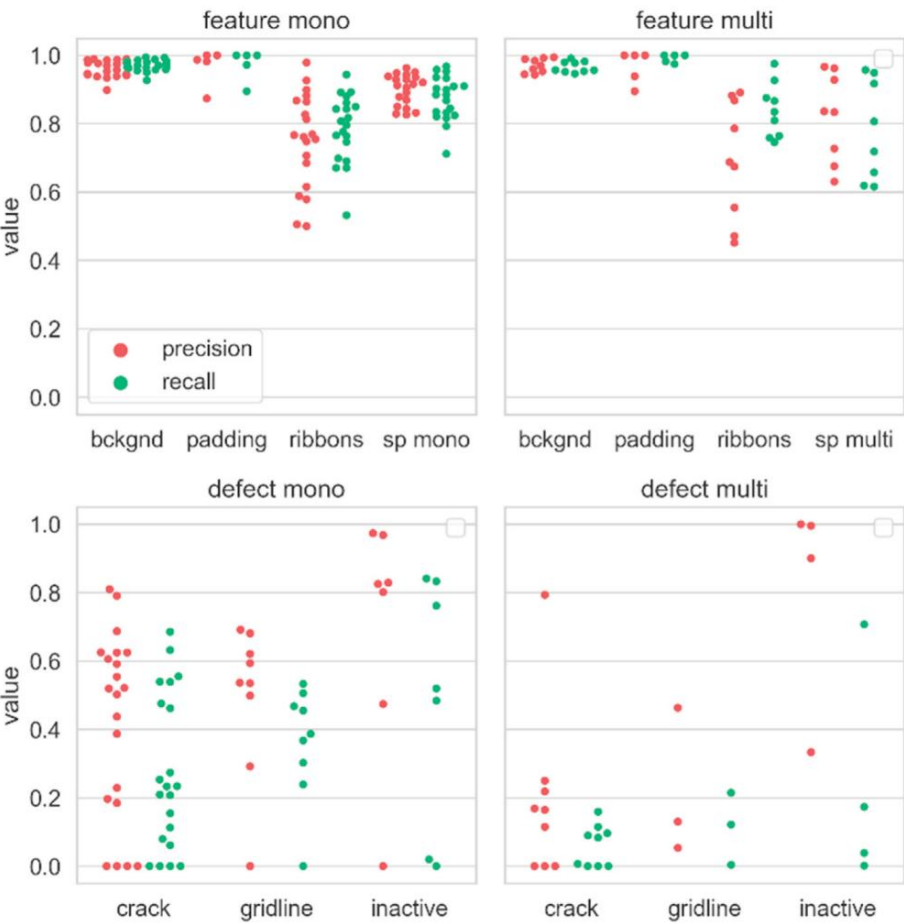
Hình 11 cho thấy ma trận độ chính xác và thu hồi cho các hình ảnh được hiển thị trong Hình 10. Các ma trận này định lượng mức độ phù hợp của mặt nạ dự đoán được tạo ra từ mô hình u-net với mặt nạ thực tế được tạo thủ công trong GIMP. Ví dụ, hàng được gắn nhãn 'không hoạt động' cho thấy mức độ mô hình máy tính dự đoán các điểm ảnh được gắn nhãn là 'không hoạt động' trong mặt nạ thực tế. Đối với hình ảnh a), các ma trận cho thấy 80% điểm ảnh được phân loại là 'không hoạt động' bởi mô hình máy tính cũ ng được gắn nhãn là 'không hoạt động' trong hình ảnh thực tế (độ chính xác) và 83% điểm ảnh được gắn nhãn là 'không hoạt động' trong mặt nạ thực tế cũ ng được gắn nhãn là 'không hoạt động' trong mặt nạ dự đoán (thu hồi). Tương tự như đối với hình ảnh b), hàng được dán nhãn là 'vết nứt' cho thấy 80% pixel được dán nhãn là 'vết nứt' bởi mô hình máy tính cũ ng được dán nhãn là 'vết nứt' trong mặt nạ thực tế (độ chính xác) và 73% pixel được dán nhãn là 'vết nứt' trong mặt nạ thực tế cũ ng được dán nhãn là 'vết nứt' bởi mô hình máy tính (thu hồi). Một mô hình máy tính hoàn hảo sẽ hiển thị tất cả các số một dọc theo đường chéo.

Các số liệu về độ chính xác và độ thu hồi cũ ng phụ thuộc vào chất lượng của mặt nạ thực tế, do đó mặt nạ thực tế chính xác là rất quan trọng để thành công. Hình 12 cho thấy lớp vết nứt (điểm ảnh màu trắng) được cắt từ tâm của Hình 10a. Mặt nạ dự đoán có màu xanh lá cây. Các điểm ảnh màu trắng còn lại chỉ ra các vết nứt không được mô hình phát hiện, do đó góp phần vào việc thu hồi thấp (48%). Kiểm tra kỹ hơn hình ảnh này cũ ng phát hiện ra các vấn đề về độ chính xác của mặt nạ thực tế. Ở một số khu vực, mặt nạ dự đoán do máy tính tạo ra chính xác hơn mặt nạ thực tế do con người tạo ra. Bất chấp những lỗi như vậy, mô hình u-net vẫn thực hiện công việc hợp lý trong việc xác định các vết nứt trong hình ảnh EL gốc.



(a) Original (b) Resized (c) Recoded (d) Flip horizontal (e) Flip vertical (f) Rotated 180

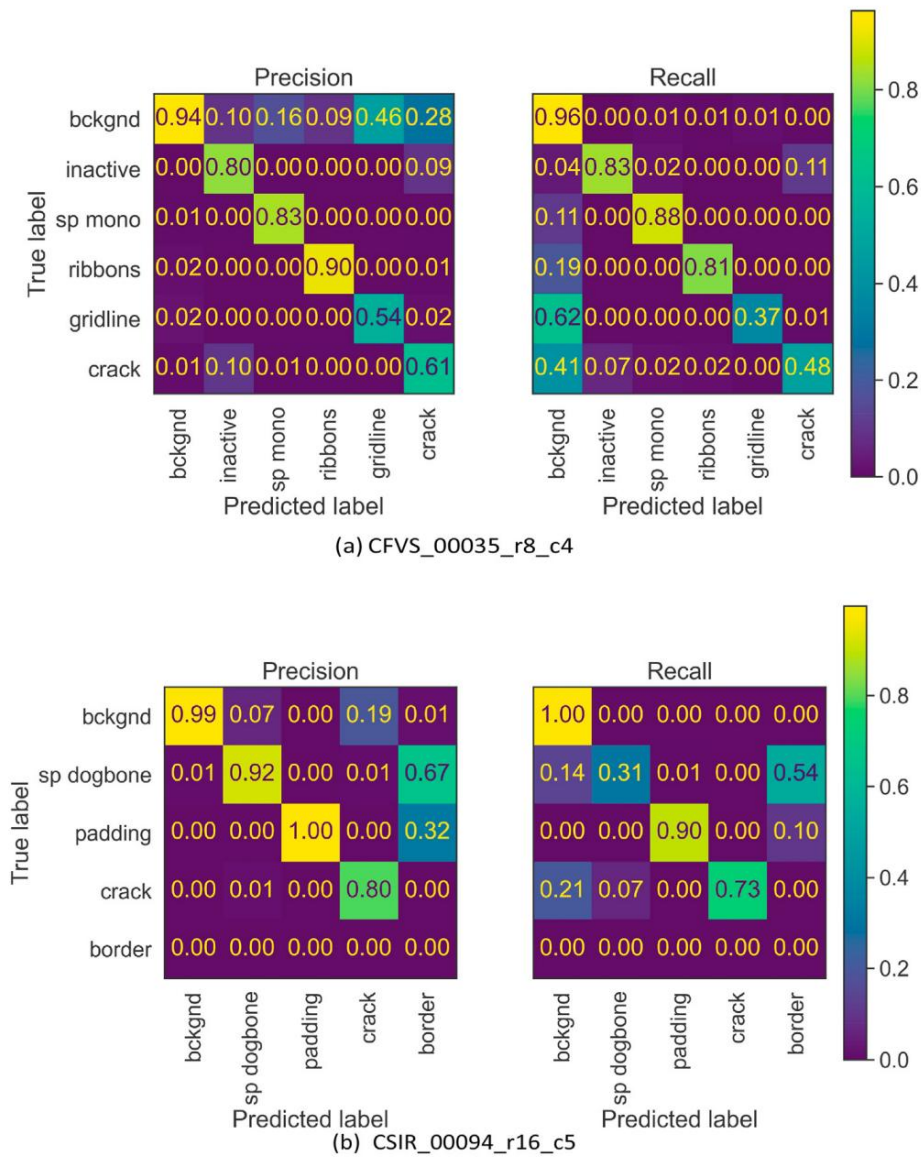
Hình 8. Ví dụ cho thấy quá trình xử lý trước một mặt nạ cơ bản gốc: a) bản gốc, b) thay đổi kích thước, c) mã hóa lại, d) lật theo chiều ngang, e) lật theo chiều dọc và f) xoay 180 độ để tạo ra bốn mặt nạ cơ bản từ mỗi bản gốc (c,d,e,f) để tăng hiệu quả kích thước của tập dữ liệu đào tạo.



Hình 9. Các số liệu hiệu suất cho tất cả các hình ảnh trong tập dữ liệu thử nghiệm so sánh sự phù hợp giữa đầu ra mặt nạ thực tế từ quá trình kiểm tra thủ công và đầu ra mặt nạ dự đoán từ mô hình máy tính: độ chính xác và khả năng thu hồi cho ba mươi (30) hình ảnh thử nghiệm.

EL	Ground Truth Mask	Prediction Mask
(a) CFVS_00035_r8_c4		
(b) CSIR_00094_r16_c5		

Hình 10. Các mẫu ảnh EL được cắt từ ảnh mô-dun đầy đủ (bên trái), mặt nạ thực tế được tô màu thủ công trong GIMP (ở giữa) và đầu ra mặt nạ dự đoán từ mô hình học máy (bên phải) trong đó các màu tương ứng với các khuyết tật và đặc điểm khác nhau được quan sát thấy trong ảnh EL gốc.



Hình 11. Ma trận độ chính xác và thu hồi định lượng khả năng của mô hình máy tính trong việc tái tạo màu pixel được dán nhãn thủ công trong một nậ dữ liệu thực tế cho hai ô đơn sắc đại diện.

5.2. Ứng dụng mô hình để thử nghiệm ứng suất tăng tốc của các mô-đun PV

Mô hình u-net đã được đào tạo hiện có thể được sử dụng để định lượng các thay đổi trong hình ảnh EL theo thời gian hoặc qua một loạt các thử nghiệm ứng suất phổ biến trong ngành PV trong quá trình chứng nhận mô-đun và thử nghiệm độ tin cậy mở rộng. Hình 13 cho thấy hình ảnh EL từ một mô-đun duy nhất chạy qua một loạt các thử nghiệm như vậy tại Phòng thí nghiệm CFV, bao gồm thử nghiệm tái cơ học tĩnh (SMLT), thử nghiệm tải cơ học động (DMLT), chu kỳ nhiệt (TC) và đóng băng độ ẩm (HF). HF10 biểu thị 10 chu kỳ HF và HF20 biểu thị 20 chu kỳ HF. SMLT dẫn đến các vết nứt và vùng không hoạt động không xuất hiện trong hình ảnh EL ban đầu. Các vết nứt có thể tăng lên và dẫn đến các vùng không hoạt động lớn hơn vào cuối chuỗi này. Mặt nạ dự đoán từ mô hình u-net có thể được sử dụng để định lượng thiệt hại và tương quan hiệu suất điện ở mỗi giai đoạn của thử nghiệm ứng suất tăng tốc

sự liên tiếp.

Hình 14 cho thấy hình ảnh EL và mặt nạ dự đoán do máy tính tạo ra cho một tế bào được cắt từ hình ảnh cấp mô-đun trong Hình 13. Cụ thể, đây là tế bào nằm trên hàng 4 (r4) và

cột 4 (c4). Hình ảnh EL cho thấy vết nứt dendritic đáng kể sau SMLT, phát triển thành các vùng tối hơn sau các ứng suất môi trường tiếp theo. Các vùng không hoạt động trở nên bị cô lập về mặt điện khỏi các dải liên kết, nghĩa là dòng điện được tạo ra không thể được trích xuất từ pin mặt trời và đầu ra điện của mô-đun giảm. Mặt nạ dự đoán theo dõi các thay đổi trong hình ảnh EL khi các vết nứt (màu trắng) phát triển thành các vùng không hoạt động (màu đỏ). Tuy nhiên, mặt nạ dự đoán đang dự đoán không chính xác các khuyết tật vật liệu (màu vàng) thay vì dự đoán chính xác các vùng không hoạt động (màu đỏ), đặc biệt là ở hình ảnh cuối cùng bên phải.

Hình 15 cho thấy một tập hợp hình ảnh tương tự cho một tế bào khác được cắt từ các hình ảnh mô-đun trong Hình 13. Tế bào này ở hàng 8 và cột 4 cũ ng cho thấy vết nứt hình cây đáng kể sau SMLT và sự tiến hóa tương tự hướng tới các vùng không hoạt động sau ứng suất HF. Một lần nữa, hình ảnh cuối cùng bên phải cho thấy xu hướng dự đoán các khuyết tật vật liệu (màu vàng) thay vì các vùng không hoạt động (màu đỏ).

Hình 16 cho thấy một tế bào khác được cắt từ cùng một tập hợp hình ảnh mô-đun được hiển thị trong Hình 13. Trong tế bào này từ hàng 3 và cột 2, các vết nứt đơn lẻ phát triển sau SMLT thay vì các vết nứt dạng cây



Hình 12. Lớp vết nứt cho CFVS_00035_r8_c4 hiển thị dự đoán từ mô hình máy tính (màu xanh lá cây) và mặt nạ thực tế cơ bản được tô màu thủ công (màu trắng) trong đó mô hình máy tính không dán nhãn chính xác các điểm ảnh là vết nứt.

được thấy trong hai ô trước. Các vùng không hoạt động nhỏ hơn tiến triển và các vùng màu đỏ tương ứng xuất hiện trong mặt nạ dự đoán. Các khiếm khuyết của đường lưới cũng ng phát triển ở rìa vết nứt dài, được nhìn thấy dưới dạng các đường ngang tối trong hình ảnh EL. Các khiếm khuyết này tương quan với các đường lưới được in trên pin mặt trời được thiết kế để trích xuất dòng điện do hiệu ứng quang điện tạo ra và truyền đến dải kết nối gần nhất. Các khiếm khuyết của đường lưới này có khả năng tương quan với tổn thất điện trở tăng lên, dẫn đến giảm sản lượng điện từ mô-đun PV. Các khiếm khuyết tương tự của đường lưới xuất hiện dọc theo một số vết nứt trong Hình 14 và 15. Tuy nhiên, mô hình u-net đã không phân loại các vùng này thành các khiếm khuyết của đường lưới,

xuất hiện dưới dạng các đường màu cam trong mặt nạ dự đoán. Bảng 1 định lượng sự thay đổi trong số lượng điểm ảnh cho các lớp khuyết tật đã chọn trong chuỗi thử nghiệm ứng suất tăng tốc. Các giá trị được lập bảng cho thấy số lượng điểm ảnh trong mỗi mặt nạ dự đoán được hiển thị trong các hình trên (16, 17 và 18). Số lượng điểm ảnh cho các vết nứt và khuyết tật không hoạt động tăng đáng kể sau SMLT đối với cả ba ô và sự gia tăng này tương quan với những thay đổi được quan sát thấy trong hình ảnh EL. Vào cuối chuỗi ứng suất tăng tốc, số lượng khuyết tật vết nứt giảm và số lượng khuyết tật không hoạt động tăng so với số lượng sau SMLT, như được chỉ ra bởi tỷ lệ giữa số lượng sau HF20 với số lượng sau SMLT được hiển thị trong cột ngoài cùng bên phải. Kết quả này là mong đợi, vì các vùng không hoạt động có xu hướng tăng do ứng suất nhiệt trong thể giới thực và được tạo ra trong chu kỳ nhiệt và đóng băng độ ẩm [5]. Tuy nhiên, mô hình không nắm bắt được những thay đổi trong các khuyết tật đường lưới được thấy trong hình ảnh EL, đặc biệt là xung quanh các vết nứt sau HF10 và sau HF20. Hàng trong bảng có nhãn 'nhiều' biểu thị tổng số điểm ảnh được phân loại sai thành các lớp vật liệu (màu vàng), đường viền (màu nâu) và khoảng cách đa (màu xám nhạt). Mức độ nhiễu hoặc phân loại sai có xu hướng tăng lên khi trình tự ứng suất tiến triển, đặc biệt là đối với hai tế bào có vết nứt dạng cây sau SMLT.

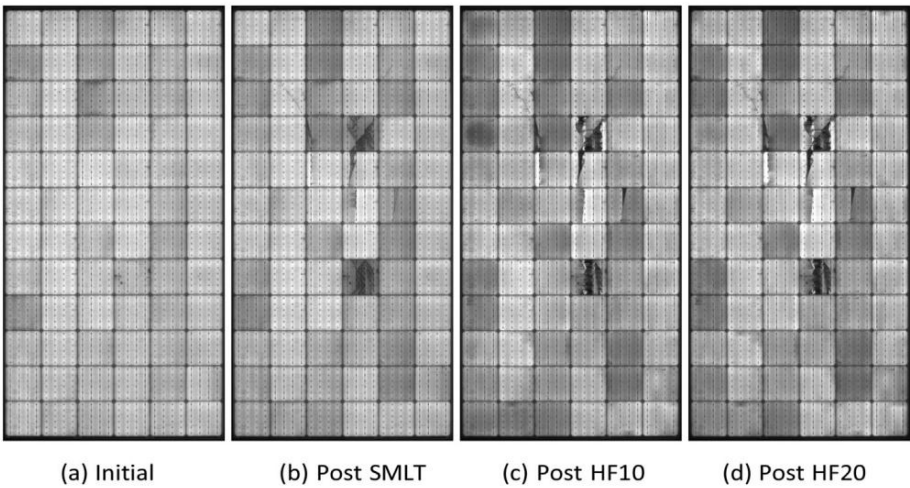
6. Công việc tương lai

Các công việc trong tương lai thuộc về hai hạng mục: cải tiến mô hình học máy và ứng dụng rộng rãi hơn trong các mô-đun PV. Khía cạnh học máy sẽ tập trung vào việc tăng tập dữ liệu đào tạo, cải thiện độ chính xác của mặt nạ thực tế và thử nghiệm các mạng nơ-ron thay thế để xác định kiến trúc phù hợp nhất cho hình ảnh EL. Công việc trong tương lai trong các ứng dụng sẽ tập trung vào việc thử nghiệm một tập hợp hình ảnh EL hoàn toàn khác từ một nguồn mới và phân tích thống kê quy mô lớn các lô mô-đun khác nhau.

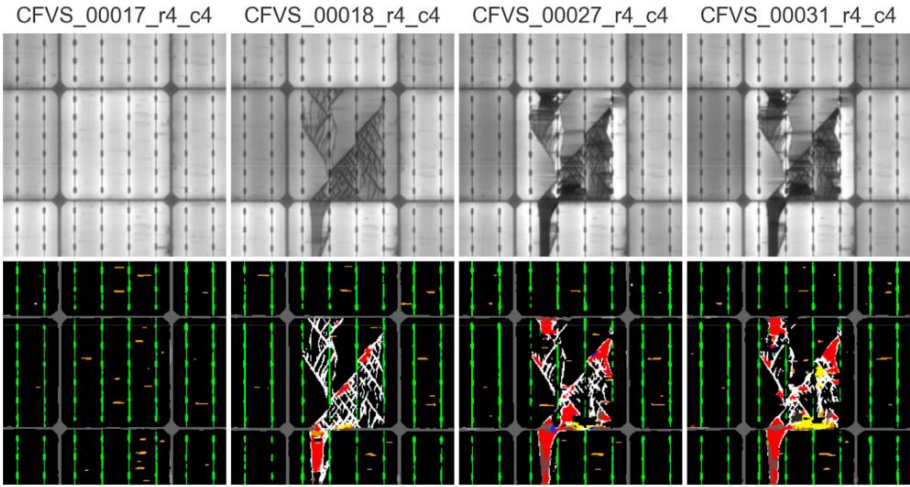
7. Kết luận

Một mô hình máy tính dựa trên phân đoạn ngữ nghĩa cho thấy tiềm năng phát hiện, phân loại và định lượng các tính năng và khuyết tật trong hình ảnh EL của các mô-đun PV được làm từ các ô silicon đơn tinh thể và đa tinh thể. Mô hình hoạt động tốt hơn trên các tính năng nội tại lớn như khoảng cách giữa các ô và kết nối ruy băng so với các khuyết tật bên ngoài nhỏ hơn như vết nứt và khuyết tật đường lưới. Mô hình hoạt động tốt hơn trên các ô được làm từ các ô đơn tinh thể so với các ô được làm từ các ô đa tinh thể. Việc thu hồi các khuyết tật không hoạt động, nứt và đường lưới đối với các ô được làm từ các tấm wafer silicon đơn tinh thể đạt tới mức cao lần lượt là 84%, 69% và 53%. Thống kê đầu ra từ mô hình cũng tương quan với những thay đổi được quan sát thấy trong một chuỗi hình ảnh EL được chụp qua nhiều giai đoạn của một thí nghiệm kiểm tra ứng suất tăng tốc được tiến hành tại Phòng thí nghiệm CFV.

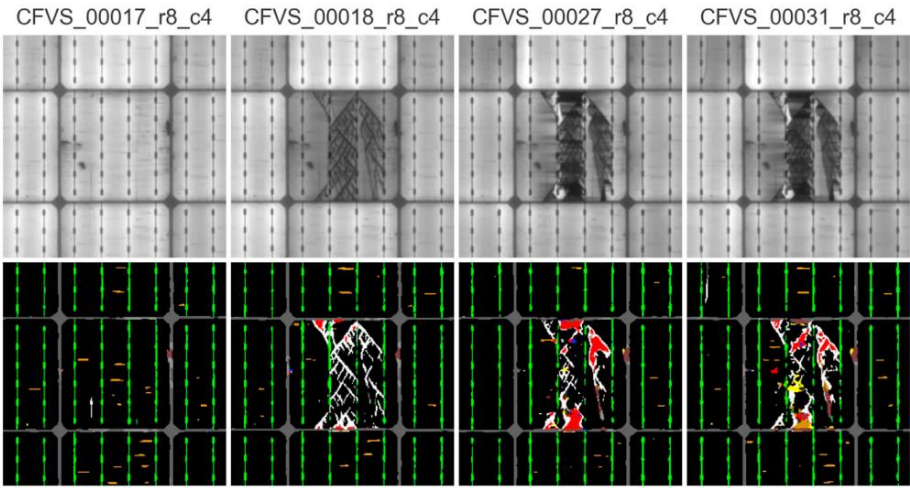
Phân đoạn ngữ nghĩa của hình ảnh EL cho phép định lượng và phân tích thống kê quy mô lớn các khiếm khuyết trong hàng triệu mô-đun PV. Tự động hóa quy trình này về cơ bản thay đổi lượng và loại dữ liệu có thể được trích xuất từ hình ảnh EL, mở ra cơ hội cho các phân tích mới để liên hệ các khiếm khuyết với hiệu suất điện, so sánh chất lượng mô-đun từ các nhà cung cấp khác nhau và định lượng các thay đổi trong các mẫu khiếm khuyết theo thời gian. Phân đoạn ngữ nghĩa cũng có thể được áp dụng cho các công nghệ năng lượng tái tạo khác vì mô hình có khả năng chuyển đổi bất kỳ hình ảnh trực quan nào thành một mảng số có thể được các kỹ sư và nhà khoa học trong lĩnh vực tương ứng của họ phân tích thêm để giải quyết các câu hỏi và thách thức nghiên cứu khác.



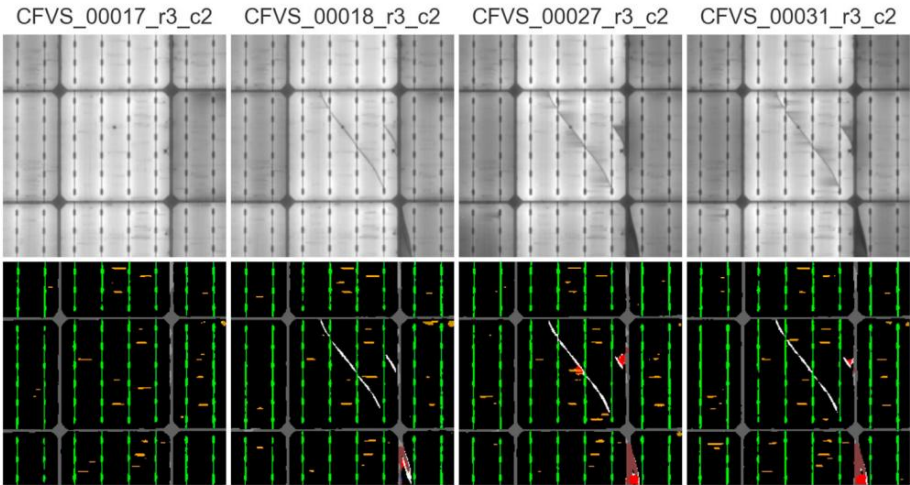
Hình 13. Hình ảnh EL của một mô-đun xiăng lê được chụp ở nhiều giai đoạn của chuỗi thử nghiệm ứng suất tăng tốc cho thấy các vết nứt tế bào ban đầu sau SMLT và các khu vực bị hư hỏng dẫn sẫm màu hơn sau các thử nghiệm tiếp theo.



Hình 14. Tác động của thử nghiệm ứng suất tăng tốc như được thấy trong hình ảnh EL gốc (trên) và mặt nạ dự đoán từ mô hình U-Net (dưới) đối với tế bào r4_c4 lúc ban đầu, sau SMLT, sau HF10 và sau HF20.



Hình 15. Tác động của thử nghiệm ứng suất tăng tốc như được thấy trong hình ảnh EL gốc (trên) và mặt nạ dự đoán tương ứng từ mô hình u-net (dưới) đối với tế bào r8_c4 lúc ban đầu, sau SMLT, sau HF10 và sau HF20.



Hình 16. Tác động của thử nghiệm ứng suất tăng tốc như được thấy trong hình ảnh EL gốc (trên cùng) và mặt nạ dự đoán tương ứng từ mô hình u-net (dưới cùng) cho ô r3_c2 lúc ban đầu, sau SMLT, sau HF10 và sau HF20.

Bảng 1

Số lượng pixel để phân loại lỗi dự đoán trong quá trình kiểm tra ứng suất tăng tốc và tỷ lệ sau HF20 so với sau SMLT cho ba tế bào được chọn.

Mô tả	—	Ban đầu	Tỷ lệ sau SMLT	Tỷ lệ sau HF10	Tỷ lệ sau HF20
nứt	r4-c4 0 r8-	12184	7448	8040	0,66
	c4 132 r3-c2 0	7428	4812	5996	0,81
	r4-c4 0 r8-	1304	1196	1108	0,85
	c4 8	2636	5932	5888	2.23
không hoạt động	r3-c2 0	640	3564	1864	2.91
	r3-c2 0	100	800	496	4,96
	r4-c4 1040	752	808	684	0,91
	r8-c4 1044 668		360	808	1.21
lưới	r3-c2 1244 1308 r4-c4 432		1376	1540	1.18
	r8-c4 1908 r3-	756	3304	4052	5,36
	c2 904	1248	2148	3356	2,69
		2044	2392	2160	1.06

Tuyên bố đóng góp tác giả CRediT

Lawrence Pratt: Khái niệm, Phương pháp, Phần mềm, Xác thực, Phân tích chính thức, Điều tra, Tài nguyên, Quản lý dữ liệu, Viết bản thảo gốc, Viết bài đánh giá và biên tập, Hình ảnh hóa, Quản lý dự án, Thu hút tài trợ. Devashen Govender: Phần mềm, Xác thực, Điều tra, Quản lý dữ liệu. Richard Klein: Khái niệm hóa, Phương pháp luận, Phân tích hình thức, Điều tra, Tài nguyên, Viết e đánh giá & biên tập, Giám sát, Dự án quản lý, thu hút nguồn tài trợ.

Tuyên bố về lợi ích cạnh tranh

Các tác giả tuyên bố rằng họ không có đối thủ cạnh tranh nào được biết đến lợi ích tài chính hoặc các mối quan hệ cá nhân có thể có đường như có ảnh hưởng đến công trình được báo cáo trong bài báo này.

Lời cảm ơn

Các tác giả muốn cảm ơn Tiến sĩ Kittessa Roro và CSIR vì hỗ trợ kỹ thuật, thiết bị đo lường, mẫu thử nghiệm và hỗ trợ tài chính cho chương trình tiến sĩ dẫn đến ấn phẩm này. Chúng tôi muốn cảm ơn CFV Labs và ARTsolar đã cung cấp hình ảnh EL và nhóm người dân nhận đã chú thích chúng: Nandi Bau, Sibusiso Mgidl, Rifumo Mzimba, Siyathandana Nontolwana, Kian Reddy và Kyle Wootton từ Đại học Witwatersrand; và Keketso Moletsane. Công trình này dựa trên nghiên cứu được hỗ trợ trong

một phần của Quỹ nghiên cứu quốc gia Nam Phi (Grant Số: 118075).

Tài liệu tham khảo

[1] G. Masson, I. Kaizuka, IEA PVPS xu hướng trong ứng dụng quang điện 2020.pdf. https://iea-pvps.org/wp-content/uploads/2020/11/IEA_PVPS_Trends_Report_2020-1.pdf, 2020.

[2] M. Schmela, Triển vọng thị trường toàn cầu về năng lượng mặt trời/2018-2022.pdf. <https://www.solarpowereurope.org/wp-content/uploads/2018/09/Global-Market-Outlook-2018-2022.pdf>, 2018.

[3] Irena, Tương lai của quang điện mặt trời: triển khai, đầu tư, công nghệ, lưới điện hội nhập và các khía cạnh kinh tế xã hội (một sự chuyển đổi năng lượng toàn cầu: giấy).pdf. https://www.irena.org/-/media/Files/IRENA/Agency/Publication/2019/Tháng_11/IRENA_Future_of_Solar_PV_2019.pdf, 2019.

[4] R. Fu, D. Feldman, R. Margolis, M. Woodhouse, K. Ardani, Điện mặt trời quang điện Hoa Kỳ Tiêu chuẩn chi phí hệ thống: Quý 1 năm 2017, Tech. Rep, Ấn phẩm và sản phẩm EERE Thư viện, 2017.

[5] M. Kontges, I. Kunze, S. Kajari-Schr oder, X. Breitenmoser, B. Bjørneklett, Định lượng rủi ro mất điện trong các mô-đun quang điện do các vết nứt nhỏ, trong: 25 Hội nghị năng lượng mặt trời quang điện châu Âu, Valencia, Tây Ban Nha, 2010, trang 3745e3752.

[6] X. Qian, H. Zhang, H. Zhang, Y. Wu, Z. Diao, Q.-E. Wu, C. Yang, Bề mặt pin mặt trời phát hiện khuyết tật dựa trên thị giác máy tính, Int. J. Perform. Eng. 13 (7) (2017).

[7] X. Qian, H. Zhang, C. Yang, Y. Wu, Z. He, Q.-E. Wu, H. Zhang, Các vết nứt nhỏ phát hiện bề mặt tế bào quang điện đa tinh thể dựa trên các tính năng tự học và phục hồi ma trận hạng thấp, Đánh giá cảm biến 38-3 (2018) 360e368, <https://doi.org/10.1108/SR-08-2017-0166>.

[8] MD Lydia, KS Sindhu, K. Gagan, Phân tích và phát hiện vết nứt tấm pin mặt trời sử dụng các kỹ thuật tối ưu hóa, Tạp chí Vật lý Nano và Điện tử 9 (2) (2017), 2004e1.

[9] SA Anwar, MZ Abdullah, Phát hiện vết nứt nhỏ của pin mặt trời đa tinh thể có bộ lọc khuếch tán dị hướng được cải tiến và phân đoạn hình ảnh kỹ thuật, Tạp chí EURASIP về Xử lý hình ảnh và video 2014 (1) (2014) 15.

[10] D.-M. Tsai, J.-Y. Luo, Phát hiện khuyết tật dựa trên độ dịch chuyển trung bình trong đa tinh thể bề mặt tấm wafer năng lượng mặt trời, Giao dịch IEEE về Tin học Công nghiệp 7 (1) (2010) 125e135.

[11] C. Mantel, F. Villebro, GA dos Reis Benatto, HR Parikh, S. Wendlandt, K. Hossain, P. Poulsen, S. Spataru, D. Sera, S. Forchhammer, Học máy dự đoán các loại khuyết tật cho hình ảnh phát quang điện của quang điện các bảng điều khiển, trong: Ứng dụng của Học máy, tập 11139, Hiệp hội quốc tế về Quang học và Photonics, 2019, trang 11139e4.

[12] AM Karimi, JS Fada, MA Hossain, S. Yang, TJ Peshek, JL Braid, RH French, Đường ống tự động cho hình ảnh phát quang điện của mô-đun quang điện phân loại tính năng xử lý và suy thoái, Tạp chí IEEE về quang điện 9 (5) (2019) 1324e1335.

[13] E. Sovetkin, A. Steland, Xử lý tự động và phát hiện pin mặt trời trong hình ảnh phát quang điện quang điện, Tích hợp Comput. Aided Eng. 26 (2) (2019) 123e137.

[14] S. Deitsch, C. Buerhop-Lutz, A. Maier, F. Gallwitz, C. Riess, Phân đoạn Hình ảnh tế bào mô-đun quang điện trong phát quang điện, bản in trước arXiv năm 2018 arXiv:1806.06530.

[15] KG Bedrich, M. Bliss, TR Betts, R. Gottschalg, Hình ảnh phát quang điện của thiết bị pv: hiệu chuẩn camera và hiệu chỉnh hình ảnh, trong: 2016 IEEE 43

L. Pratt, D. Govender và R. Klein

Năng lượng tái tạo 178 (2021) 1211e1222

Hội nghị các chuyên gia về quang điện (PVSC), IEEE, 2016, trang 1532e1537.

[16] S. Spatazu, P. Hacke, D. Sera, Tự động phát hiện và đánh giá các vết nứt nhỏ của tế bào quang điện trong hình ảnh phát quang điện bằng cách sử dụng các bộ lọc phù hợp, trong: Hội nghị chuyên gia quang điện lần thứ 43 (PVSC) của IEEE năm 2016, IEEE, 2016, tr. 1602e1607.

[17] MM Akram, G. Li, Y. Jin, X. Chen, C. Zhu, X. Zhao, A. Khaliq, M. Faheem, A. Ahmad, Phát hiện tự động các khuyết tật của tế bào quang điện dựa trên Cnn trong hình ảnh phát quang điện, Năng lượng 189 (2019) 116319.

[18] S. Deitsch, V. Christlein, S. Berger, C. Buerhop-Lutz, A. Maier, F. Gallwitz, C. Riess, Phân loại tự động các ô mô-đun quang điện bị lỗi trong hình ảnh phát quang điện, Sol. Energy 185 (2019) 455e468.

[19] W. Tang, Q. Yang, K. Xiong, W. Yan, Nhận dạng lỗi tự động dựa trên học sâu của mô-đun quang điện bằng hình ảnh phát quang điện, Sol. Năng lượng 201 (2020) 453e460.

[20] O. Ronneberger, P. Fischer, T. Brox, U-net, Mạng tích chập để phân đoạn hình ảnh y sinh, trong: Hội nghị quốc tế về máy tính hình ảnh y tế và can thiệp hỗ trợ máy tính, Springer, 2015, trang 234e241.

[21] V. Badrinarayanan, A. Kendall, R. Cipolla, Segnet: kiến trúc mã hóa-giải mã tích chập sâu để phân đoạn hình ảnh, IEEE Trans. Pattern Anal. Mach. Intell. 39 (12) (2017) 2481e2495.

[22] H. Dong, G. Yang, F. Liu, Y. Mo, Y. Guo, Phát hiện và phân đoạn khối u não tự động bằng mạng tích chập hoàn toàn dựa trên u-net, trong: Hội nghị thường niên về hiểu biết và phân tích hình ảnh y tế, Springer, 2017, trang 506e517.

[23] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, H. Adam, Bộ mã hóa-giải mã với tích chập tách rời atrous để phân đoạn hình ảnh ngữ nghĩa, trong: Biên bản Hội nghị Châu Âu về Tầm nhìn Máy tính (ECCV), 2018, trang 801e818.

[24] S. Cui, L. Mao, J. Jiang, C. Liu, S. Xiong, Phân đoạn ngữ nghĩa tự động của khối u thần kinh đệm não từ hình ảnh chụp cộng hưởng từ bằng cách sử dụng mạng nơ-ron thần kinh tăng sâu, Tạp chí kỹ thuật chăm sóc sức khỏe 2018 (2018).

[25] K. He, G. Gkioxari, P. Dollar, R. Girshick, Mask r-cnn, trong: Biên bản Hội nghị quốc tế IEEE về tầm nhìn máy tính, 2017, trang 2961e2969.

[26] G. Roberts, SY Haile, R. Sainju, DJ Edwards, B. Hutchinson, Y. Zhu, Học sâu để phân đoạn ngữ nghĩa các khuyết tật trong hình ảnh thần thép tiên tiến, Sci. Rep. 9 (1) (2019) 1e12.

[27] Y. Yuan, X. Chen, J. Wang, Biểu diễn ngữ cảnh đối tượng cho phân đoạn ngữ nghĩa, 2019, trang 11065, bản in trước arXiv arXiv:1909.

[28] K. Zhang, Y. Zhang, H.-D. Cheng, Crackgan: phát hiện vết nứt vỉa hè bằng cách sử dụng

sự thật cơ bản chính xác một phần dựa trên học tập đối nghịch tạo sinh, trong: Giao dịch IEEE về Hệ thống giao thông thông minh, 2020.

[29] M. Kontges, S. Kurtz, C. Packard, U. Jahn, KA Berger, K. Kato, T. Friesen, H. Liu, M. Van Iseghem, J. Wohlgemuth, et al., Đánh giá về sự cố của các mô-đun quang điện, 2014.

[30] U. Jahn, M. Herz, M. Kontges, D. Parlevliet, M. Paggi, I. Tsanakas, Đánh giá về hình ảnh hồng ngoại và phát quang điện cho các ứng dụng tại hiện trường PV: Chương trình hệ thống điện quang điện của Cơ quan Năng lượng Quốc tế: Nhiệm vụ 13 PVPS của IEA, Cơ quan Năng lượng Quốc tế, 2018. Nhiệm vụ phụ 3.3: báo cáo IEA-PVPS T13-12 : 2018.

[31] S. Johnson, T. Silverman, Chụp ảnh mô-đun ngoài trời bằng phát quang và phát quang điện; nrel (phòng thí nghiệm năng lượng tái tạo quốc gia), trong: Công nghệ. Đại diện, Phòng thí nghiệm năng lượng tái tạo quốc gia (NREL), Golden, CO (Hoa Kỳ), 2015.

[32] WB Hobbs, B. Hamzavy, CB Jones, C. Libby, O. Lavrova, Chụp ảnh phát quang điện trong trường: phương pháp, so sánh với chụp ảnh trong nhà và những thay đổi quan sát được trong các mô-đun trong hơn một năm, trong: Hội nghị thế giới lần thứ 7 về chuyển đổi năng lượng quang điện (WCPEC) của IEEE năm 2018 (Hội nghị chung của IEEE PVSC, PVSEC lần thứ 45 và EU PVSEC lần thứ 34), IEEE, 2018, tr. 3257e3260.

[33] M. Reuter, L. Stoicescu, JH Werner, Phát quang điện từ của mô-đun PV: Làm sáng tỏ các khuyết tật 35. URL https://www.solarzentrum-stuttgart.com/uploads/file/platzhalter_vortrag_spezial_hagelschaden_DaySy_April2015_04.pdf.

[34] M. Owen-Bellini, DB Sulas-Kern, G. Pezzin, H. North, S. Spatazu, P. Hacke, Phương pháp chụp ảnh điện phát quang tại chỗ của các mô-đun quang điện trong điều kiện môi trường khác nhau, Tạp chí quang điện IEEE 10 (5) (2020) 1254e1261.

[35] S. Koch, T. Weber, C. Sobottka, A. Fladung, P. Clemens, J. Berghold, Chụp ảnh phát quang điện ngoài trời của các mô-đun quang điện tinh thể: nghiên cứu so sánh giữa kiểm tra thủ công trên mặt đất và khảo sát trên không bằng máy bay không người lái , trong: Triển lãm Photovolta. Sol. Energy Conf. lần thứ 32 của Châu Âu, 2016, trang 1736e1740.

[36] C. Buerhop-Lutz, S. Deitsch, A. Maier, F. Gallwitz, C. Brabec, Điểm chuẩn để nhận dạng trực quan các tế bào quang điện bị lỗi trong hình ảnh phát quang điện, trong: Hội nghị và Triển lãm năng lượng mặt trời PV châu Âu lần thứ 35, tập 12871289, 2018.

[37] Nhóm phát triển GIMP, Gimp. URL <https://www.gimp.org>.

[38] D. Gupta, phân đoạn hình ảnh-keras. <https://github.com/divangupta/image-segmentation-keras>, 2020.

1222