

Phân tích lỗi mô-đun dựa trên học sâu cho các trang trại quang điện quy mô lớn

Xiaoxia Li, Qiang Yang, Thành viên cao cấp, IEEE, Zhuo Lou, Wenjun Yan, Thành viên, IEEE

Tóm tắt- Việc giám sát tình trạng hiệu quả và phát hiện lỗi mô-đun chính xác trong các trang trại quang điện (PV) quy mô lớn đòi hỏi phương pháp kiểm tra và công cụ phân tích mới. Bài báo này trình bày một giải pháp dựa trên học sâu để nhận dạng mẫu lỗi bằng cách sử dụng hình ảnh trên không thu được từ máy bay không người lái (UAV). Mạng nơ-ron tích chập (CNN) được sử dụng trong quy trình học máy để phân loại các dạng lỗi mô-đun khác nhau. Quy trình học có giám sát như vậy có thể trích xuất một loạt các tính năng sâu của các mô-đun PV đang hoạt động. Nó cải thiện đáng kể hiệu quả và độ chính xác của việc kiểm tra tài sản và đánh giá tình trạng cho các trang trại PV quy mô lớn so với các giải pháp thông thường. Giải pháp thuật toán được đề xuất được đánh giá rộng rãi từ nhiều khía cạnh khác nhau và kết quả có sức chứng minh rõ ràng tính hiệu quả của nó trong việc phát hiện lỗi hiệu quả của các mô-đun PV.

Thuật ngữ chỉ mục-Máy bay không người lái, Kiểm tra trang trại quang điện, Mạng nơ-ron tích chập, Nhận dạng mẫu

I. GIỚI THIỆU

TRONG với nhu cầu ngày càng tăng của nền kinh tế các-bon thấp và Với những tiến bộ công nghệ, việc tạo ra năng lượng quang điện (PV) đã trở thành một trong những thành phần quan trọng nhất của việc cung cấp năng lượng sạch và tái tạo trong những thập kỷ qua.

Số liệu thống kê từ Cơ quan Năng lượng Quốc tế (IEA) [1] chỉ ra rằng công suất PV đã lắp đặt vào năm 2016 đã tăng 50% (hơn 74 GW) trên toàn thế giới và Trung Quốc chiếm gần một nửa mức tăng trưởng này. Tổng công suất PV toàn cầu dự kiến sẽ đạt 740 GW vào năm 2022. Tuy nhiên, việc mở rộng công suất nhanh chóng như vậy và yêu cầu về độ tin cậy của các cơ sở hạ tầng PV quy mô lớn đặt ra nhu cầu cấp thiết về việc đánh giá tài sản hiệu quả và phát hiện lỗi sớm. Trên thực tế, các trang trại PV như vậy thường có công suất lớn (ví dụ: hàng trăm MW hoặc thậm chí lớn hơn) và nằm ở những địa điểm xa xôi không có bóng râm rõ ràng, ví dụ: đồng bằng và đồi núi, và trải dài trên một khu vực địa lý rộng lớn, như thể hiện trong Hình 1. Điều này mang đến những thách thức trực tiếp về việc theo dõi tình trạng hiệu quả và chẩn đoán lỗi [2].

Ủy ban Kỹ thuật Điện quốc tế (IEC) đã điều tra vấn đề độ tin cậy của các công nghệ quang điện (PV) từ nhiều khía cạnh khác nhau và tầm quan trọng của việc phát hiện suy thoái tiềm ẩn (PID) đã được

được nêu bật. Việc xác định kịp thời và chính xác các khiếm khuyết của mô-đun PV có thể đảm bảo tuổi thọ đầy đủ và phát điện hiệu quả của các mô-đun PV, và do đó đảm bảo hoạt động đáng tin cậy của toàn bộ các trang trại PV quy mô lớn [3, 4]. Các nhiệm vụ đánh giá tài sản thông thường đối với các trang trại PV thường do chuyên viên thực hiện đối với từng mô-đun PV.

Các lỗi và hỏng hóc của mô-đun được xác định bằng cách sử dụng các phép đo điện (ví dụ: điện áp, dòng điện và công suất), kiểm tra trực quan hoặc phân tích nhiệt trong quá trình vận hành hệ thống [5]. Rõ ràng, các phương pháp đánh giá tài sản và chẩn đoán lỗi hiện có như vậy là không hiệu quả, thậm chí không khả thi, để áp dụng trong các hệ thống PV quy mô lớn trong thực tế do tỷ lệ lỗi cao và thời gian đánh giá dài.



Hình 1. Ví dụ về trang trại PV quy mô lớn.

Trong tài liệu, các hệ thống điều khiển từ xa tự động đã được áp dụng để đạt được mục tiêu giám sát tình trạng hiệu quả và bảo trì hệ thống cho các trang trại PV quy mô lớn (ví dụ: [6, 7]). Thông qua việc áp dụng các phương tiện bay không người lái (UAV), hệ thống kiểm tra có thể cung cấp dịch vụ kiểm tra và đánh giá tài sản đáng tin cậy và không phá hủy (phân tích tiên lượng và chẩn đoán lỗi) của các trang trại PV quy mô lớn với sự can thiệp của con người được giảm thiểu tối đa [8]. Giải pháp được đề xuất trong [8] nhằm mục đích tự động hóa các chức năng kiểm tra hệ thống và tiên lượng dựa trên trạng thái hoạt động của nhà máy PV do hệ thống điều khiển cung cấp. Nghiên cứu trong [9] đã triển khai giải pháp dựa trên nhiệt kế hồng ngoại bằng nền tảng phương tiện bay không người lái (UAV) và xác nhận hiệu quả của việc kiểm tra nhà máy PV dựa trên hồ sơ nhiệt độ. Trong [10], một phương pháp phát hiện lỗi tự động dựa trên nhiệt kế hồng ngoại đã được triển khai và đánh giá. Một

Hệ thống chụp ảnh nhiệt hồng ngoại gắn trên UAV được phát triển để phát hiện lỗi và định vị hiệu quả các tấm pin quang điện trong [11]. Phân tích thời gian thực dựa trên nhiệt ảnh IR đã được trình bày để xác định các khiếm khuyết tiềm ẩn của hệ thống PV trong [12]. Mặc dù cách tiếp cận như vậy đã được xác nhận là hiệu quả để phát hiện lỗi điểm nóng, nhưng nó không thể thực hiện phân tích cho các lỗi khác

Công trình này được hỗ trợ một phần bởi Quỹ Khoa học Tự nhiên Trung Quốc (51777183), Quỹ Khoa học Tự nhiên Tỉnh Chiết Giang (LZ15E070001).

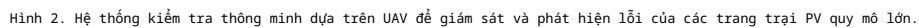
Các tác giả thuộc Khoa Kỹ thuật Điện, Đại học Chiết Giang, Hàng Châu, 310027, Trung Quốc. Tác giả liên hệ Q. Yang (email: qyang@zju.edu.cn)

dạng lỗi. Mặt khác, một số nỗ lực nghiên cứu đã khai thác nền tảng kiểm tra dựa trên UAV với camera ánh sáng để có được hình ảnh trên không của các mô-đun PV để chẩn đoán nhiều loại khuyết tật có thể nhìn thấy. Công trình trong [13] đã nghiên cứu quét hồng ngoại của các nhà máy điện mặt trời PV và nêu bật lợi ích của việc sử dụng giải pháp dựa trên UAV so với đánh giá mặt đất thông thường. Chụp ảnh nhiệt trực quan trên không dựa trên nền tảng UAV đã được áp dụng trong [14] để thực hiện các nhiệm vụ kiểm tra hệ thống và phát hiện lỗi bằng các kỹ thuật ghép ảnh. Trong [15], một giải pháp tự động dựa trên hình ảnh hồng ngoại trên không đã được phát triển để phát hiện và phân tích các bất thường về nhiệt độ trong các mô-đun quang điện, ví dụ: mô-đun quá nhiệt, điểm nóng và chuỗi con quá nhiệt. Công trình trước đây của chúng tôi [16] đã khai thác giải pháp chẩn đoán cho hai khuyết tật có thể nhìn thấy điển hình của các mô-đun PV, ví dụ: vết ố sên, bóng bụi, thông qua việc xác định chính xác các đặc điểm lỗi từ hình ảnh trên không thu được bằng các thuật toán nhận dạng mẫu. Tuy nhiên, cần lưu ý rằng hiệu suất phát hiện của phương pháp tiếp cận này có thể giảm đáng kể nếu hình ảnh trên không thu được có độ phân giải thấp do nhiều lý do, ví dụ như hiệu ứng gió và rung động của xe. Tóm lại, việc phát hiện và phân tích chính xác các dạng khiếm khuyết khác nhau của mô-đun PV trong các trang trại PV quy mô lớn đòi hỏi một giải pháp nhận dạng mẫu hiệu quả và mạnh mẽ hơn đối với hình ảnh trên không thu được trong quá trình kiểm tra UAV.

Để đạt được mục đích này, bài báo này khai thác một phương pháp mới để phát hiện và phân tích lỗi bằng cách sử dụng học sâu dựa trên CNN

Phần còn lại của bài báo được tổ chức như sau: Phần II tổng quan về hệ thống kiểm tra dựa trên UAV được phát triển cho các trang trại PV quy mô lớn; cấu trúc học sâu dựa trên CNN được trình bày trong Phần III; Phần IV cung cấp thông tin chi tiết về việc triển khai giải pháp được đề xuất và trình bày một tập hợp các kết quả số chính xác kèm theo thảo luận; và cuối cùng là các nhận xét kết luận được đưa ra trong Phần V.

Với thông tin địa lý của các trang trại PV và phạm vi bay, bộ xử lý trên không có thể lập kế hoạch đường bay phù hợp và thu thập hình ảnh trên không của các mô-đun PV trong quá trình kiểm tra. Việc điều khiển bay của UAV được thực hiện tại Trạm điều khiển mặt đất (GCS). Hình ảnh mô-đun PV được chụp có thể được truyền kịp thời đến GCS qua mạng truyền thông không dây dựa trên 4G để theo dõi tình trạng, sau đó được cung cấp cho hệ thống lưu trữ dữ liệu duy trì cơ sở dữ liệu hình ảnh được cập nhật. Hình ảnh mô-đun PV có sẵn được sử dụng để mô tả các đặc điểm của lỗi và hỏng mô-đun thông qua thuật toán dựa trên máy học theo cách ngoại tuyến.



Hiệu suất của thuật toán nhận dạng mẫu dựa trên học có giám sát được áp dụng có thể được cải thiện dần dần cùng với tính khả dụng tăng lên của hình ảnh trên không. Cần lưu ý rằng, mặc dù quá trình đào tạo ngoại tuyến có thể mất một khoảng thời gian nhất định (ví dụ: vài giờ) theo nền tảng tính toán được áp dụng, nhưng các lỗi mô-đun có thể được xác định bởi mô hình được đào tạo tốt theo cách gần như thời gian thực. Điều này ngụ ý rằng mô hình được đào tạo như vậy có thể được lập trình và tích hợp vào bộ xử lý trên bo mạch của nền tảng UAV để xác định lỗi trong quá trình kiểm tra trang trại PV. Kết quả phát hiện có thể được cung cấp cho trung tâm vận hành và bảo trì (OMC) của các trang trại PV.

Trong công trình này, hệ thống kiểm tra dựa trên UAV được phát triển để thực hiện các nhiệm vụ thu thập hình ảnh trên không và phát hiện khuyết tật. Hình ảnh mô-đun PV trên không được thu thập bằng máy ảnh phản xạ ống kính đơn kỹ thuật số (SLR) (Zenmuse X3) được gắn trên UAV hạng nhẹ (DJI Matrix100), như minh họa trong Hình 3. Các thông số kỹ thuật và tham số chi tiết của UAV được áp dụng trong công trình này được trình bày trong Bảng I. Bộ xử lý trên không (Manifold) và truyền dữ liệu không dây (LightBridge2) có thể thực hiện xử lý hình ảnh trên không hiệu quả trên bo mạch và truyền hình ảnh thời gian thực.

Do tiếp xúc lâu ngoài trời, các mô-đun PV bị ảnh hưởng trực tiếp bởi nhiều yếu tố môi trường khác nhau, ví dụ như gió, muối, tuyết và bụi, và các cơ chế lão hóa khác nhau có thể ảnh hưởng đến các mô-đun PV với hiện tượng không khớp tương quan [21].



Hình 3. Nền tảng phần cứng và các thành phần của UAV.


Hình 4 minh họa các khuyết tật phổ biến nhất có thể nhìn thấy của các mô-đun PV, bao gồm sự tách lớp chất đóng gói, che bụi, ăn mòn đường lưới, ổ vàng và vết ố sên. Sự mất độ bám dính giữa các lớp của mô-đun PV có thể gây ra sự tách lớp. Sự tách lớp chất đóng gói nghiêm trọng có thể làm tăng sự phản xạ và

sự xâm nhập của nước vào các mô-đun, dẫn đến tăng tốc quá trình oxy hóa tế bào và rủi ro vận hành [22-24]. Sự tích tụ bụi có thể làm giảm trực tiếp khả năng truyền ánh sáng và do đó làm giảm đáng kể hiệu suất phát điện quang điện, đôi khi có thể giảm 50% và thậm chí tệ hơn là 80% [25]. Các tế bào quang điện bị che bóng sẽ dẫn đến quá nhiệt làm hỏng các mô-đun [26, 27].

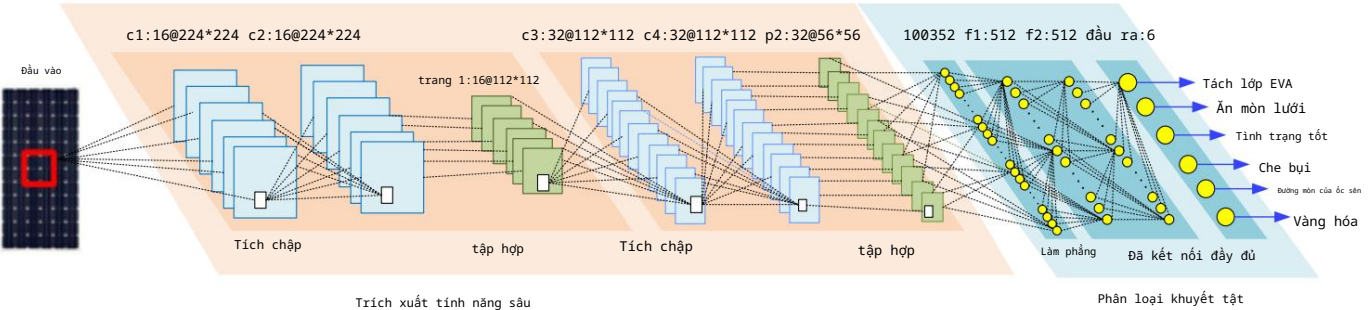
Các vết ố sên có thể không làm giảm trực tiếp hiệu quả phát điện, nhưng chúng thường liên quan đến các vết nứt vô hình của ô dẫn đến suy giảm phát điện đáng kể [28]. Việc phát hiện kịp thời và chính xác các lỗi mô-đun được coi là vô cùng quan trọng để ngăn chặn các trang trại PV khỏi tình trạng suy giảm hiệu suất nghiêm trọng và hỏng hóc vận hành.

BẢNG I: THÔNG SỐ KỸ THUẬT VÀ THÔNG SỐ CỦA NỀN TẢNG UAV.

Tham số	Giá trị
Tốc độ hành trình	5-10 m/giây
Phạm vi hoạt động	1 km
Độ cao nhiệm vụ	5-10 phút
Độ bền của chuyến bay	0,25-0,67 giờ
Cân nặng	3,6Kg
Chiều dài (động cơ đối xứng)	650mm
Sải cánh	0,3 phút
Động lực	Điện năng
Kích thước cảm biến hình ảnh	6,17mm×4,55mm
Độ phân giải tối đa	4000×2250



Hình 4. Các dạng khác nhau của các khuyết tật điển hình có thể nhìn thấy trong các mô-đun PV: (a) che phủ bởi bụi; (b) tách lớp chất đóng gói; (c) ăn mòn đường lưới; (d) vết ố sên; và (e) ổ vàng.



Hình 5. Kiến trúc trích xuất đặc điểm CNN về lỗi của mô-đun PV.

III. GIẢI PHÁP DỰA TRÊN CNN ĐƯỢC ĐỀ XUẤT ĐỂ CHẨN ĐOÁN KHUYẾT TẬT

Phần này trình bày chi tiết giải pháp dựa trên học sâu được đề xuất để chẩn đoán lỗi mô-đun PV. Ý tưởng đằng sau phương pháp này là để xác định các đặc điểm sâu từ hình ảnh mô-đun và thực hiện nhận dạng mẫu các lỗi thông qua mạng nơ-ron học sâu. Người ta biết rằng CNN là mạng nơ-ron truyền thẳng trong đó mỗi nơ-ron chỉ tác động đến các nơ-ron trong lớp liền kề và giữ nguyên tương quan không gian của hình ảnh, do đó có thể nắm bắt được các đặc điểm hình ảnh cục bộ. Trong CNN [29, 30], các phép toán tích chập và lấy mẫu phụ xen kẽ được thực hiện trước tiên, và cuối cùng là mạng nhiều lớp chung được áp dụng. Đầu ra được làm phẳng dưới dạng vectơ cho lớp được kết nối đầy đủ và

softmax [31] được sử dụng để phân loại các tính năng thu được thành một số lớp tương ứng.

A. Mô hình phân loại khuyết tật

Hình 5 minh họa cấu trúc CNN được áp dụng trong công trình này bao gồm 7 lớp đã học: bốn lớp tích chập (c1~c4) và ba lớp kết nối đầy đủ (f1, f2 và đầu ra). 4 lớp tích chập đầu tiên được sử dụng để trích xuất các đặc điểm CNN bằng cách sử dụng lần lượt 16, 16, 32 và 32 hạt nhân (7*7*3). Các đặc điểm đào tạo và thử nghiệm được trích xuất bởi hai lớp kết nối đầy đủ sau đây (f1 và f2) đều có 512 chiều. Đầu ra của lớp kết nối đầy đủ cuối cùng (tức là f2) được đưa vào bộ phân loại 6 chiều với Đơn vị tuyến tính chỉnh lưu phi tuyến tính (ReLU) [32] và có thể được phân loại thêm thành 6 nhãn lớp khác nhau. Để giảm độ phức tạp tính toán của mạng, các hạt nhân của lớp tích chập thứ hai và thứ tư, tức là c2 và c4, được theo sau bởi một lớp max-pooling tương ứng. Các tham số của cấu trúc CNN được áp dụng được đưa ra trong Bảng II.

BẢNG II: CẤU TRÚC CNN VÀ TRÍ CH XUẤT ĐẶC ĐIỂM.

Lớp	Hình dạng đầu ra	Các tham số
Tích chập (c1)	224, 224, 16	448
Tích chập (c2)	224, 224, 16	2320
Tổng hợp tối đa (p1)	112, 112, 16	0
Tích chập (c3)	112, 112, 32	4640
Tích chập (c4)	112, 112, 32	9248
Tổng hợp tối đa (p2)	56, 56, 32	0
Làm phẳng	100352	0
Đã kết nối đầy đủ (f1)	512	51380736
Đã kết nối đầy đủ (f2)	512	262656
Đã kết nối đầy đủ (đầu ra)	6	3078

B. Cập nhật tham số mô hình

Ở đây, tập dữ liệu của mô-đun PV thu thập được trên không nn hình ảnh được ký hiệu là $\{x_{ij}^{(n)}\}_{i=1}^{n \times n}$, $x_{ij}^{(n)}$, xy , trong đó n là chỉ số của mô-đun trong PV mảng, x biểu diễn hình ảnh mô-đun và y biểu thị nhãn lớp tương ứng. Đối với hàm đích, hàm mất lỗi bình phương được áp dụng. Đây là bài toán đa lớp với m lớp và q ví dụ đào tạo. Đối với một

mẫu, hàm chi phí được biểu thị như (1).

$$J = \frac{1}{2} \sum_{i=1}^N (t_i^N - y_i^N)^2 \tag{1}$$

Đối với một tập huấn luyện có q mẫu, hàm chi phí có thể được diễn đạt như sau:

$$J = \frac{1}{2} \sum_{n=1}^q \sum_{i=1}^N (t_i^N - y_i^N)^2 \tag{2}$$

Ở đây t_i^N là k mục tiêu tương ứng (nhãn) trong mẫu n, và y_i^N là giá trị của đơn vị lớp đầu ra.

Mạng có thể được đào tạo với tập dữ liệu có sẵn bằng cách giảm dần độ dốc ngẫu nhiên. Trong quá trình đào tạo, a được đưa động lượng vào để tăng tốc độ hội tụ hoặc bù đắp độ dốc để ngăn ngừa sự phân kỳ [33]. Một lượng nhỏ suy giảm trọng số có thể giảm thiểu lỗi đào tạo mô hình. Thông qua việc giảm dần độ dốc của các tham số hàm chi phí lỗi, trọng số W được cập nhật với việc giảm dần độ dốc dựa trên (3) và (4).

$$W_{ij}^{l+1} = W_{ij}^l - \eta \frac{\partial J}{\partial W_{ij}^l} \tag{3}$$

Ở đây η (4) biểu thị tốc độ học tập, v là động lượng biến đổi, W_{ij}^l và v biểu diễn trọng lượng và động lượng giữa đơn vị i của lớp l và đơn vị j của lớp l-1,

và $\frac{\partial J}{\partial W_{ij}^l}$ là độ dốc của trọng số hạt nhân.

Hàm chi phí tổng thể được giảm liên tục để cập nhật các tham số và xây dựng mạng lý tưởng theo phương trình (1)-(4).

Thông qua việc chia sẻ trọng số và gộp nhóm, nó có thể làm giảm đáng kể độ phức tạp tính toán của mạng và dần dần xây dựng thêm tính bất biến không gian và có thể cấu hình. Các tham số CNN được cập nhật nhằm mục đích tạo ra các dự đoán lỗi chính xác hơn trong quá trình đào tạo. Các siêu tham số được khởi tạo của cấu trúc CNN được đưa ra trong Bảng III.

BẢNG III: SIÊU THAM SỐ KHỞI TẠO CỦA KIẾN TRÚC CNN.

Sự miêu tả	Biểu tượng	Giá trị
Kích thước niềng và	P_s	16
Kích thước lỗ hàng	b_s	16
Kích thước hạt nhân Gaussian	σ	0,01
Tỷ lệ học tập		0,01
động lượng		0,9
giảm cân		0,01
Thời gian lặp lại	T	400

IV. PHÂN TÍCH THỰC NGHIỆM VÀ KẾT QUẢ

Phần này đánh giá phương pháp dựa trên CNN được đề xuất để phân tích lỗi mô-đun PV thông qua các thử nghiệm mở rộng từ nhiều khía cạnh khác nhau và so sánh hiệu suất của nó với các giải pháp hiện có.

A. Thiết lập thử nghiệm

Hiện tại tập dữ liệu bao gồm số lượng đủ
Hình ảnh mô-đun PV với các dạng khuyết tật khác nhau khó có thể lấy được từ phạm vi công cộng. Trong nghiên cứu này, bộ sưu tập hình ảnh mô-đun PV trên không chủ yếu lấy từ ba nguồn: Hình ảnh mô-đun PV thu thập được trong quá trình kiểm tra thực địa thủ công, hình ảnh mô-đun tổng hợp được tạo ra với các khuyết tật điển hình và hình ảnh mô-đun trên không thu được trong quá trình kiểm tra thực địa dựa trên UAV tại ba trang trại PV thực tế: một trang trại PV (100 MW) ở Đại Đồng, Tỉnh Sơn Tây, một trang trại PV (100 MW) ở Vô Tích, Tỉnh Giang Tây và một trang trại PV (80 MW) ở Thái Châu, Tỉnh Chiết Giang, Trung Quốc. Các hình ảnh trên không thu được được xử lý trước khi phân tích thêm vì chúng chắc chắn có các mức độ nhiễu và biến dạng khác nhau và được chụp ở các góc nghiêng. Trong công trình này, tập dữ liệu hình ảnh bao gồm tổng cộng 8400 mẫu hình ảnh trên không của các mô-đun PV trong 6 điều kiện khác nhau (1400 mẫu cho mỗi điều kiện), bao gồm 5 loại khuyết tật khác nhau (bụi che bóng, tách lớp chất đóng gói, ăn mòn đường lưới, vết ốc sên và ổ vàng, như đã đề cập trong Hình 4), như thể hiện trong Bảng IV.

BẢNG IV: CÁC ĐIỀU KIỆN KHÁC NHAU CỦA CÁC MÔ-ĐUN PV.

Khuyết điểm	Tình trạng mô-đun PV	Quy mô	Kích thước	Kích thước của
mẫu train		đào tạo	thực nghiệm	bài kiểm tra
mẫu	mẫu	mẫu	mẫu	mẫu
#0	Che bụi	980	280	140
#1	Tách lớp chất đóng gói	980	280	140
#2	Không có khuyết điểm	980	280	140
#3	Ăn mòn lưới	980	280	140
#4	Đường mòn của ốc sên	980	280	140
#5	vàng ổ	980	280	140

Các mẫu hình ảnh được chia thành ba tập con: tập huấn luyện (70%, tức là 5880 mẫu), tập xác thực (20%, tức là 1680 mẫu) và tập kiểm tra (10%, tức là 840 mẫu). Tập huấn luyện và tập xác thực được sử dụng để điều chỉnh tham số thông qua việc học và điều chỉnh các tham số tương ứng.

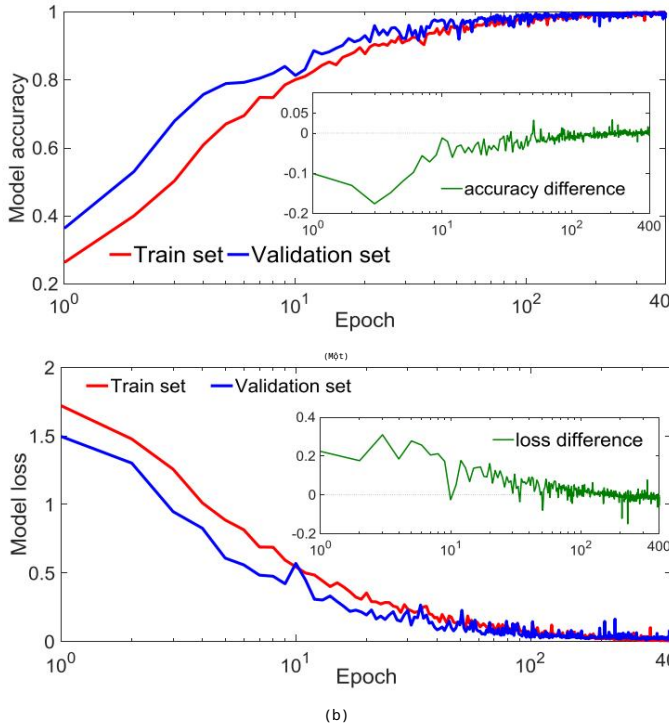
Cuối cùng, bộ kiểm tra được sử dụng để đánh giá hiệu suất của mô hình đã được đào tạo nhằm xác định các loại lỗi khác nhau của mô-đun PV.

Trong các thí nghiệm, các đặc điểm sâu được trích xuất từ các lớp được kết nối đầy đủ 512 chiều, tức là f1 và f2 (Bảng II), và cùng một tốc độ học được áp dụng cho tất cả các lớp tích chập. Việc trích xuất đặc điểm dựa trên CNN như vậy được triển khai trong python dựa trên tensorflow. Ngoài ra, để tăng tốc quá trình đào tạo, các tế bào thần kinh không bão hòa và nền tảng tính toán hiệu suất cao (với 4 GPU NVIDIA TITAN) được sử dụng để thực hiện hoạt động tích chập. Mạng dựa trên CNN được đề xuất được đào tạo trong khoảng 400 chu kỳ mất khoảng 8 giờ bằng cách sử dụng nền tảng tính toán.

B. Quá trình đào tạo và hiệu suất mô hình

Mô hình dựa trên CNN được đề xuất đầu tiên được đánh giá bằng cách sử dụng tập dữ liệu xác thực trước khi được áp dụng để xác định lỗi và phân tích các mô-đun PV. Hình 6 cho thấy hiệu suất của mô hình về độ chính xác và hàm mất mát

so với số lần lặp trong quá trình đào tạo. Nó cho thấy rằng việc đào tạo bộ phân loại CNN được đề xuất có thể nhanh chóng hội tụ đối với các ví dụ hình ảnh xác thực với lỗi tối thiểu, điều này xác nhận khả năng khái quát hóa tuyệt vời của cấu trúc mạng được áp dụng. Độ chính xác phát hiện của mô hình được đề xuất được cải thiện cùng với sự gia tăng số lượng kỷ nguyên, như thể hiện trong Hình.6 (a). Nó cũng cho thấy rằng tổn thất mô hình giảm đáng kể cùng với sự gia tăng số lần lặp và tổn thất đạt khoảng 0,03 ở lần lặp thứ 100, như thể hiện trong Hình.6 (b). Mô hình thu được sau quá trình đào tạo có thể đạt độ chính xác nhận dạng 98,5% đối với các lỗi mô-đun. Điều này chỉ ra rằng một mô hình được đào tạo tốt có thể thu được sau một số lần lặp giới hạn với độ phức tạp tính toán chấp nhận được.



Hình 6 Đánh giá hiệu suất mô hình (a) độ chính xác của mô hình; và (b) hàm mất mát của mô hình so với số lần lặp lại.

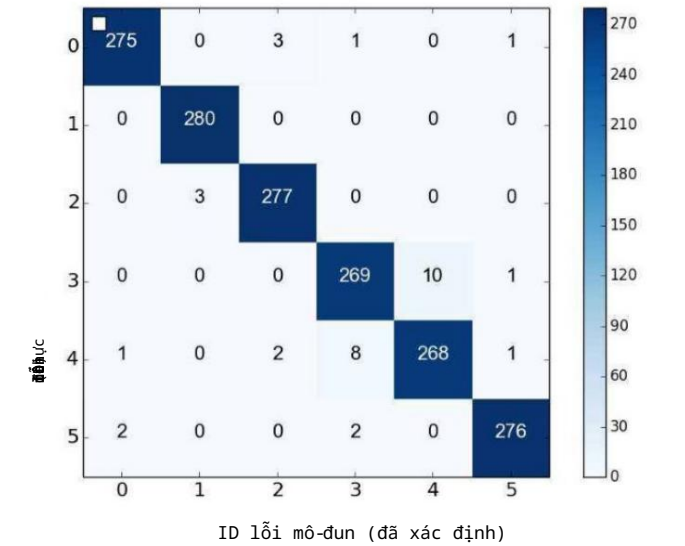
Cấu trúc CNN được đề xuất được đánh giá cho các điều kiện hoạt động khác nhau của mô-đun PV và kết quả số được trình bày bằng cách sử dụng ma trận nhầm lẫn, như minh họa trong Hình 7.

Ma trận nhầm lẫn trình bày phân loại của tất cả các điều kiện mô-đun PV và chỉ ra độ chính xác phân loại và lỗi phân loại sai. Trục tung và trục hoành của ma trận nhầm lẫn lần lượt đề cập đến các loại lỗi thực tế (ID #0-#5) và các loại lỗi đã xác định. Có thể thấy rõ ràng rằng giải pháp được đề xuất có thể xác định chính xác các dạng lỗi khác nhau của mô-đun PV với độ chính xác cao. Ma trận nhầm lẫn cũng cho thấy ăn mòn đường lưới (ID #3) và đường mòn ốc sên (ID #4) có độ chính xác phát hiện thấp hơn và do đó cần nhiều tính năng hơn để phân biệt hiệu quả hai loại lỗi này.

Dựa trên mô hình đào tạo đã đề cập ở trên, hiệu suất để xác định lỗi PV được đánh giá thêm bằng cách sử dụng 840 mẫu (tức là 140 mẫu cho mỗi điều kiện mô-đun PV). Kết quả số được trình bày trong Bảng V chứng minh rằng tất cả các loại lỗi mô-đun đều có thể được xác định

¹ Bộ dữ liệu hình ảnh mô-đun PV được sử dụng trong công trình này có thể được cung cấp theo yêu cầu.

với độ chính xác cao (trên 95%) với độ chính xác trung bình là 97,9% cho tất cả các điều kiện mô-đun.




Hình 7. Ma trận nhầm lẫn của phân loại lỗi sử dụng mô hình đã được đào tạo.

BẢNG V: KẾT QUẢ SO SÁNH HIỆU SUẤT TRÊN CÁC LỖI PV KHÁC NHAU .

Mã số #0	Mã số #1	Mã số #2	Mã số #3	Mã số #4	Mã số #5
Bụi	Chất đóng gói	KHÔNG	LƯỚI	ốC sên	Vàng hóa
bóng đổ	sự tách lớp	khuyết tật	sự ăn mòn		
98,2%	100%	98,9%	96,1%	95,7%	98,5%

Để đánh giá khả năng của mô hình học sâu được đề xuất để tự động trích xuất các đặc điểm lỗi của mô-đun PV, cần kiểm tra các đặc điểm lớp trong quá trình học. Do thực tế là các đặc điểm dữ liệu (512 chiều) được trích xuất từ các lớp được kết nối đầy đủ (tức là f1 và f2) đều có chiều cao, nên phương pháp giảm chiều phi tuyến tính, nhúng lân cận ngẫu nhiên phân tán t (t-SNE), được áp dụng để phân tích và trực quan hóa các đặc điểm đã học và làm nổi bật bất thông tin ẩn hữu ích trong các hình ảnh mô-đun gốc. Hình 8 minh họa các đặc điểm dữ liệu 512 chiều được trích xuất cho 6 điều kiện mô-đun PV khác nhau (bao gồm trường hợp không có lỗi và 5 loại lỗi) bằng cách sử dụng t-SNE có thể phân biệt rõ ràng.



Hình 8 t-SNE của các tính năng đã học bằng cách sử dụng mô hình đào tạo được đề xuất cho bộ xác thực.

C. Phân tích hiệu suất xác định lỗi PV

Tại đây, hiệu suất của giải pháp phát hiện và phân tích lỗi dựa trên CNN được đề xuất được đánh giá từ nhiều khía cạnh khác nhau, ví dụ, hiệu suất so với các lựa chọn tham số và kích thước khác nhau của tập dữ liệu hình ảnh, và được đánh giá khi so sánh với các giải pháp hiện có thông qua một loạt các thử nghiệm.

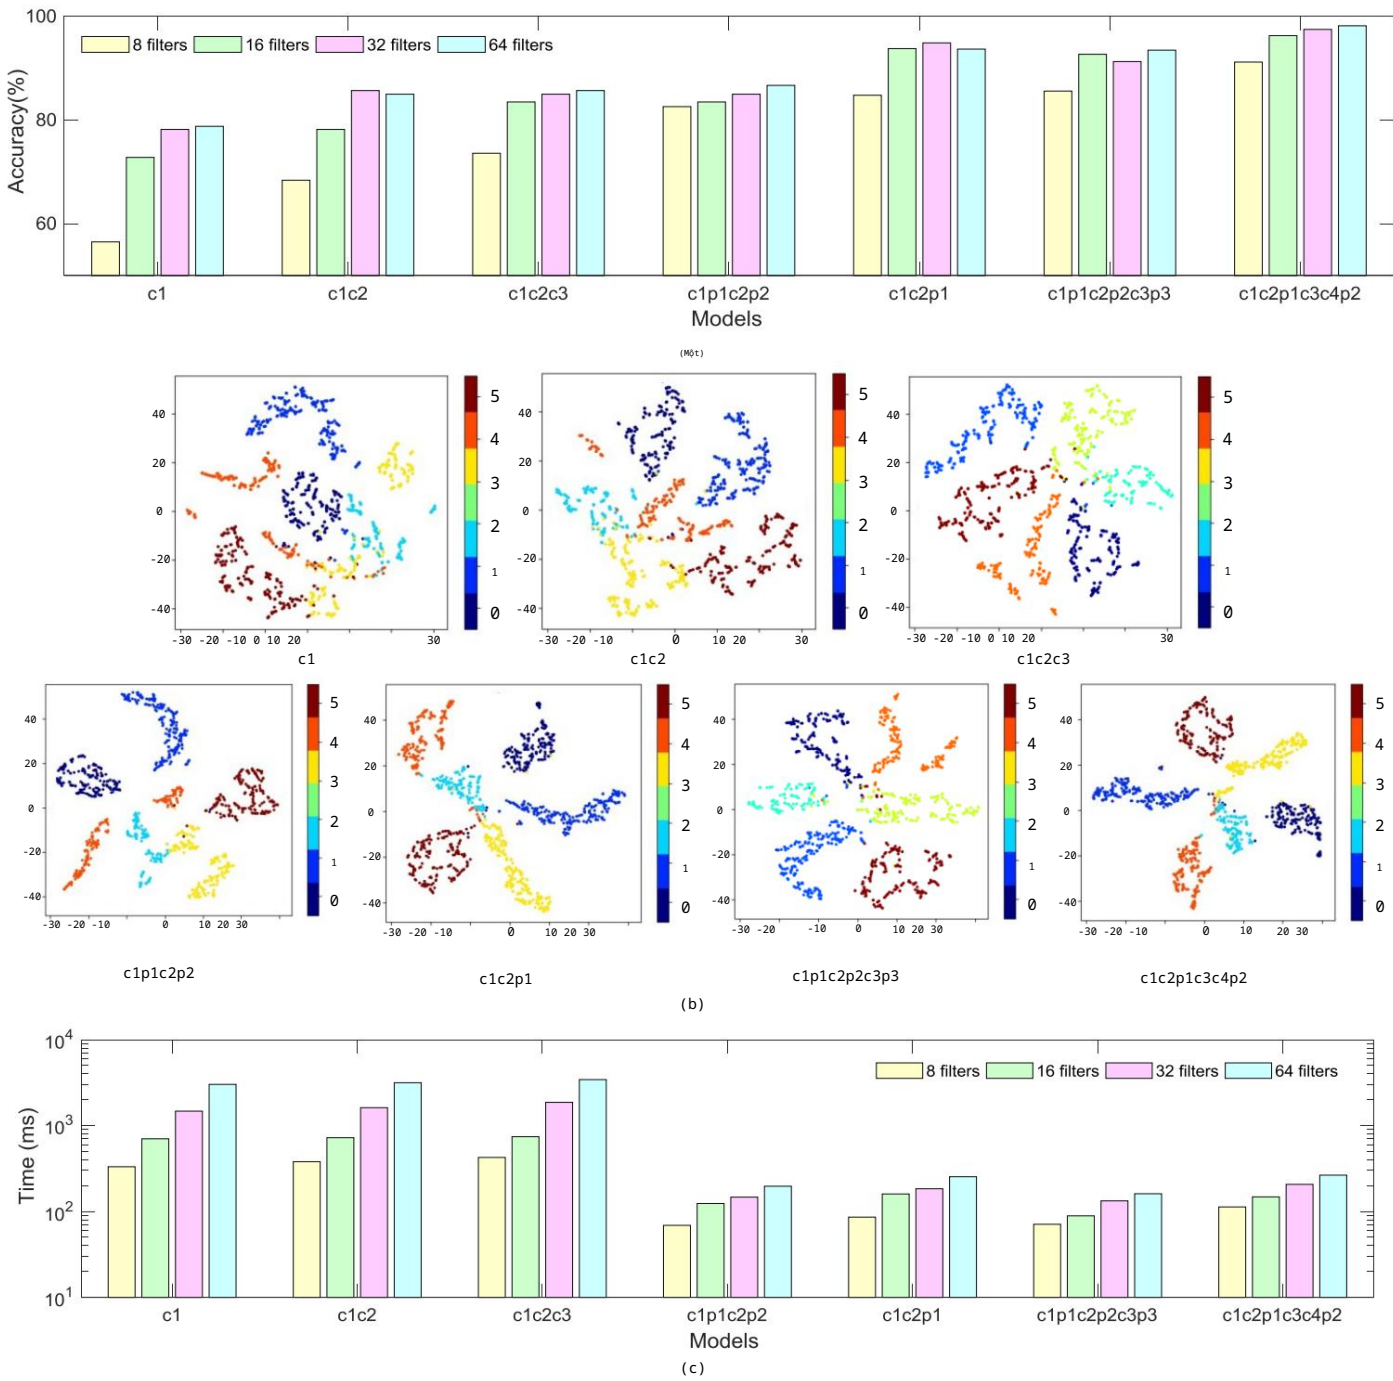
Trường hợp 1: Hiệu suất với lựa chọn tham số khác nhau

Tác động của độ sâu mạng: Cấu trúc mạng có thể ảnh hưởng lớn đến hiệu suất của giải pháp được đề xuất. Do đó, hiệu suất so với số lượng lớp tích chập khác nhau (mỗi lớp chứa 16 bản đồ đặc trưng) trước tiên được đánh giá thông qua các thí nghiệm để định lượng tác động của độ sâu mạng. Hình 9 (a) trình bày kết quả của lỗi kiểm tra trung bình của 840 lần thử dự đoán (tức là các mẫu xác thực) cho một loạt các mô hình với số lượng lớp tích chập khác nhau, tức là c1, c1c2, c1c2c3, c1p1c2p2, c1c2p1, c1p1c2p2c3p3 và c1c2p1c3c4p2. Hình 9 (b) cho thấy kết quả t-SNE của các đặc trưng đã học được cho các mô hình khác nhau, các đặc trưng dữ liệu được trích xuất từ 6 loại trong c1 phân tán không gian và hầu hết chúng chồng chéo lên nhau, điều này khó có thể phân biệt được. So sánh với mô hình c1, c1c2 và c1c2c3, nhiều lớp tích chập hơn không dẫn đến cải thiện đáng kể về độ chính xác phát hiện và hai lớp tích chập được coi là đủ trong trường hợp được đánh giá, như được chỉ ra từ Hình 9 (b). Kết quả thể hiện trong Hình 9 (c) cho thấy việc tăng số lớp có thể làm tăng thêm độ phức tạp về mặt tính toán nhưng khó có thể cải thiện độ chính xác của việc xác định khuyết tật.

Tác động của gộp ngẫu nhiên: Thêm một lớp gộp vào các lớp tích chập, nó có thể làm giảm đáng kể độ phức tạp tính toán của mạng. Hình 9 (a) và (c) lần lượt hiển thị độ chính xác trung bình của tập dữ liệu thử nghiệm và thời gian tiêu thụ để phát hiện lỗi. Đánh giá được thực hiện với các cấu trúc khác nhau (như một cp, lớp tích chập với một lớp gộp (c1p1), hai lớp tích chập với một lớp gộp (c1c2p1)). Có thể thấy rằng độ chính xác kiểm tra trung bình với 100 lần thử nghiệm (c1c2p1) chính xác hơn mô hình c1c2 và thời gian tiêu thụ giảm đáng kể, như thể hiện trong Hình 9 (c). Điều này là do gộp làm giảm chiều và do đó kích thích tính toán trọng số đầu ra.

Ngoài ra, mô hình c1c2p1 cho thấy hiệu suất tốt hơn mô hình c1p1c2p2, giống như mô hình c1p1c2p2c3p3 và c1c2p1c3c4p2. Điều này cho thấy cấu trúc mô hình ()m cp tốt hơn cấu trúc ()m cp. Ngoài ra, độ chính xác trung bình của mô hình c1c2p1c3c4p2 là khoảng 97%. Hình 9 (b) cho thấy các tính năng được trích xuất từ ảnh mô-đun trên không cho các loại điều kiện mô-đun PV khác nhau có thể dễ dàng phân biệt thông qua việc bổ sung các lớp gộp.

Hình 9 (c) cho thấy rõ ràng rằng các mô hình với số lượng bộ lọc khác nhau có thể đưa ra các độ phức tạp tính toán khác nhau với thời gian tính toán từ hàng trăm mili giây đến hàng nghìn mili giây, được coi là có thể chấp nhận được trong thực tế.



Hình 9 Đánh giá hiệu suất của các thử nghiệm nhận dạng sử dụng các mô hình khác nhau (a) độ chính xác trung bình của phát hiện lỗi; (b) t-SNE của các tính năng đã học; và (c) thời gian trung bình tiêu thụ để phát hiện lỗi.

Tác động của số lượng bộ lọc: Kết quả thể hiện trong Hình 9(a) chứng minh rằng độ chính xác phát hiện lỗi mô-đun PV có thể được cải thiện đáng kể khi số lượng bộ lọc tăng từ 8 lên 64, đặc biệt đối với mô hình c1 và c1c2. Điều này chỉ ra rằng số lượng bộ lọc lớn hơn có thể tăng cường khả năng phát hiện sâu các lỗi mô-đun. Tuy nhiên, một khi độ sâu mạng đủ (hơn hai lớp tích chập), ví dụ, mô hình c1c2c3, c1c2p1, c1p1c2p2c3p3 và c1c2p1c3c4p2, không thể đạt được cải thiện hiệu suất đáng kể nào khi số lượng bộ lọc vượt quá 16 bộ lọc, như thể hiện trong Hình 9 (a). Quan sát như vậy ngụ ý rằng 16 bộ lọc là đủ để nhận dạng và

Phân tích các lỗi mô-đun trong nghiên cứu này có xét đến độ phức tạp thời gian được đưa vào. Qua phân tích trên, có thể thấy mô hình c1c2p1c3c4p2 với 16 bộ lọc có thể đáp ứng được yêu cầu nhận dạng lỗi và đưa ra sự cân bằng tốt nhất giữa độ chính xác phát hiện và độ phức tạp tính toán.

Trường hợp 2: Hiệu suất với các kích thước tập dữ liệu khác nhau

Trường hợp này đánh giá hiệu suất của giải pháp đề xuất cho các kích thước tập dữ liệu khác nhau, từ 600 mẫu đến 8400 mẫu. Kết quả được trình bày trong Bảng VI cho thấy xu hướng biến thiên của độ chính xác cùng với các kích thước tập dữ liệu khác nhau. Nó cho thấy hiệu suất của mạng được cải thiện theo


với sự gia tăng kích thước tập dữ liệu. Đặc biệt, khi kích thước tập dữ liệu đạt 6000 mẫu (tức là 1000 mẫu cho mỗi loại điều kiện PV), hiệu suất cải thiện đáng kể của giải pháp được đề xuất được quan sát thấy. Trên thực tế, hiệu suất và khả năng thích ứng của nhận dạng mẫu các lỗi mô-đun PV có thể được cải thiện hơn nữa khi có đủ các mẫu ảnh trên không.

BẢNG VI: ĐỘ CHÍNH XÁC C THEO CÁC SỐ MẪU KHÁC C NHAU.

Số lượng mẫu	600	Độ chính xác (%)	1200	1800	2400	3000	3600	4200		
6000	6600	7200	7800	8400						
Độ chính xác (%)	26,5	97,3	98,9	98,6	98,7	98,5				

Trường hợp 3: Hiệu suất của các tính năng đã học ở các lớp khác nhau

Để minh họa khả năng của mô hình học sâu được đề xuất trong việc trích xuất đặc điểm khuyết tật từ hình ảnh mô-đun PV trên không, quá trình học được kiểm tra từng lớp một cách chi tiết. Hình 10 trình bày các đặc điểm sâu được trích xuất thu được bằng t-SNE, có thể làm nổi bật thông tin ẩn hữu ích trong dữ liệu đầu vào thô (hình ảnh mô-đun trên không gốc).



Hình 10. Phép chiếu t-SNE của các đặc điểm đã học được sử dụng phương pháp đề xuất. (a) các đặc điểm dữ liệu thô (được trích xuất bởi bốn lớp tích chập đầu tiên); (b) các đặc điểm trong lớp được kết nối đầy đủ đầu tiên; và (c) các đặc điểm trong lớp được kết nối đầy đủ thứ hai.

Hình 10 (a) cho thấy các đặc điểm dữ liệu thô được trích xuất sau bốn lớp tích chập đầu tiên khó phân biệt được với nhau. Hình 10 (b) cho thấy các đặc điểm sâu thu được bằng t-SNE từ các đặc điểm cấp độ kết nối đầy đủ đầu tiên (tức là f1) có thể cải thiện hiệu suất nhận dạng khi so sánh với các đặc điểm dữ liệu thô. Hơn nữa, các đặc điểm sâu từ các đặc điểm cấp độ kết nối đầy đủ thứ hai (tức là f2), như thể hiện trong Hình 10 (c), có thể phân biệt rõ ràng các đặc điểm khuyết tật khác nhau. Điều này cho thấy các đặc điểm cấp độ cao hơn có thể biểu diễn các tín hiệu được đo chính xác hơn

hơn các tính năng cấp thấp hơn. Do đó, đánh giá khẳng định rõ ràng khả năng và khả năng thích ứng của giải pháp đề xuất trong quá trình học tập.

Trường hợp 4: So sánh hiệu suất với giải pháp thông thường

Cuối cùng, hiệu suất của giải pháp dựa trên CNN được đề xuất được đánh giá thêm khi so sánh với thuật toán nhận dạng mẫu thông thường [16] và Vgg16 được đào tạo trước trong ImageNet [17].

Bảng VII trình bày kết quả so sánh để xác định các loại lỗi khác nhau của mô-đun PV dựa trên tập dữ liệu hình ảnh được áp dụng. Nó cho thấy thuật toán nhận dạng mẫu thông thường được đề xuất trong [16] có thể hoạt động tốt đối với các lỗi về bóng bụi và ổ vàng với độ chính xác lần lượt là 89,7% và 96,8%, thông qua việc trích xuất các đặc điểm lỗi từ các mẫu hình ảnh có sẵn. Tuy nhiên, hiệu suất chẩn đoán của phương pháp tiếp cận như vậy có thể giảm đáng kể đối với một số lỗi mô-đun PV có cùng

đặc điểm, ví dụ, đường đi của ốc sên và ăn mòn đường lưới với độ chính xác phát hiện lần lượt là 48,3% và 47,9%, do khả năng thích ứng và độ bền hạn chế.

Đối với Vgg16 được đào tạo trước [17], trước tiên nó được sử dụng để trích xuất các tính năng có sẵn của các mô-đun PV từ các lớp ẩn được kết nối đầy đủ trước khi thực hiện phân loại khuyết tật bằng bộ phân loại SVM. Điều này cho thấy Vgg16 được đào tạo trước có thể cung cấp hiệu suất được cải thiện trong việc phát hiện và phân tích các vết ốc sên và ăn mòn đường lưới so với giải pháp nhận dạng mẫu thông thường [16].

Tuy nhiên, hiệu suất như vậy vẫn được coi là không đủ tin cậy và chính xác đối với tất cả các lỗi mô-đun điển hình để đáp ứng yêu cầu kiểm tra. Kết quả số được hiển thị trong Bảng VII xác nhận rõ ràng rằng giải pháp đề xuất vượt trội trong tất cả các trường hợp được đánh giá để chẩn đoán các tình huống lỗi mô-đun khác nhau với độ chính xác cao trên 97%.

BẢNG VII: SO SÁNH HIỆU SUẤT CHO CÁC LỖI PV KHÁC C NHAU.

Loại khuyết tật	Thông thường giải pháp [16]	Đã được đào tạo trước Vgg16 [17]	Đề xuất giải pháp
Che bụi	89,7%	76,3%	pháp 97,8%
Chất đóng gói sự tách lớp	77,5%	68,6%	99,5%
Không có khuyết tật	86,8%	89,4%	98,5%
Ăn mòn	47,9%	67,6%	98,0%
Lưới	48,3%	67,9%	97,8%
Đường mòn của ốc sên			
chuyển sang màu vàng	96,8%	73,5%	98,1%

V. KẾT LUẬN VÀ THẢO LUẬN

Bài báo này trình bày một hệ thống kiểm tra tự động dựa trên UAV với chức năng chẩn đoán lỗi dựa trên học sâu CNN để đánh giá tình trạng hoạt động của các mô-đun trong quá trình kiểm tra các trang trại PV quy mô lớn. Giải pháp phát hiện và phân tích lỗi được đề xuất được đánh giá rộng rãi so với các giải pháp hiện có thông qua một nghiên cứu so sánh.

Kết quả số xác nhận rõ ràng hiệu quả của nó trong việc chẩn đoán các dạng khuyết tật điển hình khác nhau của các mô-đun PV, bao gồm che bụi, tách lớp chất đóng gói, ăn mòn đường lưới, vết ốc sên và ổ vàng, với độ chính xác cao. Phương pháp đánh giá mô-đun như vậy có thể được thực hiện theo thời gian thực với mô hình được đào tạo tốt và do đó có thể được tích hợp trên bo mạch trong nền tảng UAV để kiểm tra hiệu quả các trang trại PV quy mô lớn với các rào cản triển khai được giảm thiểu.

Với sự tôn trọng đối với công việc trong tương lai, một số hướng nghiên cứu được coi là đáng để nghiên cứu và nỗ lực triển khai thêm. Mô hình phát hiện lỗi được đào tạo ngoại tuyến có thể được lập trình vào bộ xử lý trên không của nền tảng UAV để thực hiện phát hiện lỗi theo thời gian thực trong quá trình kiểm tra. Độ tin cậy và độ bền của hệ thống kiểm tra dựa trên UAV được đề xuất cùng với giải pháp phát hiện lỗi học sâu cần được xác thực và cải thiện thêm thông qua các đánh giá thực địa mở rộng.

Ngoài ra, việc phân tích dữ liệu về các phép đo điện theo thời gian thực của các mô-đun PV đang hoạt động thu được từ cơ sở hạ tầng giám sát hệ thống cơ bản có thể được sử dụng kết hợp với giải pháp được đề xuất để cải thiện hơn nữa hiệu suất kiểm tra và đánh giá tài sản.

TÀI LIỆU THAM KHẢO:

[1] Cơ quan Năng lượng Quốc tế (2017), “Năng lượng tái tạo 2017” (Trực tuyến). Có sẵn tại <http://www.iea.org/renewables/>.

[2] S. Tatapudi et al., “Kiểm tra lỗi và an toàn của 6 công nghệ PV từ 56.000 mô-đun đại diện cho 257.000 mô-đun ở 4 vùng khí hậu của Hoa Kỳ”, Proc. PVSC, Washington, DC, Hoa Kỳ, tháng 6 năm 2016.

[3] H. Denio et al., “Nhiệt ảnh mặt trời trên không và giám sát tình trạng của hệ thống quang điện”, Proc. PVSC, Austin, TX, Hoa Kỳ, tháng 6 năm 2012.

[4] M. Köntges, S. Kurtz, C. Packard, et al., “Đánh giá các lỗi của mô-đun quang điện”, IEA-Photovolt. Power Syst. Program, trang 1-140, 2014.

[5] M. Munoz, M. Alonso-Garcia, N. Vela và F. Chenlo, “Sự suy thoái sớm của các mô-đun PV silicon và các điều kiện bảo hành”, Sol. Energy, tập 85, số 9, trang 2264-2274, tháng 9 năm 2011.

[6] J. Tsanakas, L. Ha, F. Al Shakarchi, “Kiểm tra nâng cao các cơ sở quang điện bằng phương pháp tam giác hóa trên không và tham chiếu địa lý trên mặt đất của hình ảnh nhiệt/hình ảnh”, Renew. Energy, tập 102, trang 224-233, tháng 3 năm 2017.

[7] F. Grimaccia, S. Leva, A. Niccolai, “Bản đồ kỹ thuật số nhà máy điện mặt trời để phát hiện lỗi mô-đun bằng máy bay không người lái”, IET Renew. Power Gener., tập 11, số 10, trang 1221-1228, tháng 8 năm 2017.

[8] M. Aghaei, F. Grimaccia, C. Gonano, et al., “Hệ thống điều khiển tự động sáng tạo để kiểm tra và điều khiển từ xa các cánh đồng PV”, IEEE Trans. Ind. Electron., tập 62, trang 7287-7296, tháng 8 năm 2015.

[9] C. Buerhop, T. Pickel, M. Dalsass, “aIR-PV-check: kiểm tra chất lượng nhà máy điện PV mà không gián đoạn hoạt động”, Proc. PVSC, Portland, OR, Hoa Kỳ, tháng 6 năm 2016.

[10] X. Gao et al., “Tự động nhận dạng tấm pin mặt trời và phát hiện lỗi bằng hình ảnh hồng ngoại”, Proc. SPIE, Baltimore, MD, Hoa Kỳ, tháng 5 năm 2015.

[11] P. Zhang, L. Zhang và cộng sự, “Phát hiện và xác định vị trí bám bản trên tấm pin quang điện bằng hệ thống chụp ảnh nhiệt hồng ngoại gắn trên máy bay không người lái”, J. Appl. Remote Sens, tập 11, trang 016026, tháng 2 năm 2017.

[12] M. Aghaei et al., “Phân tích thời gian thực IR để giám sát hệ thống PV bằng các kỹ thuật xử lý hình ảnh kỹ thuật số”, Proc. EBCCSP, Krakow, Ba Lan, Hoa Kỳ, tháng 6 năm 2015.

[13] T. Kauppinen và cộng sự, “Về quét hồng ngoại của nhà máy điện mặt trời quang điện”, Proc. SPIE, Baltimore, MD, Hoa Kỳ, tháng 5 năm 2015.

[14] M. Aghaei, S. Leva, F. Grimaccia, “Kiểm tra nhà máy điện PV bằng kỹ thuật ghép ảnh cho hình ảnh thời gian thực IR”, Proc. PVSC, Portland, OR, Hoa Kỳ, tháng 6 năm 2016.

[15] S. Dotenco et al., “Tự động phát hiện và phân tích các mô-đun quang điện trong hình ảnh hồng ngoại trên không”, Proc. WACV, Lake Placid, NY, Hoa Kỳ, tháng 3 năm 2016.

[16] X. Li, Q. Yang, Z. Chen, et al., “Phát hiện khuyết tật có thể nhìn thấy dựa trên kiểm tra bằng UAV trong hệ thống quang điện quy mô lớn”, IET Renew. Power Gener., tập 11, trang 1234-1244, tháng 8 năm 2017.

[17] KW. Kim, HG. Hong, GP. Nam, “Một nghiên cứu về phân loại mất nhem và mờ dựa trên CNN sâu bằng cảm biến camera ánh sáng khả kiến”, Sensors, tập 17, trang 21, tháng 6 năm 2017.

[18] W. Zhao, L. Jiao, W. Ma, “Superpixel-based multiple local CNN for panchromatic and multispectral image classification”, IEEE Trans. on Geosci. Remote Sens., tập 55, trang 4141-4156, tháng 4 năm 2017.

[19] J. Acquarelli, T. Laarhoven, J. Gerretzen, “Mạng nơ-ron tích chập để phân tích dữ liệu quang phổ rung động”, Anal. Chim. Acta, tập 954, trang 1873-4324, tháng 2 năm 2017.

[20] S. Hoo-Chang, et al., “Mạng nơ-ron tích chập sâu để phát hiện bằng máy tính: Kiến trúc CNN, đặc điểm tập dữ liệu và học chuyển giao”, IEEE Trans. Med. Imag., tập 35, trang 1285-1298, tháng 2. 2015.

[21] S. Mohammed, B. Boumediene, B. Miloud, “Đánh giá sự suy thoái của các mô-đun PV dựa trên hiệu suất và kiểm tra trực quan ở sa mạc Sahara Algeria”, Tạp chí nghiên cứu năng lượng tái tạo quốc tế, tập 6, số 1, trang 106-116, tháng 1 năm 2016.

[22] A. Bouraiou, M. Hamouda, A. Chaker, et al., “Phân tích và đánh giá tác động của điều kiện khí hậu đến hiệu suất của các mô-đun quang điện trong môi trường sa mạc”, Energy Convers. Manage., tập 106, trang 1345-1355, tháng 12 năm 2015.

[23] A. Skoczek, T. Sample, E. Dunlop và H. Ossenbrink, “Kết quả hiệu suất điện tử thử nghiệm ứng suất vật lý của các mô-đun PV thương mại theo trình tự thử nghiệm IEC 61215”, Sol. Energy Mater. Sol. Cells, tập 92, trang 1593-1604, tháng 12 năm 2008.

[24] J. Tracy, N. Bosco, R. Dauskardt, “Độ bám dính của chất đóng gói vào lớp kim loại hóa bề mặt trên các tế bào quang điện”, IEEE J. Photovolt., tập 7, trang. 1635-1639, tháng 9 năm 2017.

[25] A. Tabanjat, M. Becherif, D. Hissel, “Giải pháp cấu hình lại cho các tấm pin PV được che bóng bằng cách sử dụng điều khiển chuyển mạch”, Renew. Energy, tập 82, trang. 4-13, tháng 10 năm 2015.

[26] A. Dolara, GC Lazaroiu, S. Leva, et al., “Nghiên cứu thực nghiệm về các kịch bản che bóng một phần trên các mô-đun PV (quang điện)”, Năng lượng, tập 55, trang 466-475, tháng 6 năm 2015.

[27] M. Bressan, Y. EI Basri, AG Galeano, et al., “Một phương pháp phát hiện lỗi bóng dựa trên phân tích lỗi chuẩn của đường cong IV”, Renew. Năng lượng, tập 99, trang 1181-1190, tháng 12 năm 2016.

[28] A. Dolara, GC Lazaroiu, S. Leva, et al., “Những vết ố sên và vết nứt nhỏ của tế bào ảnh hưởng đến công suất tối đa của mô-đun quang điện và sản xuất năng lượng”, IEEE J. Photovolt., tập 6, trang 1269-1277, tháng 6 năm 2016.

[29] A. Manoj, C. Han, F. Michael, “Máy gia tốc CNN lớp hợp nhất”, Proc. MICRO, Đài Bắc, Đài Loan, tháng 10 năm 2016.

[30] K. Simonyan, A. Zisserman, “Mạng tích chập rất sâu để nhận dạng hình ảnh quy mô lớn”, Thị giác máy tính và Nhận dạng mẫu, tháng 4 năm 2015.

[31] W. Liu, Y. Wen, Z. Yu, “Mất mát softmax biến độ lớn cho mạng nơ-ron tích chập”, Proc. ICML, New York, NY, Hoa Kỳ, tháng 11 năm 2017.

[32] X. Jiang, Y. Pang, X. Li, et al., “Mạng nơ-ron sâu với đơn vị tuyến tính chính lưu đàn hồi để nhận dạng đối tượng”, Neurocomputing, tập 275, trang 1132-1139, tháng 2 năm 2018.

[33] A. Botev, G. Lever, D. Barber, “Độ dốc và động lượng tăng tốc của Nesterov như là phép xấp xỉ cho quá trình hạ xuống cập nhật được điều chỉnh”, Proc. IJCNN, Anchorage, AK, Hoa Kỳ, tháng 5 năm 2017.



Xiaoxia Li nhận bằng Cử nhân Khoa học về tự động hóa từ Đại học Chiết Giang, Hàng Châu, Trung Quốc vào năm 2015, nơi cô hiện đang theo đuổi bằng Tiến sĩ về lý thuyết điều khiển và kỹ thuật điều khiển. Các mối quan tâm nghiên cứu của cô bao gồm phân tích hình ảnh, phân tích và mô hình hóa năng lượng tái tạo, phát hiện lỗi và máy bay không người lái.



Qiang Yang (M'03-SM'18) nhận bằng Tiến sĩ Kỹ thuật Điện tử và Khoa học Máy tính từ Queen Mary, Đại học London, London, Vương quốc Anh, năm 2007 và làm việc tại Khoa Kỹ thuật Điện và Điện tử tại Imperial College London, Vương quốc Anh, từ năm 2007 đến năm 2010. Ông đã đến thăm Đại học British Columbia và Đại học Victoria Canada với tư cách là học giả thỉnh giảng vào năm 2015 và 2016. Hiện ông là Phó Giáo sư tại Khoa Kỹ thuật Điện, Đại học Chiết Giang, Trung Quốc và đã xuất bản hơn 150 bài báo kỹ thuật, nộp 50 bằng sáng chế quốc gia, đồng tác giả 3 cuốn sách và một số chương sách. Các mối quan tâm nghiên cứu của ông trong nhiều năm qua bao gồm mạng lưới truyền thông, hệ thống năng lượng thông minh và mô hình hóa, điều khiển và tối ưu hóa mạng phức hợp quy mô lớn. Ông là thành viên cao cấp của IEEE, IET và là Thành viên cao cấp của Liên đoàn Máy tính Trung Quốc (CCF).



Zhuo Lou nhận bằng Cử nhân Khoa học về tự động hóa từ Đại học Chiết Giang, Hàng Châu, Trung Quốc vào năm 2016, nơi cô hiện đang theo đuổi bằng thạc sĩ về lý thuyết điều khiển và kỹ thuật điều khiển. Các mối quan tâm nghiên cứu của cô bao gồm phân tích hình ảnh, thị giác máy tính và máy bay không người lái.



Wenjun Yan nhận bằng Thạc sĩ và Tiến sĩ từ Đại học Chiết Giang, Hàng Châu, Trung Quốc, lần lượt vào năm 1991 và 1994. Hiện tại, ông là Giáo sư chính thức tại Khoa Kỹ thuật Điện, Đại học Chiết Giang. Các lĩnh vực nghiên cứu của ông bao gồm điều khiển mạnh mẽ, chẩn đoán lỗi cho hệ thống hybrid, robot dịch vụ tại nhà và điều phối phối hợp cho điện và nhiệt trong lưới điện vi mô.